

CS114 - Exam 02 Answer

Quoc Kien

Table of contents

ĐÁP ÁN ĐỀ THI MACHINE LEARNING — ĐỀ 02	2
Câu 1. MLE cho Linear Regression — Chứng minh OLS	2
1.1 Hàm mật độ	2
1.2 Hàm Likelihood	2
1.3 Chứng minh MLE OLS	2
1.4 Normal Equations	3
Câu 2. Gaussian Discriminant Analysis	3
2.1 Prior	3
2.2 Mean	3
2.3 Variance chung	3
2.4 Phân loại $x = 3.5$	4
2.5 Ranh giới quyết định	4
Câu 3. Logistic Regression — Gradient Descent	4
3.1 Xác suất ban đầu	4
3.2 Gradient	5
3.3 Cập nhật	6
3.4 Ý nghĩa	6
Câu 4. Decision Tree — Entropy	6
4.1 Entropy ban đầu	6
4.2 Information Gain — Nợ	6
4.3 Information Gain — Thu nhập	7
4.4 Kết luận	7
Câu 5. Backpropagation — Mạng 2-2-1	7
5.1 Forward Propagation	7
5.2 Loss	7
5.3 Backpropagation	8
5.4 Gradient	8
5.5 Cập nhật ($\eta = 0.1$)	8
Câu 6. K-means	8
6.1 Iteration 0	8
Iteration 1	9
6.2 Với $K = 3$	9
6.3 Elbow	9
Câu 7. Thử thách: Hội tụ của K-means và Giới hạn của Đảm bảo Hội tụ	10
7.1 Bước gán cụm	10
7.2 Bước cập nhật tâm	10

7.3 Hội tụ hữu hạn	11
7.4 Ví dụ hai khối tạo	11
7.5 Vì sao vẫn không đảm bảo global minimum?	12
7.6 Cách giảm rủi ro nghiệm cục bộ	12

ĐÁP ÁN ĐỀ THI MACHINE LEARNING — ĐỀ 02

Câu 1. MLE cho Linear Regression — Chứng minh OLS

1.1 Hàm mật độ

$$P(y_i | \mathbf{x}_i; \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

1.2 Hàm Likelihood

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

1.3 Chứng minh MLE OLS

Log-likelihood:

$$\begin{aligned} \ell(\beta) &= \sum_{i=1}^n \left[\log \frac{1}{\sqrt{2\pi}\sigma} - \frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2} \right] \\ &= n \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2 \end{aligned}$$

Hạng đầu là hằng số theo β . Hệ số $\frac{1}{2\sigma^2} > 0$.

$$\max_{\beta} \ell \iff \min_{\beta} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2 \quad \blacksquare$$

1.4 Normal Equations

$$\begin{aligned} L &= \frac{1}{2}(\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta) \\ &= \frac{1}{2}(\mathbf{y}^T\mathbf{y} - 2\beta^T\mathbf{X}^T\mathbf{y} + \beta^T\mathbf{X}^T\mathbf{X}\beta) \end{aligned}$$

Gradient:

$$\nabla_{\beta}L = -\mathbf{X}^T\mathbf{y} + \mathbf{X}^T\mathbf{X}\beta = \mathbf{0}$$

$$\implies \mathbf{X}^T\mathbf{X}\beta = \mathbf{X}^T\mathbf{y}$$

$$\implies \beta = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y} \quad \blacksquare$$

Câu 2. Gaussian Discriminant Analysis

2.1 Prior

$$P(y=0) = \frac{4}{8} = 0.5, \quad P(y=1) = \frac{4}{8} = 0.5$$

2.2 Mean

$$\mu_0 = \frac{1.0 + 1.5 + 2.0 + 2.5}{4} = \frac{7.0}{4} = 1.75$$

$$\mu_1 = \frac{5.0 + 5.5 + 6.0 + 6.5}{4} = \frac{23.0}{4} = 5.75$$

2.3 Variance chung

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_{y_i})^2$$

$$\text{Lớp 0: } (1.0-1.75)^2 + (1.5-1.75)^2 + (2.0-1.75)^2 + (2.5-1.75)^2 = 0.5625 + 0.0625 + 0.0625 + 0.5625 = 1.25$$

$$\text{Lớp 1: } (5.0-5.75)^2 + (5.5-5.75)^2 + (6.0-5.75)^2 + (6.5-5.75)^2 = 0.5625 + 0.0625 + 0.0625 + 0.5625 = 1.25$$

$$\sigma^2 = \frac{1.25 + 1.25}{8} = \frac{2.50}{8} = 0.3125$$

2.4 Phân loại $x = 3.5$

$$P(x = 3.5 \mid y = 0) = \frac{1}{\sqrt{2\pi(0.3125)}} \exp\left(-\frac{(3.5 - 1.75)^2}{2(0.3125)}\right) = \frac{1}{1.4005} \exp\left(-\frac{3.0625}{0.625}\right) = 0.7142 \cdot e^{-4.9} \approx 0.00532$$

$$P(x = 3.5 \mid y = 1) = \frac{1}{1.4005} \exp\left(-\frac{(3.5 - 5.75)^2}{0.625}\right) = 0.7142 \cdot e^{-8.1} \approx 0.000216$$

Nhân prior:

$$\text{score}_0 = 0.00532 \times 0.5 = 0.00266$$

$$\text{score}_1 = 0.000216 \times 0.5 = 0.000108$$

Posterior:

$$P(y = 0 \mid x = 3.5) = \frac{0.00266}{0.00266 + 0.000108} = \frac{0.00266}{0.00277} \approx 0.961$$

Kết luận: Phân loại $x = 3.5$ vào **lớp 0**.

2.5 Ranh giới quyết định

Vì prior bằng nhau, ranh giới là điểm cách đều hai mean:

$$x^* = \frac{\mu_0 + \mu_1}{2} = \frac{1.75 + 5.75}{2} = 3.75$$

(Khi prior bằng nhau và variance chung, ranh giới nằm giữa hai mean.)

Câu 3. Logistic Regression — Gradient Descent

3.1 Xác suất ban đầu

Khi $\beta = (0, 0, 0)$: $z_i = 0$ cho mọi mẫu, nên $\hat{p}_i = \sigma(0) = 0.5$ cho tất cả.

3.2 Gradient

Ma trận $\mathbf{X}$ (cột 1 cho bias):

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \\ 1 & 3 & 1 \\ 1 & 0 & 3 \end{pmatrix}$$

Sai số: $\hat{p}_i - y_i$:

STT	$\hat{p}$	y	$\hat{p} - y$
1	0.5	1	-0.5
2	0.5	0	0.5
3	0.5	1	-0.5
4	0.5	0	0.5
5	0.5	1	-0.5
6	0.5	0	0.5

$$\nabla J = \frac{1}{6} \mathbf{X}^T (\hat{\mathbf{p}} - \mathbf{y})$$

Thành phần bias ($x_0 = 1$):

$$\frac{1}{6} \sum (\hat{p}_i - y_i) = \frac{1}{6} (-0.5 + 0.5 - 0.5 + 0.5 - 0.5 + 0.5) = 0$$

Thành phần β_1 :

$$\begin{aligned} \frac{1}{6} \sum (\hat{p}_i - y_i) x_{i1} &= \frac{1}{6} [(-0.5)(1) + (0.5)(0) + (-0.5)(2) + (0.5)(1) + (-0.5)(3) + (0.5)(0)] \\ &= \frac{1}{6} (-0.5 + 0 - 1.0 + 0.5 - 1.5 + 0) = \frac{-2.5}{6} = -0.4167 \end{aligned}$$

Thành phần β_2 :

$$\begin{aligned} \frac{1}{6} \sum (\hat{p}_i - y_i) x_{i2} &= \frac{1}{6} [(-0.5)(0) + (0.5)(1) + (-0.5)(1) + (0.5)(2) + (-0.5)(1) + (0.5)(3)] \\ &= \frac{1}{6} (0 + 0.5 - 0.5 + 1.0 - 0.5 + 1.5) = \frac{2.0}{6} = 0.3333 \end{aligned}$$

$$\nabla J = \begin{pmatrix} 0 \\ -0.4167 \\ 0.3333 \end{pmatrix}$$

3.3 Cập nhật

$$\beta_{new} = \beta - \alpha \nabla J = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} - 0.5 \begin{pmatrix} 0 \\ -0.4167 \\ 0.3333 \end{pmatrix} = \begin{pmatrix} 0 \\ 0.2083 \\ -0.1667 \end{pmatrix}$$

3.4 Ý nghĩa

- β_1 tăng (dương): x_1 lớn tương quan dương với $y = 1$. Đúng vì các mẫu dương có x_1 lớn (1, 2, 3).
 - β_2 giảm (âm): x_2 lớn tương quan dương với $y = 0$. Đúng vì các mẫu $y = 0$ có x_2 lớn (1, 2, 3).
 - Bias không đổi vì số mẫu lớp 0 và lớp 1 bằng nhau.
-

Câu 4. Decision Tree — Entropy

4.1 Entropy ban đầu

10 mẫu: 4 Cao, 6 Thấp.

$$\begin{aligned} H(S) &= -\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \\ &= -0.4 \log_2 0.4 - 0.6 \log_2 0.6 = -0.4(-1.3219) - 0.6(-0.7370) \\ &= 0.5288 + 0.4422 = 0.9710 \end{aligned}$$

4.2 Information Gain — Ng

- **Nhiều** (dòng 1,4,7): 3 Cao, 0 Thấp $\rightarrow H = 0$
- **Ít** (dòng 2,3,5,6,8,9,10): 1 Cao, 6 Thấp $\rightarrow H = -\frac{1}{7} \log_2 \frac{1}{7} - \frac{6}{7} \log_2 \frac{6}{7} = 0.5917$

$$G_{split} = \frac{3}{10}(0) + \frac{7}{10}(0.5917) = 0 + 0.4142 = 0.4142$$

$$\text{Gain}_{Ng} = 0.9710 - 0.4142 = 0.5568$$

4.3 Information Gain — Thu nhập

- **Thấp** (dòng 1,4,7,10): 3 Cao, 1 Thấp $\rightarrow H = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} = 0.8113$
- **Trung bình** (dòng 2,6,9): 1 Cao, 2 Thấp $\rightarrow H = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3} = 0.9183$
- **Cao** (dòng 3,5,8): 0 Cao, 3 Thấp $\rightarrow H = 0$

$$G_{split} = \frac{4}{10}(0.8113) + \frac{3}{10}(0.9183) + \frac{3}{10}(0)$$

$$= 0.3245 + 0.2755 + 0 = 0.6000$$

$$\text{Gain}_{\text{Thu nhập}} = 0.9710 - 0.6000 = 0.3710$$

4.4 Kết luận

Thuộc tính	Information Gain
Nợ	0.5568
Thu nhập	0.3710

Chọn Nợ vì Information Gain lớn nhất. Nhánh “Nhiều” nợ $\rightarrow$ thuần nhất lớp Cao (entropy = 0).

Câu 5. Backpropagation — Mạng 2-2-1

5.1 Forward Propagation

$$z_{h1} = 0.5(2) + (-0.3)(-1) + 0.2 = 1.0 + 0.3 + 0.2 = 1.5$$

$$h_1 = \sigma(1.5) = \frac{1}{1+e^{-1.5}} \approx 0.8176$$

$$z_{h2} = (-0.2)(2) + 0.4(-1) + (-0.1) = -0.4 - 0.4 - 0.1 = -0.9$$

$$h_2 = \sigma(-0.9) = \frac{1}{1+e^{0.9}} \approx 0.2891$$

$$z_o = 0.6(0.8176) + (-0.4)(0.2891) + 0.3 = 0.4906 - 0.1156 + 0.3 = 0.6750$$

$$\hat{y} = \sigma(0.6750) \approx 0.6625$$

5.2 Loss

$$L = \frac{1}{2}(0.6625 - 0)^2 = \frac{1}{2}(0.4389) = 0.2195$$

5.3 Backpropagation

$$\delta_o = (\hat{y} - y) \cdot \sigma'(z_o) = (0.6625 - 0) \cdot \hat{y}(1 - \hat{y}) = 0.6625 \times 0.6625 \times 0.3375 = 0.1481$$

$$\delta_{h1} = \delta_o \cdot w_{h1 \rightarrow o} \cdot h_1(1 - h_1) = 0.1481 \times 0.6 \times 0.8176 \times 0.1824 = 0.01325$$

$$\delta_{h2} = \delta_o \cdot w_{h2 \rightarrow o} \cdot h_2(1 - h_2) = 0.1481 \times (-0.4) \times 0.2891 \times 0.7109 = -0.01217$$

5.4 Gradient

Trọng số	Gradient
$\partial L / \partial w_{h1 \rightarrow o} = \delta_o \cdot h_1$	$0.1481 \times 0.8176 = 0.1211$
$\partial L / \partial w_{h2 \rightarrow o} = \delta_o \cdot h_2$	$0.1481 \times 0.2891 = 0.04282$
$\partial L / \partial w_{x1 \rightarrow h1} = \delta_{h1} \cdot x_1$	$0.01325 \times 2 = 0.02650$
$\partial L / \partial w_{x2 \rightarrow h1} = \delta_{h1} \cdot x_2$	$0.01325 \times (-1) = -0.01325$
$\partial L / \partial w_{x1 \rightarrow h2} = \delta_{h2} \cdot x_1$	$-0.01217 \times 2 = -0.02434$
$\partial L / \partial w_{x2 \rightarrow h2} = \delta_{h2} \cdot x_2$	$-0.01217 \times (-1) = 0.01217$

5.5 Cập nhật ($\eta = 0.1$)

Kết nối	w_{old}	Gradient	$w_{new} = w_{old} - 0.1 \times \text{grad}$
$x_1 \rightarrow h_1$	0.500	0.02650	0.4974
$x_2 \rightarrow h_1$	-0.300	-0.01325	-0.2987
$x_1 \rightarrow h_2$	-0.200	-0.02434	-0.1976
$x_2 \rightarrow h_2$	0.400	0.01217	0.3988
$h_1 \rightarrow o$	0.600	0.1211	0.5879
$h_2 \rightarrow o$	-0.400	0.04282	-0.4043

Câu 6. K-means

6.1 Iteration 0

$$\mu_1 = 2, \mu_2 = 11$$

x	$d(x, \mu_1)$	$d(x, \mu_2)$	Cụm
1	1	100	1
2	0	81	1
3	1	64	1
10	64	1	2
11	81	0	2
12	100	1	2
20	324	81	2
21	361	100	2

$$C_1 = \{1, 2, 3\}, C_2 = \{10, 11, 12, 20, 21\}$$

$$J_0 = \frac{1}{8}(1 + 0 + 1 + 1 + 0 + 1 + 81 + 100) = \frac{185}{8} = 23.125$$

Cập nhật:

$$\mu_1^{(1)} = \frac{1 + 2 + 3}{3} = 2$$

$$\mu_2^{(1)} = \frac{10 + 11 + 12 + 20 + 21}{5} = \frac{74}{5} = 14.8$$

Iteration 1

Với $\mu_1 = 2$, $\mu_2 = 14.8$:

x	$d^2(x, 2)$	$d^2(x, 14.8)$	Cụm
1	1	190.44	1
2	0	163.84	1
3	1	139.24	1
10	64	23.04	2
11	81	14.44	2
12	100	7.84	2
20	324	27.04	2
21	361	38.44	2

Không đổi: $C_1 = \{1, 2, 3\}$, $C_2 = \{10, 11, 12, 20, 21\}$

$$J_1 = \frac{1}{8}(1 + 0 + 1 + 23.04 + 14.44 + 7.84 + 27.04 + 38.44) = \frac{112.8}{8} = 14.1$$

$$\mu_1^{(2)} = 2, \quad \mu_2^{(2)} = 14.8 \quad (\text{hội tụ})$$

6.2 Với $K = 3$

$$C_1 = \{1, 2, 3\}: \mu_1 = 2, \text{ distortion} = (1 + 0 + 1)/3 = 0.667$$

$$C_2 = \{10, 11, 12\}: \mu_2 = 11, \text{ distortion} = (1 + 0 + 1)/3 = 0.667$$

$$C_3 = \{20, 21\}: \mu_3 = 20.5, \text{ distortion} = (0.25 + 0.25)/2 = 0.25$$

$$J_{K=3} = \frac{1}{8}(1 + 0 + 1 + 1 + 0 + 1 + 0.25 + 0.25) = \frac{4.5}{8} = 0.5625$$

6.3 Elbow

K	Distortion
1	rất lớn
2	14.1
3	0.5625

Giảm rất mạnh từ $K = 2$ sang $K = 3$ (từ 14.1 xuống 0.56). **Chọn** $K = 3$ vì dữ liệu có 3 nhóm rõ ràng ($\{1,2,3\}$, $\{10,11,12\}$, $\{20,21\}$).

Câu 7. Thử thách: Hội tụ của K-means và Giới hạn của Đảm bảo Hội tụ

7.1 Bước gán cụm

Khi các tâm $\mu_1, \dots, \mu_K$ cố định, mỗi điểm $\mathbf{x}^{(i)}$ đóng góp:

$$\left\| \mathbf{x}^{(i)} - \mu_{c_i} \right\|_2^2.$$

Chọn cụm gần nhất nghĩa là:

$$c_i^{new} = \arg \min_k \left\| \mathbf{x}^{(i)} - \mu_k \right\|_2^2.$$

Do đó với từng điểm:

$$\left\| \mathbf{x}^{(i)} - \mu_{c_i^{new}} \right\|_2^2 \leq \left\| \mathbf{x}^{(i)} - \mu_{c_i^{old}} \right\|_2^2.$$

Cộng trên mọi điểm suy ra J không tăng.

7.2 Bước cập nhật tâm

Khi nhãn cụm cố định, bài toán của cụm C_k là:

$$\min_{\mu_k} \sum_{\mathbf{x}^{(i)} \in C_k} \left\| \mathbf{x}^{(i)} - \mu_k \right\|_2^2.$$

Lấy gradient:

$$\nabla_{\mu_k} J_k = -2 \sum_{\mathbf{x}^{(i)} \in C_k} \mathbf{x}^{(i)} + 2|C_k|\mu_k.$$

Đặt bằng 0:

$$\mu_k = \frac{1}{|C_k|} \sum_{\mathbf{x}^{(i)} \in C_k} \mathbf{x}^{(i)}.$$

Vì mean là nghiệm tối ưu của bài toán bình phương nhỏ nhất trong cụm, bước cập nhật tâm cũng không làm tăng J .

7.3 Hội tụ hữu hạn

Mỗi vòng lặp gồm hai bước đều làm J giảm hoặc giữ nguyên. Đồng thời $J \geq 0$. Hơn nữa, với m điểm và K cụm, số cách gán cụm tối đa là K^m , hữu hạn. Vì thuật toán không thể tạo vô hạn trạng thái gán cụm khác nhau với J giảm mãi, K-means phải dừng sau hữu hạn bước khi nhãn cụm không đổi.

7.4 Ví dụ hai khởi tạo

Dữ liệu: $x = \{0, 2, 3, 10, 11, 12\}$, $K = 2$.

Trường hợp A: $\mu_1 = 0$, $\mu_2 = 10$.

Gán cụm:

$$C_1 = \{0, 2, 3\}, \quad C_2 = \{10, 11, 12\}.$$

Cập nhật:

$$\mu_1 = \frac{0 + 2 + 3}{3} = \frac{5}{3}, \quad \mu_2 = \frac{10 + 11 + 12}{3} = 11.$$

Gán lại không đổi, nên hội tụ. SSE:

$$J_A = (0 - \frac{5}{3})^2 + (2 - \frac{5}{3})^2 + (3 - \frac{5}{3})^2 + (10 - 11)^2 + (11 - 11)^2 + (12 - 11)^2.$$

$$J_A = \frac{25}{9} + \frac{1}{9} + \frac{16}{9} + 1 + 0 + 1 = \frac{42}{9} + 2 = \frac{20}{3} \approx 6.667.$$

Trường hợp B: $\mu_1 = 2$, $\mu_2 = 3$.

Lần gán đầu:

$$C_1 = \{0, 2\}, \quad C_2 = \{3, 10, 11, 12\}.$$

Cập nhật:

$$\mu_1 = 1, \quad \mu_2 = \frac{3 + 10 + 11 + 12}{4} = 9.$$

Gán lại:

$$C_1 = \{0, 2, 3\}, \quad C_2 = \{10, 11, 12\}.$$

Cập nhật tiếp:

$$\mu_1 = \frac{5}{3}, \quad \mu_2 = 11.$$

SSE cuối cùng cũng là:

$$J_B = \frac{20}{3} \approx 6.667.$$

7.5 Vì sao vẫn không đảm bảo global minimum?

Trong ví dụ này hai khởi tạo đều đi về cùng nghiệm tốt. Tuy nhiên, đây chỉ là một ví dụ thuận lợi, không phải một chứng minh global optimum cho mọi dữ liệu.

Lý do cốt lõi là $J(\mathbf{c}, \mu)$ không lồi theo đồng thời cả nhãn cụm rời rạc $\mathbf{c}$ và tâm cụm μ . K-means chỉ tối ưu từng khối biến một cách tham lam:

- Tối ưu nhãn khi tâm cố định.
- Tối ưu tâm khi nhãn cố định.

Một trạng thái có thể ổn định theo hai bước này nhưng vẫn không phải cách chia tốt nhất trong toàn bộ không gian phân cụm. Do đó, hội tụ hữu hạn chỉ đảm bảo đạt một điểm cố định của thuật toán Lloyd, không đảm bảo cực tiểu toàn cục.

7.6 Cách giảm rủi ro nghiệm cục bộ

Trong thực tế thường dùng:

- Chạy K-means nhiều lần với nhiều khởi tạo khác nhau rồi chọn nghiệm có SSE nhỏ nhất.
- Dùng K-means++ để chọn tâm ban đầu xa nhau hơn và có xác suất khởi tạo tốt hơn.
- Kiểm tra elbow/silhouette để tránh chọn K quá sai so với cấu trúc dữ liệu.

HẾT ĐÁP ÁN