

# CS114 - Exam 05 Answer

Quoc Kien

## Table of contents

|                                                         |          |
|---------------------------------------------------------|----------|
| <b>ĐÁP ÁN ĐỀ THI MACHINE LEARNING — ĐỀ 05</b>           | <b>2</b> |
| Câu 1. Logistic Regression Hoàn chỉnh                   | 2        |
| 1.1 Bảng tính                                           | 2        |
| 1.2                                                     | 2        |
| 1.3 Gradient                                            | 2        |
| 1.4 Cập nhật                                            | 3        |
| 1.5 Nhận xét                                            | 3        |
| Câu 2. Naive Bayes — Laplace Smoothing                  | 3        |
| 2.1 Không dùng Laplace                                  | 3        |
| 2.2 Với Laplace ( $\alpha = 1$ )                        | 4        |
| 2.3 Kết luận                                            | 4        |
| Câu 3. Decision Tree — Entropy vs Gini                  | 4        |
| Dữ liệu: 8 mẫu, 5 (+), 3 (-)                            | 4        |
| 3.1 IG(A) theo Entropy                                  | 4        |
| 3.2 IG(A) theo Gini                                     | 5        |
| 3.3 IG(B) theo Entropy                                  | 5        |
| 3.4 So sánh                                             | 5        |
| Câu 4. Dropout và Batch Normalization                   | 5        |
| 4.1 Inverted Dropout                                    | 5        |
| 4.2 Batch Normalization                                 | 6        |
| 4.3 Giải thích                                          | 6        |
| Câu 5. Dropout trong Neural Network                     | 6        |
| Câu 6. MLE Exponential Family                           | 7        |
| 6.1 Log-Likelihood                                      | 7        |
| 6.2 Gradient                                            | 7        |
| 6.3 Hessian                                             | 7        |
| 6.4 Chứng minh                                          | 7        |
| 6.5 Ý nghĩa                                             | 7        |
| Câu 7. Thử thách: Vanishing Gradient bằng Quy tắc Chuỗi | 8        |
| 7.1 Chứng minh $\sigma'(z) \leq \frac{1}{4}$            | 8        |
| 7.2 Gradient tăng đầu bằng tích đạo hàm                 | 8        |
| 7.3 Cận trên cho gradient                               | 9        |
| 7.4 Ước lượng với $L = 8$                               | 9        |
| 7.5 Vì sao các kỹ thuật hiện đại giúp giảm vấn đề?      | 10       |

# ĐÁP ÁN ĐỀ THI MACHINE LEARNING — ĐỀ 05

---

## Câu 1. Logistic Regression Hoàn chỉnh

$$\beta = (-0.5, 1.0, -0.8), z = -0.5 + 1.0x_1 - 0.8x_2$$

### 1.1 Bảng tính

| STT | $z$                     | $\hat{p}$ | Lớp | $y$ | Đúng? | Loss                   |
|-----|-------------------------|-----------|-----|-----|-------|------------------------|
| 1   | $-0.5 + 2 - 0.8 = 0.7$  | 0.668     | 1   | 1   |       | $-\log(0.668) = 0.404$ |
| 2   | $-0.5 + 0 - 1.6 = -2.1$ | 0.109     | 0   | 0   |       | $-\log(0.891) = 0.115$ |
| 3   | $-0.5 + 1 - 0 = 0.5$    | 0.622     | 1   | 1   |       | $-\log(0.622) = 0.475$ |
| 4   | $-0.5 + 3 - 1.6 = 0.9$  | 0.711     | 1   | 1   |       | $-\log(0.711) = 0.342$ |
| 5   | $-0.5 - 1 - 0.8 = -2.3$ | 0.091     | 0   | 0   |       | $-\log(0.909) = 0.095$ |
| 6   | $-0.5 + 1 - 2.4 = -1.9$ | 0.130     | 0   | 0   |       | $-\log(0.870) = 0.139$ |

### 1.2

$$\bar{J} = \frac{0.404 + 0.115 + 0.475 + 0.342 + 0.095 + 0.139}{6} = \frac{1.570}{6} = 0.262$$

$$\text{Accuracy} = \frac{6}{6} = 1.0 \quad (100\%)$$

### 1.3 Gradient

Sai số  $\hat{p}_i - y_i$ :

| STT | $\hat{p} - y$ | $x_0$ | $x_1$ | $x_2$ |
|-----|---------------|-------|-------|-------|
| 1   | -0.332        | 1     | 2     | 1     |
| 2   | 0.109         | 1     | 0     | 2     |
| 3   | -0.378        | 1     | 1     | 0     |
| 4   | -0.289        | 1     | 3     | 2     |
| 5   | 0.091         | 1     | -1    | 1     |
| 6   | 0.130         | 1     | 1     | 3     |

$$\nabla_{\beta_0} = \frac{1}{6}(-0.332 + 0.109 - 0.378 - 0.289 + 0.091 + 0.130) = \frac{-0.669}{6} = -0.1115$$

$$\nabla_{\beta_1} = \frac{1}{6}[(-0.332)(2) + (0.109)(0) + (-0.378)(1) + (-0.289)(3) + (0.091)(-1) + (0.130)(1)]$$

$$= \frac{1}{6}(-0.664 + 0 - 0.378 - 0.867 - 0.091 + 0.130) = \frac{-1.870}{6} = -0.3117$$

$$\nabla_{\beta_2} = \frac{1}{6}[(-0.332)(1) + (0.109)(2) + (-0.378)(0) + (-0.289)(2) + (0.091)(1) + (0.130)(3)]$$

$$= \frac{1}{6}(-0.332 + 0.218 + 0 - 0.578 + 0.091 + 0.390) = \frac{-0.211}{6} = -0.0352$$

## 1.4 Cập nhật

$$\beta_{new} = \begin{pmatrix} -0.5 \\ 1.0 - 0.8 \end{pmatrix} - 0.5(-0.1115 - 0.3117 - 0.0352) = \begin{pmatrix} -0.4443 \\ 1.1559 - 0.7824 \end{pmatrix}$$

## 1.5 Nhận xét

- Bias tăng: mô hình đẩy xác suất lớp 1 lên một chút.
- $\beta_1$  tăng:  $x_1$  lớn tương quan mạnh hơn với  $y = 1$ .
- $\beta_2$  tăng nhẹ (bớt âm): điều chỉnh nhẹ mối quan hệ âm với  $x_2$ .
- Accuracy đã 100% nên các thay đổi nhỏ, mô hình đang tinh chỉnh để tăng confidence.

## Câu 2. Naive Bayes — Laplace Smoothing

### 2.1 Không dùng Laplace

Prior:  $P(\text{Rác}) = 3/6 = 0.5$ ,  $P(\text{BT}) = 3/6 = 0.5$

**Lớp Rác (3 mẫu: dòng 1,2,3):** -  $P(\text{giảm giá=Không} \mid \text{Rác}) = 1/3$  -  $P(\text{miễn phí=Có} \mid \text{Rác}) = 2/3$  -  $P(\text{hộp=Không} \mid \text{Rác}) = 3/3 = 1$  -  $P(\text{dự án=Không} \mid \text{Rác}) = 3/3 = 1$

$$\text{score}_{\text{Rác}} = 0.5 \times \frac{1}{3} \times \frac{2}{3} \times 1 \times 1 = 0.1111$$

**Lớp BT (3 mẫu: dòng 4,5,6):** -  $P(\text{giảm giá=Không} \mid \text{BT}) = 3/3 = 1$  -  $P(\text{miễn phí=Có} \mid \text{BT}) = 0/3 = 0 \leftarrow \text{Vấn đề!}$

$$\text{score}_{\text{BT}} = 0.5 \times 1 \times 0 \times \dots = 0$$

**Vấn đề:** Xác suất bằng 0 triệt tiêu toàn bộ posterior. Mô hình luôn kết luận Rác dù “miễn phí” chỉ đơn giản chưa xuất hiện trong lớp BT ở tập huấn luyện.

## 2.2 Với Laplace ( $\alpha = 1$ )

Công thức:  $P(w | c) = \frac{\text{count}(w,c)+1}{N_c+2}$

**Lớp Rác ( $N_c = 3$ ):** -  $P(\text{giảm giá=Không} | \text{Rác}) = \frac{1+1}{3+2} = 2/5 = 0.4$  -  $P(\text{miễn phí=Có} | \text{Rác}) = \frac{2+1}{3+2} = 3/5 = 0.6$  -  $P(\text{hộp=Không} | \text{Rác}) = \frac{3+1}{3+2} = 4/5 = 0.8$  -  $P(\text{dự án=Không} | \text{Rác}) = \frac{3+1}{3+2} = 4/5 = 0.8$

$$\text{score}_{\text{Rác}} = 0.5 \times 0.4 \times 0.6 \times 0.8 \times 0.8 = 0.5 \times 0.1536 = 0.07680$$

**Lớp BT ( $N_c = 3$ ):** -  $P(\text{giảm giá=Không} | \text{BT}) = \frac{3+1}{3+2} = 4/5 = 0.8$  -  $P(\text{miễn phí=Có} | \text{BT}) = \frac{0+1}{3+2} = 1/5 = 0.2$  -  $P(\text{hộp=Không} | \text{BT}) = \frac{1+1}{3+2} = 2/5 = 0.4$  -  $P(\text{dự án=Không} | \text{BT}) = \frac{1+1}{3+2} = 2/5 = 0.4$

$$\text{score}_{\text{BT}} = 0.5 \times 0.8 \times 0.2 \times 0.4 \times 0.4 = 0.5 \times 0.02560 = 0.01280$$

**Posterior:**

$$P(\text{Rác} | \mathbf{x}) = \frac{0.07680}{0.07680 + 0.01280} = \frac{0.07680}{0.08960} = 0.857$$

## 2.3 Kết luận

Phân loại: **Rác** (xác suất 85.7%).

Laplace smoothing cần thiết vì nó ngăn xác suất bằng 0 triệt tiêu toàn bộ tích xác suất. Nó “cho phép” các sự kiện chưa quan sát có một xác suất nhỏ hợp lý.

---

## Câu 3. Decision Tree — Entropy vs Gini

**Dữ liệu: 8 mẫu, 5 (+), 3 (-)**

### 3.1 IG(A) theo Entropy

Entropy cha:  $H = -\frac{5}{8} \log_2 \frac{5}{8} - \frac{3}{8} \log_2 \frac{3}{8}$

$$= -0.625(-0.678) - 0.375(-1.415) = 0.424 + 0.531 = 0.954$$

**A=0** (dòng 1,2,3,8): 1(+), 3(-)  $\rightarrow H = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} = 0.811$

**A=1** (dòng 4,5,6,7): 4(+), 0(-)  $\rightarrow H = 0$

$$IG_E(A) = 0.954 - \frac{4}{8}(0.811) - \frac{4}{8}(0) = 0.954 - 0.406 = 0.549$$

### 3.2 IG(A) theo Gini

Gini cha:  $G = 1 - (5/8)^2 - (3/8)^2 = 1 - 0.391 - 0.141 = 0.469$

**A=0**:  $G = 1 - (1/4)^2 - (3/4)^2 = 1 - 0.0625 - 0.5625 = 0.375$

**A=1**:  $G = 0$

$$IG_G(A) = 0.469 - \frac{4}{8}(0.375) - \frac{4}{8}(0) = 0.469 - 0.188 = 0.281$$

### 3.3 IG(B) theo Entropy

**B=0** (dòng 1,3,4,7): 2(+), 2(-)  $\rightarrow H = 1.0$

**B=1** (dòng 2,5,6,8): 3(+), 1(-)  $\rightarrow H = -\frac{3}{4}\log_2 \frac{3}{4} - \frac{1}{4}\log_2 \frac{1}{4} = 0.811$

$$IG_E(B) = 0.954 - \frac{4}{8}(1.0) - \frac{4}{8}(0.811) = 0.954 - 0.500 - 0.406 = 0.049$$

### 3.4 So sánh

| Thuộc tính | IG (Entropy) | IG (Gini)    |
|------------|--------------|--------------|
| <b>A</b>   | <b>0.549</b> | <b>0.281</b> |
| B          | 0.049        | —            |

**A tốt hơn B** theo cả hai metric. Entropy và Gini thường cho cùng kết luận về thứ tự, chỉ khác giá trị tuyệt đối.

---

## Câu 4. Dropout và Batch Normalization

### 4.1 Inverted Dropout

Dropout mask:  $\mathbf{M} = (1, 0, 1, 0)$ ,  $p = 0.5$

$$\mathbf{a}_{dropout} = \frac{\mathbf{a} \odot \mathbf{M}}{1 - p} = \frac{(0.8, 0, 0.6, 0)}{0.5} = (1.6, 0, 1.2, 0)$$

## 4.2 Batch Normalization

$\mathbf{z} = (2, 4, 6, 8)$

$$\mu_{\mathcal{B}} = \frac{2 + 4 + 6 + 8}{4} = 5$$

$$\sigma_{\mathcal{B}}^2 = \frac{(2-5)^2 + (4-5)^2 + (6-5)^2 + (8-5)^2}{4} = \frac{9+1+1+9}{4} = 5$$

$$\hat{z}_i = \frac{z_i - 5}{\sqrt{5 + 10^{-8}}} \approx \frac{z_i - 5}{2.236}$$

| $z_i$ | $\hat{z}_i$ | $\tilde{z}_i = 2\hat{z}_i + 1$ |
|-------|-------------|--------------------------------|
| 2     | -1.342      | -1.683                         |
| 4     | -0.447      | 0.106                          |
| 6     | 0.447       | 1.894                          |
| 8     | 1.342       | 3.683                          |

## 4.3 Giải thích

**Dropout giống ensemble:** Mỗi bước huấn luyện, dropout tạo ra một mạng con (sub-network) khác nhau bằng cách tắt ngẫu nhiên các neuron. Khi test, sử dụng toàn bộ mạng tương đương với lấy trung bình dự đoán của exponentially nhiều sub-network  $\rightarrow$  giống bagging/ensemble.

**Batch Normalization tăng tốc:** Chuẩn hóa input của mỗi tầng về  $\mu = 0, \sigma = 1$  giảm hiện tượng internal covariate shift (phân phối input thay đổi liên tục khi train). Điều này cho phép dùng learning rate lớn hơn mà không gây dao động, tăng tốc hội tụ.

---

## Câu 5. Dropout trong Neural Network

Kỹ thuật Inverted Dropout ngẫu nhiên tắt đi (đặt giá trị bằng 0) một tỷ lệ  $p$  các nơ-ron ở các tầng ẩn trong mỗi bước lặp khi huấn luyện. Cụ thể, vector kích hoạt  $\mathbf{a}$  được nhân phần tử (element-wise) với một ma trận mặt nạ  $\mathbf{M}$  (chứa 0 và 1) rồi chia cho  $(1-p)$  để giữ nguyên cường độ tín hiệu ( kỳ vọng toán học):

$$\mathbf{a}_{drop} = \frac{\mathbf{a} \odot \mathbf{M}}{1-p}.$$

**Ý nghĩa Ensemble:** Ở mỗi vòng lặp, bằng cách tắt ngẫu nhiên các nơ-ron khác nhau, mô hình thực chất đang huấn luyện một mạng con (sub-network) khác nhau được trích xuất từ mạng toàn cục ban đầu. Khi bước vào giai đoạn dự đoán (inference/test mode) và không dùng Dropout, toàn bộ nơ-ron được giữ lại và tham gia tính toán. Hiệu ứng này tương đương về mặt toán học với việc lấy trung bình dự đoán (model averaging / bagging) của hàng tỷ mạng con đã được huấn luyện, giúp mô hình đạt được sự vững chãi (robust) và giảm thiểu Overfitting hiệu quả.

## Câu 6. MLE Exponential Family

### 6.1 Log-Likelihood

$$\ell(\eta) = \sum_{i=1}^n \log P(y^{(i)} | \eta) = \sum_{i=1}^n [\log b(y^{(i)}) + \eta T(y^{(i)}) - a(\eta)]$$

### 6.2 Gradient

$$\nabla_{\eta} \ell = \sum_{i=1}^n [T(y^{(i)}) - a'(\eta)] = \sum_{i=1}^n [T(y^{(i)}) - \mathbb{E}[T(y) | \eta]]$$

### 6.3 Hessian

$$\nabla_{\eta}^2 \ell = - \sum_{i=1}^n a''(\eta) = -n \cdot a''(\eta)$$

### 6.4 Chứng minh

Ta biết  $a''(\eta) = \text{Var}(T(y) | \eta)$  (tính chất chuẩn của Exponential Family).

Vì phương sai luôn  $\geq 0$ :

$$a''(\eta) = \text{Var}(T(y)) \geq 0$$

$$\Rightarrow \nabla_{\eta}^2 \ell = -n \cdot a''(\eta) \leq 0$$

Tức Hessian  $\preceq 0 \rightarrow$  log-likelihood là hàm **lõm**  $\rightarrow$  negative log-likelihood là hàm **lồi** ■

### 6.5 Ý nghĩa

Vì negative log-likelihood lồi, mọi bài toán MLE cho phân phối thuộc Exponential Family (Gaussian, Bernoulli, Poisson, ...) đều: - Có tối đa **một** cực tiểu toàn cục (không có cực tiểu cục bộ). - Gradient descent/Newton luôn hội tụ đến nghiệm tối ưu. - Đây là lý do nền tảng mà Linear Regression (Gaussian) và Logistic Regression (Bernoulli) đều có hàm loss lồi.

## Câu 7. Thử thách: Vanishing Gradient bằng Quy tắc Chuỗi

### 7.1 Chứng minh $\sigma'(z) \leq \frac{1}{4}$

Với:

$$\sigma(z) = \frac{1}{1 + e^{-z}},$$

ta có:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

Đặt  $s = \sigma(z)$ . Vì sigmoid luôn nằm trong  $(0, 1)$ :

$$s(1 - s) = s - s^2.$$

Đây là parabola quay xuống, đạt cực đại khi:

$$\frac{d}{ds}(s - s^2) = 1 - 2s = 0 \Rightarrow s = \frac{1}{2}.$$

Giá trị cực đại:

$$\frac{1}{2} \left(1 - \frac{1}{2}\right) = \frac{1}{4}.$$

Vậy:

$$0 < \sigma'(z) \leq \frac{1}{4}.$$

### 7.2 Gradient tăng đều bằng tích đạo hàm

Với:

$$L_{oss} = \frac{1}{2}(a^{[L]} - y)^2,$$

ta có:

$$\frac{\partial L_{oss}}{\partial a^{[L]}} = a^{[L]} - y.$$

Gradient theo  $w_1$ :

$$\frac{\partial L_{oss}}{\partial w_1} = \frac{\partial L_{oss}}{\partial a^{[L]}} \frac{\partial a^{[L]}}{\partial a^{[L-1]}} \cdots \frac{\partial a^{[2]}}{\partial a^{[1]}} \frac{\partial a^{[1]}}{\partial w_1}.$$

Với tầng  $\ell \geq 2$ :

$$\frac{\partial a^{[\ell]}}{\partial a^{[\ell-1]}} = \sigma'(z^{[\ell]})w_\ell.$$

Với tầng đầu:

$$\frac{\partial a^{[1]}}{\partial w_1} = \sigma'(z^{[1]})a^{[0]}.$$

Do đó:

$$\frac{\partial L_{oss}}{\partial w_1} = (a^{[L]} - y) \left[ \prod_{\ell=2}^L \sigma'(z^{[\ell]})w_\ell \right] \sigma'(z^{[1]})a^{[0]}.$$

### 7.3 Cận trên cho gradient

Lấy trị tuyệt đối:

$$\left| \frac{\partial L_{oss}}{\partial w_1} \right| \leq |a^{[L]} - y| \left[ \prod_{\ell=2}^L |\sigma'(z^{[\ell]})| |w_\ell| \right] |\sigma'(z^{[1]})| |a^{[0]}|.$$

Vì  $|\sigma'(z)| \leq \frac{1}{4}$  và  $|w_\ell| \leq 1$ :

$$\prod_{\ell=2}^L |\sigma'(z^{[\ell]})| |w_\ell| \leq \left( \frac{1}{4} \right)^{L-1}.$$

Thêm  $|\sigma'(z^{[1]})| \leq \frac{1}{4}$ :

$$\left| \frac{\partial L_{oss}}{\partial w_1} \right| \leq |a^{[L]} - y| |a^{[0]}| \left( \frac{1}{4} \right)^L.$$

Nếu tách riêng phần suy giảm do các tầng sau, tín hiệu truyền từ output về tầng 1 bị nhân bởi ít nhất:

$$\left( \frac{1}{4} \right)^{L-1}.$$

### 7.4 Ước lượng với $L = 8$

Phần suy giảm do các sigmoid tầng sau:

$$\left( \frac{1}{4} \right)^7 = \frac{1}{16384} \approx 0.000061.$$

Tức là trước khi gradient chạm tới tầng đầu, chỉ riêng chuỗi đạo hàm sigmoid đã có thể làm tín hiệu nhỏ đi hơn 16 nghìn lần. Nếu nhiều  $z$  rơi vào vùng bão hòa của sigmoid,  $\sigma'(z)$  còn nhỏ hơn  $\frac{1}{4}$  rất nhiều, nên gradient có thể gần như biến mất.

### 7.5 Vì sao các kỹ thuật hiện đại giúp giảm vấn đề?

- **ReLU:**  $g'(z) = 1$  khi  $z > 0$ , nên gradient không luôn bị nhân với một số tối đa 0.25 như sigmoid. Điều này giúp tín hiệu truyền ngược qua nhiều tầng tốt hơn.
- **Batch Normalization:** Giữ phân phối  $z$  ổn định hơn, giảm khả năng sigmoid/tanh rơi sâu vào vùng bão hòa nơi đạo hàm gần 0.
- **Residual connection:** Tạo đường truyền tắt dạng  $a^{[\ell+1]} = F(a^{[\ell]}) + a^{[\ell]}$ . Khi backprop, gradient có một nhánh cộng trực tiếp qua identity path, giúp tín hiệu không phải đi qua toàn bộ chuỗi đạo hàm phi tuyến.

**HẾT ĐÁP ÁN**