

CS114: Tài liệu Học máy Tổng hợp

Quoc Kien

Mục lục chi tiết

Cách dùng tài liệu này	4
Phần 1: Học máy: Suy luận Bình phương Tối thiểu OLS	5
1. Mô hình Hồi quy Tuyến tính Đơn	5
2. Hàm mất mát: Residual Sum of Squares	5
3. Suy luận hệ số chặn β_0	6
4. Suy luận hệ số góc β_1	7
5. Bảng Công thức Thi: Quy trình Thay số OLS	8
6. Minh họa bằng Python	8
7. Bộ bài tập mẫu có lời giải	10
Bài 1: Tính đường OLS từ 3 điểm	10
Bài 2: Dữ liệu 10 dòng và dự đoán	10
Bài 3: Dùng residual để kiểm tra đường OLS	12
Phần 2: Học máy: Hồi quy Tuyến tính từ Xác suất, MLE, và Ma trận	13
1. Vì sao OLS có thể xuất hiện từ xác suất?	13
2. Maximum Likelihood Estimation dẫn tới OLS	14
3. Biểu diễn ma trận	15
4. Suy luận Normal Equations	15
5. Ý nghĩa hình học	16
6. Bảng Công thức Thi: Matrix OLS	18
7. Bộ bài tập mẫu có lời giải	19
Bài 1: Giải OLS bằng ma trận với hai điểm	19
Bài 2: Bộ dữ liệu 10 dòng, giải đầy đủ bằng matrix OLS	20
Phần 3: Học máy: Phân loại và Tối ưu Hồi quy Logistic	22
1. Bản chất của Bài toán Phân loại (Classification)	22
Tại sao Tuyến tính (Linear Regression) thất bại với Phân loại?	22
2. Mô hình Logistic Regression & Hàm Sigmoid	22
Công thức Xác suất Hợp nhất	23

3. Chứng minh Hàm Mất mát Cross-Entropy bằng MLE	23
4. Chứng minh Tính Lồi (Convex Optimization) bằng Ma trận Hessian	24
Đạo hàm Bậc một (Gradient) via Chain Rule	24
Đạo hàm Bậc hai (Ma trận Hessian)	24
5. Các Phương pháp Tối ưu hóa Toán học	25
Thuật toán Gradient Descent (Tối ưu bậc 1)	25
Phương pháp Newton - Raphson (Tối ưu bậc 2)	25
6. Kiểm tra Thực thi: Sigmoid và Ranh giới Quyết định	27
7. Bảng Công thức Thi: Quy trình Thay số cho Logistic Regression	29
Bộ bài tập mẫu có lời giải	30
Bài 2: Bảng 12 dòng, tính xác suất, loss, accuracy	31
Bài 3: Một bước cập nhật gradient	32
Phần 4: Học máy: Họ Hàm Mũ và Mô hình Tuyến tính Tổng quát (GLM)	34
1. Họ Phân Phối Số Mũ (Exponential Family Distribution - EFD)	34
Các tính chất toán học cốt lõi (Properties)	34
2. Chuẩn hóa các phân phối kinh điển về dạng EFD	34
2.1 Phân phối Bernoulli (Nền tảng của Logistic Regression)	34
2.2 Phân phối Gaussian (Nền tảng của Linear Regression)	36
3. Bản chất Tính Lồi của bài toán MLE thuộc họ EFD	36
4. Khung Mô Hình Tuyến Tính Tổng Quát (Generalized Linear Models - GLMs)	37
5. Bản đồ ánh xạ hệ thống GLM	38
6. Giai đoạn Dự đoán và Thuật toán Tối ưu hóa Tổng quát	38
Giai đoạn Dự đoán (Testing Phase)	38
Thuật toán Cập nhật Trọng số Tổng quát (Gradient Descent)	38
7. Thực hành Minh họa bằng Code Python	39
8. Bảng Công thức Thi: Chọn GLM và Thay số	41
Bộ bài tập mẫu có lời giải	42
Bài 2: Bảng 10 dòng, chọn inverse link phù hợp	43
Bài 3: Tính log-likelihood Bernoulli từ 10 quan sát	44
Phần 5: Học máy: Thuật toán Học Tạo sinh	46
1. Triết lý Mô hình Phân biệt (Discriminative) vs. Mô hình Sinh (Generative)	46
2. Phân tích Phân biệt Gaussian (Gaussian Discriminant Analysis - GDA)	46
2.1 Nhắc lại kiến thức: Phân phối Chuẩn Đa Biến	47
2.2 Các giả định nền tảng của GDA	47
3. Ước lượng Tham số GDA bằng Maximum Likelihood Estimation (MLE)	47
3.1 Ước lượng Tham số Tiên nghiệm ϕ	48
3.2 Ước lượng các Vector Kỳ vọng μ_0 và μ_1	48
3.3 Ước lượng Ma trận Hiệp phương sai Chung Σ	48
4. Chứng minh GDA tương đương toán học với Hàm Sigmoid	49
Biến đổi Đại số chi tiết	49

5. Thuật toán Phân loại Naive Bayes (Dữ liệu rời rạc)	50
5.1 Giả định Độc lập Điều kiện Naive Bayes	50
5.2 Thiết lập các Tham số và MLE	50
5.3 Kỹ thuật mịn hóa Laplace (Laplace Smoothing)	51
6. Thực hành Triển khai GDA bằng Python từ đầu (Scratch)	51
7. Bảng Công thức Thi: Cách Thay số cho Bộ phân loại Sinh	54
Bộ bài tập mẫu có lời giải	56
Bài 2: Naive Bayes với bảng đếm từ	56
Bài 3: Gaussian Discriminant Analysis từ 12 điểm một chiều	58
Phần 6: Học máy: Cây Quyết định Nâng cao và Phương pháp Kết hợp	60
1. Cơ chế Hoạt động của Cây Quyết định (Decision Tree)	60
2. Hàm Mục Tiêu và Các Độ Đo Ô Nhiễm (Impurity Metrics)	61
2.1 Đối với Bài toán Phân loại (Classification)	61
2.2 Đối với Bài toán Hồi quy (Regression Trees - CART)	61
3. Kiểm Soát Overfitting & Kỹ Thuật Cắt Tỉa Cây (Pruning)	62
4. Các Phương Pháp Học Tập Hợp (Ensemble Methods)	62
4.1 Phương pháp Bagging (Bootstrap Aggregating)	62
4.2 Phương pháp Boosting & Bản chất Toán học của XGBoost	63
5. Bảng Công thức Thi: Máy tính Phân tách Cây Quyết định	64
Bộ bài tập mẫu có lời giải	66
Bài 2: Chọn split tốt nhất từ bộ dữ liệu 12 dòng	67
Bài 3: Lá hồi quy và MSE sau split	69
Phần 7: Học máy: Mạng Nơ-ron và Lan truyền Ngược Vector hóa	70
1. Bức tranh tinh thần: mạng nơ-ron đang lưu gì?	70
2. Một nơ-ron đơn: từ đầu vào đến dự đoán	71
3. Lan truyền xuôi: dữ liệu chảy từ trái sang phải	72
4. Lan truyền ngược: lỗi chảy từ phải sang trái	73
5. Vì sao sigmoid dễ làm mất gradient?	75
6. Dropout và Chuẩn hóa Mini-batch	77
Dropout	77
Chuẩn hóa mini-batch	77
7. Bảng Công thức Thi: Lan truyền Xuôi, Lan truyền Ngược, Cập nhật	78
8. Bộ bài tập mẫu có lời giải	79
Bài 1: Xác định kích thước ma trận	79
Bài 2: Lan truyền xuôi qua mạng 2-2-1	80
Bài 3: Một bước lan truyền ngược ở tầng đầu ra	82
Phần 8: Học máy: Tối ưu hóa, Thiên lệch-Phương sai, và Điều chuẩn	83
1. Tối ưu hóa bằng Gradient Descent	83
2. Batch, Stochastic, và Mini-batch	83
3. Underfitting và Overfitting	85

4. Bias-Variance Decomposition	86
5. Regularization	87
6. Chọn siêu tham số bằng Cross-validation	87
7. Bảng Công thức Thi: Bias, Variance, Regularization	88
8. Bộ bài tập mẫu có lời giải	89
Bài 1: Tính objective Ridge	89
Bài 2: Chọn λ từ bảng cross-validation	90
Bài 3: Một bước Gradient Descent trên dữ liệu 12 dòng	91
Phần 9: Học máy: Học Không Giám sát và Phân cụm K-means	93
1. Tổng quan về Học Không Giám Sát (Unsupervised Learning)	93
2. Giải thuật Phân Cụm K-means (K-means Clustering)	93
2.1 Hàm Mục Tiêu Định Lượng (Distortion Function / Cost Function)	93
2.2 Quy Trình Vòng Lặp Hội Tụ (Coordinate Descent)	94
3. Cải Tiến Chọn Tâm Ban Đầu: K-means++	97
4. Thực Hành Trace Thuật Toán Bằng Tay (Bản Số Hóa)	98
4.1 Khởi tạo dữ liệu gốc (Input Data)	98
4.2 Vòng Lặp 1 (Iteration 1)	98
4.3 Vòng Lặp 2 (Iteration 2)	99
4.4 Kết luận hội tụ (Convergence)	100
5. Thực Hành Hiện Thực Hóa Thuật Toán Bằng Python	100
6. Bảng Công thức Thi: Các Điểm Cốt lõi của K-means	103
Bộ bài tập mẫu có lời giải	104
Bài 2: K-means trên bộ dữ liệu 10 điểm hai chiều	105
Bài 3: Chọn K bằng elbow từ bảng distortion	106

Cách dùng tài liệu này

Tài liệu này ghép toàn bộ 9 notebook CS114 thành một bản PDF lớn. Mỗi notebook bắt đầu ở một trang mới và có heading cấp 1 riêng, nên có thể đi nhanh bằng mục lục PDF hoặc thanh bookmarks của trình đọc PDF.

Các phần bài tập vẫn được viết bằng lời giải tay: thay số, tính toán, kết luận. Các đoạn Python chỉ phục vụ minh họa, kiểm tra đạo hàm, hoặc tạo hình trực quan.

Phần 1: Học máy: Suy luận Bình phương Tối thiểu OLS

Nguồn: `quarto/LR_OLS_Derivation.qmd`

1. Mô hình Hồi quy Tuyến tính Đơn

Trong hồi quy tuyến tính đơn, ta mô hình hóa quan hệ giữa biến phụ thuộc y và biến độc lập x bằng một đường thẳng:

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

Trong đó:

- β_0 là **hệ số chặn**: giá trị dự đoán của y khi $x = 0$.
- β_1 là **hệ số góc**: khi x tăng 1 đơn vị, $\hat{y}$ thay đổi trung bình β_1 đơn vị.
- $\hat{y}_i$ là giá trị mô hình dự đoán cho quan sát thứ i .

Mục tiêu của OLS là chọn β_0, β_1 sao cho sai lệch giữa dữ liệu thật y_i và dự đoán $\hat{y}_i$ là nhỏ nhất.

2. Hàm mất mát: Residual Sum of Squares

Sai số của điểm thứ i là:

$$e_i = y_i - \hat{y}_i = y_i - \beta_0 - \beta_1 x_i$$

OLS dùng tổng bình phương sai số:

$$RSS = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Ta thường đặt thêm hệ số $\frac{1}{2}$ để khi đạo hàm, số 2 triệt tiêu:

$$f(\beta_0, \beta_1) = \frac{1}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Thực tế: bình phương làm sai số âm/dương đều thành dương, đồng thời phạt mạnh các điểm lệch xa.

3. Suy luận hệ số chặn β_0

Lấy đạo hàm riêng theo β_0 :

$$\frac{\partial f}{\partial \beta_0} = \sum_{i=1}^n -(y_i - \beta_0 - \beta_1 x_i) = 0$$

Nhân hai vế với -1 :

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

Tách tổng:

$$\sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0$$

Chuyển vế:

$$n\beta_0 = \sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i$$

Chia cho n :

$$\beta_0 = \frac{1}{n} \sum_{i=1}^n y_i - \beta_1 \frac{1}{n} \sum_{i=1}^n x_i$$

Vì $\bar{x} = \frac{1}{n} \sum x_i$ và $\bar{y} = \frac{1}{n} \sum y_i$, ta có:

$$\boxed{\beta_0 = \bar{y} - \beta_1 \bar{x}}$$

Điều này cũng cho thấy đường OLS luôn đi qua điểm trung bình $(\bar{x}, \bar{y})$.

4. Suy luận hệ số góc β_1

Lấy đạo hàm riêng theo β_1 :

$$\frac{\partial f}{\partial \beta_1} = \sum_{i=1}^n -(y_i - \beta_0 - \beta_1 x_i)x_i = 0$$

Nhân với -1 :

$$\sum_{i=1}^n (x_i y_i - \beta_0 x_i - \beta_1 x_i^2) = 0$$

Thay $\beta_0 = \bar{y} - \beta_1 \bar{x}$ và dùng $\sum x_i = n\bar{x}$:

$$\sum x_i y_i - (\bar{y} - \beta_1 \bar{x})n\bar{x} - \beta_1 \sum x_i^2 = 0$$

Khai triển:

$$\sum x_i y_i - n\bar{x}\bar{y} + n\beta_1 \bar{x}^2 - \beta_1 \sum x_i^2 = 0$$

Gom các hạng tử chứa β_1 :

$$\sum x_i y_i - n\bar{x}\bar{y} = \beta_1 \left(\sum x_i^2 - n\bar{x}^2 \right)$$

Suy ra:

$$\beta_1 = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$$

Dạng dễ nhớ hơn:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Tử số đo mức x và y cùng biến thiên; mẫu số đo độ phân tán của x .

5. Bảng Công thức Thi: Quy trình Thay số OLS

Bước	Công thức	Ý nghĩa
1. Tính trung bình	$\bar{x} = \frac{1}{n} \sum x_i, \bar{y} = \frac{1}{n} \sum y_i$	Xác định tâm dữ liệu.
2. Tính S_{xy}	$S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	Đo x, y biến thiên cùng nhau.
3. Tính S_{xx}	$S_{xx} = \sum (x_i - \bar{x})^2$	Đo độ phân tán của x .
4. Tính slope	$\beta_1 = \frac{S_{xy}}{S_{xx}}$	Độ dốc đường hồi quy.
5. Tính intercept	$\beta_0 = \bar{y} - \beta_1 \bar{x}$	Dịch đường thẳng cho đi qua điểm trung bình.
6. Dự đoán	$\hat{y} = \beta_0 + \beta_1 x$	Thay x mới vào mô hình.
7. Tính residual	$e_i = y_i - \hat{y}_i$	Sai số dọc của từng điểm.

Mẹo nhớ nhanh.

- $\beta_1 > 0$: x tăng thì y có xu hướng tăng.
- $\beta_1 < 0$: x tăng thì y có xu hướng giảm.
- Nếu $S_{xx} = 0$, mọi x_i giống nhau nên không xác định được slope.
- Đường OLS luôn đi qua $(\bar{x}, \bar{y})$.

6. Minh họa bằng Python

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)
X = 2 * np.random.rand(50, 1)
y = 4 + 3 * X + np.random.randn(50, 1)

x_mean = np.mean(X)
y_mean = np.mean(y)
beta_1 = np.sum((X - x_mean) * (y - y_mean)) / np.sum((X - x_mean) ** 2)
beta_0 = y_mean - beta_1 * x_mean

X_new = np.array([[0], [2]])
y_predict = beta_0 + beta_1 * X_new

print("beta_0:", round(float(beta_0), 3))
```



```

print("beta_1:", round(float(beta_1), 3))

plt.figure(figsize=(8, 5))
plt.scatter(X, y, color="#4C78A8", label="Dữ liệu")
plt.plot(X_new, y_predict, color="#F58518", linewidth=2, label=f"OLS: y = 
↪ {beta_0:.2f} + {beta_1:.2f}x")
plt.xlabel("x")
plt.ylabel("y")
plt.title("Minh họa hồi quy tuyến tính OLS")
plt.legend()
plt.grid(alpha=0.25)
plt.show()

```

beta_0: 4.097
beta_1: 2.888




Figure 1: Đường OLS khớp dữ liệu và các residual theo phương dọc.

7. Bộ bài tập mẫu có lời giải

Bài 1: Tính đường OLS từ 3 điểm

Đề bài. Cho ba điểm $(1, 2)$, $(2, 3)$, $(3, 5)$. Tìm đường OLS $\hat{y} = \beta_0 + \beta_1 x$.

Lời giải.

$$\bar{x} = \frac{1+2+3}{3} = 2, \quad \bar{y} = \frac{2+3+5}{3} = \frac{10}{3}$$

$$S_{xy} = (1-2)(2-\frac{10}{3}) + (2-2)(3-\frac{10}{3}) + (3-2)(5-\frac{10}{3}) = 3$$

$$S_{xx} = (1-2)^2 + (2-2)^2 + (3-2)^2 = 2$$

$$\beta_1 = \frac{3}{2} = 1.5, \quad \beta_0 = \frac{10}{3} - 1.5(2) = \frac{1}{3}$$

Kết luận.

$$\hat{y} = \frac{1}{3} + 1.5x$$

Bài 2: Dữ liệu 10 dòng và dự đoán

Đề bài. Cho bảng dữ liệu:

x	1	2	3	4	5	6	7	8	9	10
y	3	5	6	8	11	12	14	17	18	20

Hãy fit đường OLS và dự đoán y khi $x = 12$.

Tính trung bình:

$$\bar{x} = \frac{1+2+\dots+10}{10} = 5.5$$

$$\bar{y} = \frac{3 + 5 + 6 + 8 + 11 + 12 + 14 + 17 + 18 + 20}{10} = 11.4$$

Tính hai tổng chính:

$$S_{xy} = \sum_{i=1}^{10} (x_i - \bar{x})(y_i - \bar{y}) = 159.0$$

$$S_{xx} = \sum_{i=1}^{10} (x_i - \bar{x})^2 = 82.5$$

Hệ số góc:

$$\beta_1 = \frac{S_{xy}}{S_{xx}} = \frac{159.0}{82.5} \approx 1.927$$

Hệ số chặn:

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = 11.4 - 1.927(5.5) \approx 0.800$$

Đường OLS:

$$\hat{y} = 0.800 + 1.927x$$

Dự đoán tại $x = 12$:

$$\hat{y} = 0.800 + 1.927(12) \approx 23.927$$

Kết luận. Khi $x = 12$, mô hình dự đoán $y \approx \boxed{23.93}$.

Bài 3: Dùng residual để kiểm tra đường OLS

Đề bài. Với bộ dữ liệu ở Bài 2, sau khi fit OLS, hãy kiểm tra hai điều kiện:

$$\sum_{i=1}^n e_i = 0, \quad \sum_{i=1}^n x_i e_i = 0$$

Trong đó $e_i = y_i - \hat{y}_i$. Giải thích vì sao hai điều kiện này quan trọng.

Lời giải. Điều kiện thứ nhất nói residual không còn lệch trung bình lên hoặc xuống. Điều kiện thứ hai nói residual không còn tương quan tuyến tính với x . Nếu một trong hai điều kiện còn lớn, ta vẫn có thể chỉnh intercept hoặc slope để giảm RSS.

Từ $\hat{y} = 0.800 + 1.927x$, residual xấp xỉ:

x	1	2	3	4	5	6	7	8	9	10
$e = y - \hat{y}$	0.273	0.345	-0.582	-0.509	0.564	-0.364	-0.291	0.782	-0.145	-0.073

Tổng residual:

$$\sum e_i \approx 0.273 + 0.345 - 0.582 - 0.509 + 0.564 - 0.364 - 0.291 + 0.782 - 0.145 - 0.073 \approx 0$$

Tổng $x_i e_i$:

$$\sum x_i e_i \approx 0$$

RSS:

$$\sum e_i^2 \approx 1.964$$

Kết luận. Hai tổng gần 0 xác nhận nghiệm OLS đã dừng đúng tại điểm cực tiểu. Đây là cách kiểm tra nhanh khi đề bài yêu cầu chứng minh đường fit đã tối ưu.

Phần 2: Học máy: Hồi quy Tuyến tính từ Xác suất, MLE, và Ma trận

Nguồn: *quarto/LR_MLE_Matrix_Derivation.qmd*

1. Vì sao OLS có thể xuất hiện từ xác suất?

Trong mô hình hồi quy tuyến tính, ta không giả sử dữ liệu nằm hoàn hảo trên một đường hoặc một mặt phẳng. Ta giả sử mỗi nhãn thật được tạo bởi phần tín hiệu tuyến tính cộng với nhiễu:

$$y_i = \beta^T \mathbf{x}_i + \epsilon_i$$

Trong đó:

- $\mathbf{x}_i$ là vector đặc trưng của mẫu thứ i . Nếu mô hình có intercept, phần tử đầu tiên của $\mathbf{x}_i$ thường là 1.
- β là vector hệ số cần học.
- ϵ_i là phần nhiễu mà mô hình không giải thích được.

Giả định quan trọng nhất:

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Nghĩa là sai số có trung bình bằng 0, độc lập giữa các mẫu, và có cùng phương sai σ^2 . Khi đó:

$$y_i \mid \mathbf{x}_i; \beta \sim \mathcal{N}(\beta^T \mathbf{x}_i, \sigma^2)$$

Mật độ xác suất của một nhãn y_i là:

$$p(y_i \mid \mathbf{x}_i; \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

Trực giác: nếu mô hình dự đoán gần y_i , sai số nhỏ, mũ âm nhỏ, xác suất cao. Nếu mô hình dự đoán rất xa, sai số bình phương lớn, xác suất thấp.

2. Maximum Likelihood Estimation dẫn tới OLS

Vì các mẫu độc lập, xác suất quan sát toàn bộ dữ liệu là tích của xác suất từng mẫu:

$$L(\beta) = \prod_{i=1}^n p(y_i | \mathbf{x}_i; \beta)$$

Thay công thức Gaussian vào:

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

Tích nhiều số nhỏ dễ khó nhìn, nên ta lấy log. Vì log là hàm tăng đơn điệu, cực đại của L cũng là cực đại của $\ell = \log L$:

$$\ell(\beta) = \sum_{i=1}^n \left[\log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2} \right]$$

Gộp hằng số:

$$\ell(\beta) = n \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Khi tối ưu theo β :

- Hạng $n \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right)$ là hằng số.
- $\frac{1}{2\sigma^2}$ là hệ số dương.
- Tối đa hóa số âm của tổng bình phương sai số tương đương tối thiểu hóa tổng bình phương sai số.

Vì vậy:

$$\max_{\beta} \ell(\beta) \iff \min_{\beta} \frac{1}{2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Kết luận lớn: OLS không chỉ là một mẹo hình học. Nó là nghiệm MLE nếu nhiễu của hồi quy tuyến tính là Gaussian i.i.d.

3. Biểu diễn ma trận

Với n mẫu và p đặc trưng, gom dữ liệu thành:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} \in \mathbb{R}^{n \times p}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} \in \mathbb{R}^p$$

Vector dự đoán toàn bộ dữ liệu là:

$$\hat{\mathbf{y}} = \mathbf{X}\beta$$

Vector sai số:

$$\mathbf{r} = \mathbf{y} - \mathbf{X}\beta$$

Loss OLS dạng ma trận:

$$L(\beta) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 = \frac{1}{2} (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

Nếu bạn thấy biểu thức này trong đề thi, hãy đọc nó như sau: lấy từng residual, bình phương, cộng lại, rồi nhân $\frac{1}{2}$.

4. Suy luận Normal Equations

Khai triển loss:

$$\begin{aligned} L(\beta) &= \frac{1}{2} (\mathbf{y}^T - \beta^T \mathbf{X}^T) (\mathbf{y} - \mathbf{X}\beta) \\ &= \frac{1}{2} (\mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta) \end{aligned}$$

Hai hạng giữa là scalar và là chuyển vị của nhau, nên bằng nhau:

$$\mathbf{y}^T \mathbf{X}\beta = \beta^T \mathbf{X}^T \mathbf{y}$$

Do đó:

$$L(\beta) = \frac{1}{2}(\mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta)$$

Lấy gradient theo β :

$$\nabla_{\beta} L = -\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X} \beta$$

Tại điểm cực tiểu, gradient bằng vector 0:

$$-\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X} \beta = \mathbf{0}$$

Suy ra hệ phương trình chuẩn:

$$\boxed{\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}}$$

Nếu $\mathbf{X}^T \mathbf{X}$ khả nghịch:

$$\boxed{\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}}$$

Trong code, nên dùng `np.linalg.solve(X.T @ X, X.T @ y)` thay vì tự tính nghịch đảo, vì solve thường ổn định số học hơn.

5. Ý nghĩa hình học

Normal equations có thể viết lại:

$$\mathbf{X}^T (\mathbf{y} - \mathbf{X} \beta) = \mathbf{0}$$

Tức là:

- $\hat{\mathbf{y}} = \mathbf{X} \beta$ nằm trong không gian cột của $\mathbf{X}$.
- Residual $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$ vuông góc với từng cột của $\mathbf{X}$.
- OLS chọn hình chiếu vuông góc của $\mathbf{y}$ lên không gian mà mô hình có thể biểu diễn.


```

import numpy as np
import matplotlib.pyplot as plt

X = np.array([
    [1.0, 0.0],
    [1.0, 1.0],
    [1.0, 2.0],
    [1.0, 3.0],
])
y = np.array([1.0, 2.2, 1.9, 3.2])
beta = np.linalg.solve(X.T @ X, X.T @ y)
y_hat = X @ beta
residual = y - y_hat

print("beta:", np.round(beta, 3))
print("X.T @ residual:", np.round(X.T @ residual, 10))

plt.figure(figsize=(7, 4))
plt.scatter(X[:, 1], y, label="y quan sát", color="#4C78A8", s=70)
plt.plot(X[:, 1], y_hat, label="đường fit OLS", color="#F58518", linewidth=2)
for x_i, y_i, y_fit in zip(X[:, 1], y, y_hat):
    plt.plot([x_i, x_i], [y_fit, y_i], color="#AOAECO", linestyle="--")
plt.title("Normal equations như phép chiếu vuông góc")
plt.xlabel("đặc trưng x")
plt.ylabel("mục tiêu y")
plt.legend()
plt.grid(alpha=0.25)
plt.show()

```

```

beta: [1.13 0.63]
X.T @ residual: [-0. -0.]

```




Figure 2: OLS chiếu y lên không gian dự đoán; residual vuông góc với các cột của X.

6. Bảng Công thức Thi: Matrix OLS

Nhiệm vụ	Công thức	Cách dùng khi làm bài
Mô hình xác suất	$y_i \mathbf{x}_i \sim \mathcal{N}(\beta^T \mathbf{x}_i, \sigma^2)$	Nhận ra OLS từ giả định nhiễu Gaussian.
Likelihood	$L = \prod_i p(y_i \mathbf{x}_i; \beta)$	Mẫu độc lập nên xác suất nhân lại.
Log-likelihood	$\ell = \log L$	Biến tích thành tổng, dễ đạo hàm.
Loss ma trận	$L = \frac{1}{2} \ \mathbf{y} - \mathbf{X}\beta\ _2^2$	Dạng ngắn của RSS.
Gradient	$\nabla L = -\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X} \beta$	Đặt bằng 0 để tìm nghiệm đúng.
Normal equations	$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$	Hệ tuyến tính cần giải.
Nghiệm đóng	$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$	Dùng khi ma trận khả nghịch.

Nhiệm vụ	Công thức	Cách dùng khi làm bài
Pseudoinverse	$\beta = \mathbf{X}^+ \mathbf{y}$	Dùng khi $\mathbf{X}^T \mathbf{X}$ suy biến hoặc gần suy biến.

Quy trình thay số:

1. Thêm cột 1 nếu cần intercept.
2. Tính $\mathbf{G} = \mathbf{X}^T \mathbf{X}$.
3. Tính $\mathbf{h} = \mathbf{X}^T \mathbf{y}$.
4. Giải $\mathbf{G}\beta = \mathbf{h}$.
5. Dự đoán bằng $\hat{\mathbf{y}} = \mathbf{X}\beta$.
6. Kiểm tra $\mathbf{X}^T(\mathbf{y} - \hat{\mathbf{y}}) \approx \mathbf{0}$.

7. Bộ bài tập mẫu có lời giải

Bài 1: Giải OLS bằng ma trận với hai điểm

Đề bài. Fit đường thẳng có intercept qua hai điểm $(x, y) = (0, 1)$ và $(1, 3)$ bằng công thức ma trận.

Lời giải.

Thiết kế ma trận:

$$\mathbf{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

Tính:

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{X}^T \mathbf{y} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

Normal equations:

$$\begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

Từ phương trình thứ hai: $\beta_0 + \beta_1 = 3$. Từ phương trình thứ nhất: $2\beta_0 + \beta_1 = 4$. Trừ hai phương trình:

$$\beta_0 = 1, \quad \beta_1 = 2$$

Vậy:

$$\hat{y} = 1 + 2x$$

Bài 2: Bộ dữ liệu 10 dòng, giải đầy đủ bằng matrix OLS

Đề bài. Cho dữ liệu học tập sau. Mô hình có dạng $\hat{y} = \beta_0 + \beta_1 h + \beta_2 q$, trong đó h là số giờ học, q là số quiz đã làm. Hãy tính hệ số OLS và dự đoán điểm cho sinh viên học $h = 6$ giờ, làm $q = 5$ quiz.

dòng	h	q	y
1	1	1	52
2	2	1	57
3	2	2	60
4	3	2	65
5	4	3	71
6	5	3	76
7	5	4	79
8	6	4	84
9	7	5	90
10	8	5	95

Lời giải bằng công thức. Tạo:

$$\mathbf{X} = \begin{pmatrix} 1 & h_1 & q_1 \\ 1 & h_2 & q_2 \\ \vdots & \vdots & \vdots \\ 1 & h_{10} & q_{10} \end{pmatrix}, \quad \beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Từ bảng dữ liệu, ta có:

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 10 & 43 & 30 \\ 43 & 233 & 159 \\ 30 & 159 & 110 \end{pmatrix}$$

và

$$\mathbf{X}^T \mathbf{y} = \begin{pmatrix} 729 \\ 3434 \\ 2377 \end{pmatrix}$$

Do đó normal equations là:

$$\begin{pmatrix} 10 & 43 & 30 \\ 43 & 233 & 159 \\ 30 & 159 & 110 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} 729 \\ 3434 \\ 2377 \end{pmatrix}$$

Giải hệ tuyến tính này cho:

$$\beta \approx \begin{pmatrix} 45.323 \\ 4.613 \\ 2.581 \end{pmatrix}$$

Vậy mô hình là:

$$\hat{y} = 45.323 + 4.613h + 2.581q$$

Dự đoán cho $h = 6, q = 5$:

$$\hat{y} = 45.323 + 4.613(6) + 2.581(5)$$

$$\hat{y} = 45.323 + 27.678 + 12.905 = 85.906$$

Cách đọc kết quả. Hệ số $\beta_1 \approx 4.613$ cho biết khi giữ số quiz không đổi, học thêm một giờ làm điểm dự đoán tăng trung bình khoảng 4.613. Hệ số $\beta_2 \approx 2.581$ cho biết khi giữ số giờ học không đổi, làm thêm một quiz làm điểm dự đoán tăng trung bình khoảng 2.581.

Kết luận. Dự đoán điểm cho sinh viên học 6 giờ và làm 5 quiz là khoảng 85.91.

Phần 3: Học máy: Phân loại và Tối ưu Hồi quy Logistic

Nguồn: `quarto/Classification_Logistic_Regression.qmd`

1. Bản chất của Bài toán Phân loại (Classification)

Trong bài toán phân loại nhị phân (Binary Classification), tập dữ liệu huấn luyện bao gồm n mẫu có dạng $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$, trong đó nhãn mục tiêu bị giới hạn trong hai giá trị rời rạc:

$$y^{(i)} \in \{0, 1\}$$

- $y^{(i)} = 1$: Lớp dương tính (Positive class).
- $y^{(i)} = 0$: Lớp âm tính (Negative class).

Tại sao Tuyến tính (Linear Regression) thất bại với Phân loại?

Nếu cố chấp sử dụng mô hình tuyến tính $f_{\beta}(\mathbf{x}) = \beta^T \mathbf{x}$ cho tác vụ phân loại, đường ranh giới quyết định sẽ bị ảnh hưởng nghiêm trọng bởi các điểm dữ liệu dị biệt (Outliers). Khi xuất hiện một điểm dữ liệu nằm rất xa nhưng mang nhãn cực đoan, việc tối thiểu hóa bình phương khoảng cách (MSE) sẽ ép đường thẳng tuyến tính phải xoay một góc rất lớn để bù trừ sai số. Hệ quả là đường ranh giới bị dịch chuyển một cách vô lý, trực tiếp gây ra phân loại sai cho các điểm dữ liệu bình thường ở gần.

Do đó, ta cần một hàm kích hoạt có khả năng ép toàn bộ không gian số thực về khoảng xác suất $(0, 1)$, đó chính là **Hàm số Sigmoid**.

2. Mô hình Logistic Regression & Hàm Sigmoid

Logistic Regression mô hình hóa **xác suất có điều kiện** để một mẫu dữ liệu được phân loại vào lớp 1:

$$P(y^{(i)} = 1 \mid \mathbf{x}^{(i)}) = f_{\beta}(\mathbf{x}^{(i)}) = \sigma(\beta^T \mathbf{x}^{(i)})$$

Hàm số kích hoạt Sigmoid $\sigma(z)$ được định nghĩa toán học là:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \in (0, 1)$$

Biểu thức tính xác suất cho từng trường hợp nhãn cụ thể của mẫu dữ liệu: * $P(y^{(i)} = 1 | \mathbf{x}^{(i)}; \beta) = f_\beta(\mathbf{x}^{(i)})$ * $P(y^{(i)} = 0 | \mathbf{x}^{(i)}; \beta) = 1 - f_\beta(\mathbf{x}^{(i)})$

Công thức Xác suất Hợp nhất

Để thuận tiện cho việc thiết lập hàm toán học tối ưu, hai biểu thức trên được gộp lại thành một phương trình duy nhất dưới dạng tích lũy thừa nhờ tính chất nhị phân của nhãn $y^{(i)} \in \{0, 1\}$:

$$P(y^{(i)} | \mathbf{x}^{(i)}; \beta) = [f_\beta(\mathbf{x}^{(i)})]^{y^{(i)}} [1 - f_\beta(\mathbf{x}^{(i)})]^{1-y^{(i)}}$$

3. Chứng minh Hàm Mất mát Cross-Entropy bằng MLE

Với giả định các mẫu dữ liệu trong tập huấn luyện độc lập và phân phối cùng quy luật (i.i.d.), hàm lực lượng liên hợp xác suất (Likelihood Function) được thiết lập bằng tích xác suất của tất cả các mẫu:

$$L(\beta) = \prod_{i=1}^n P(y^{(i)} | \mathbf{x}^{(i)}; \beta) = \prod_{i=1}^n [f_\beta(\mathbf{x}^{(i)})]^{y^{(i)}} [1 - f_\beta(\mathbf{x}^{(i)})]^{1-y^{(i)}}$$

Theo nguyên lý ước lượng hợp lý cực đại (Maximum Likelihood Estimation - MLE), ta cần tìm bộ tham số β sao cho giá trị $L(\beta)$ đạt cực đại. Vì hàm logarit là hàm đồng biến đơn điệu, bài toán tương đương với việc tối đa hóa hàm Log-Likelihood:

$$\max_{\beta} L(\beta) \iff \max_{\beta} \log L(\beta) \iff \min_{\beta} -\log L(\beta)$$

Tiến hành lấy logarit tự nhiên và đổi dấu để chuyển sang bài toán tối thiểu hóa hàm mất mát:

$$J(\beta) = -\log L(\beta) = -\sum_{i=1}^n \log \left([f_\beta(\mathbf{x}^{(i)})]^{y^{(i)}} [1 - f_\beta(\mathbf{x}^{(i)})]^{1-y^{(i)}} \right)$$

Sử dụng tính chất của logarit để đưa số mũ xuống thành hệ số, ta thu được hàm mất mát **Binary Cross-Entropy Loss**:

$$J(\beta) = -\sum_{i=1}^n [y^{(i)} \log f_\beta(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - f_\beta(\mathbf{x}^{(i)}))]$$

4. Chứng minh Tính Lồi (Convex Optimization) bằng Ma trận Hessian

Để các thuật toán tối ưu hóa dựa trên đạo hàm hoạt động tin cậy và không bị kẹt ở các điểm cực tiểu cục bộ, hàm mất mát $J(\beta)$ phải là một hàm lồi. Điều này đồng nghĩa với việc ma trận đạo hàm bậc hai (Hessian Matrix) phải luôn bán xác định dương ($\nabla^2 J(\beta) \succeq 0$) với mọi giá trị của β .

Đạo hàm Bậc một (Gradient) via Chain Rule

Đặt biến trung gian tuyến tính $z^{(i)} = \beta^T \mathbf{x}^{(i)}$ và giá trị dự đoán $\hat{y}^{(i)} = \sigma(z^{(i)}) = f_\beta(\mathbf{x}^{(i)})$. Áp dụng quy tắc chuỗi (Chain Rule) để tính đạo hàm riêng cho từng mẫu dữ liệu:

$$\frac{\partial J^{(i)}(\beta)}{\partial \beta} = \frac{\partial J^{(i)}}{\partial \hat{y}^{(i)}} \cdot \frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} \cdot \frac{\partial z^{(i)}}{\partial \beta}$$

Tính toán chi tiết từng thành phần vi phân:

1. **Thành phần Loss:** $\frac{\partial J^{(i)}}{\partial \hat{y}^{(i)}} = \frac{-y^{(i)}}{\hat{y}^{(i)}} + \frac{1-y^{(i)}}{1-\hat{y}^{(i)}} = \frac{\hat{y}^{(i)}-y^{(i)}}{\hat{y}^{(i)}(1-\hat{y}^{(i)})}$
2. **Thành phần Sigmoid:** $\frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} = \sigma(z^{(i)})(1 - \sigma(z^{(i)})) = \hat{y}^{(i)}(1 - \hat{y}^{(i)})$
3. **Thành phần Tuyến tính:** $\frac{\partial z^{(i)}}{\partial \beta} = \mathbf{x}^{(i)}$

Nhân kết hợp cả ba thành phần lại với nhau để triệt tiêu đại lượng mẫu số:

$$\frac{\partial J^{(i)}(\beta)}{\partial \beta} = \left[\frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(1 - \hat{y}^{(i)})} \right] \cdot [\hat{y}^{(i)}(1 - \hat{y}^{(i)})] \cdot \mathbf{x}^{(i)} = (\hat{y}^{(i)} - y^{(i)})\mathbf{x}^{(i)}$$

Đạo hàm Bậc hai (Ma trận Hessian)

Tiếp tục lấy đạo hàm bậc hai bằng cách biệt hóa toán tử Gradient thu được theo vector tham số β^T :

$$H = \nabla^2 J(\beta) = \frac{\partial^2 J(\beta)}{\partial \beta \partial \beta^T} = \sum_{i=1}^n \frac{\partial}{\partial \beta} [(\hat{y}^{(i)} - y^{(i)})\mathbf{x}^{(i)}]$$

Vì nhãn dữ liệu thực tế $y^{(i)}$ là một hằng số cố định và ta đã biết $\frac{\partial \hat{y}^{(i)}}{\partial \beta} = \hat{y}^{(i)}(1 - \hat{y}^{(i)})\mathbf{x}^{(i)}$, biểu thức ma trận Hessian tổng thể rút gọn thành:

$$H = \sum_{i=1}^n \hat{y}^{(i)}(1 - \hat{y}^{(i)})\mathbf{x}^{(i)}(\mathbf{x}^{(i)})^T$$

Biện luận tính lồi: * Vì đầu ra hàm xác suất Sigmoid luôn nằm trong biên hạn hẹp $\hat{y}^{(i)} \in (0, 1)$, hệ số trọng số luôn dương: $\hat{y}^{(i)}(1 - \hat{y}^{(i)}) > 0$. * Bản chất phép nhân ngoài của một vector với chính nó dưới dạng $\mathbf{x}\mathbf{x}^T$ luôn tạo dựng nên một ma trận bán xác định dương.

Do tổng các ma trận bán xác định dương là một ma trận bán xác định dương, ta kết luận $H \succeq 0 \forall \beta$. Hàm mục tiêu của Logistic Regression **hoàn toàn là hàm lồi (Convex Function)**.

5. Các Phương pháp Tối ưu hóa Toán học

Thuật toán Gradient Descent (Tối ưu bậc 1)

Thực hiện cập nhật véc-tơ trọng số lặp bằng cách đi ngược hướng với vector độ dốc Gradient hệ số học α :

$$\beta^{(t+1)} = \beta^{(t)} - \alpha \nabla J(\beta^{(t)}) = \beta^{(t)} + \alpha \sum_{i=1}^n (y^{(i)} - f_{\beta}(\mathbf{x}^{(i)})) \mathbf{x}^{(i)}$$

Công thức cập nhật chi tiết cho từng thành phần chỉ số tham số β_j trong không gian đa chiều:

$$\beta_j^{(t+1)} = \beta_j^{(t)} + \alpha \sum_{i=1}^n (y^{(i)} - f_{\beta}(\mathbf{x}^{(i)})) x_j^{(i)}$$

Phương pháp Newton - Raphson (Tối ưu bậc 2)

Để tìm điểm cực trị của hàm lồi bằng cách giải hệ phương trình đạo hàm bằng không $\nabla J(\beta) = 0$, phương pháp Newton sử dụng khai triển Taylor bậc hai nhằm mượn thêm thông tin độ cong từ ma trận Hessian.

Công thức cập nhật đa biến sử dụng ma trận nghịch đảo Hessian tại mỗi bước lặp:

$$\beta^{(t+1)} = \beta^{(t)} - H^{-1} \nabla J(\beta^{(t)})$$

Dạng ma trận dùng trong bài thi Newton.

Với ma trận thiết kế $\mathbf{X} \in \mathbb{R}^{n \times p}$, vector xác suất $\mathbf{p} = \sigma(\mathbf{X}\beta)$, và vector nhãn $\mathbf{y}$:

$$\nabla J(\beta) = \mathbf{X}^T (\mathbf{p} - \mathbf{y})$$

Đặt ma trận đường chéo:

$$\mathbf{R} = \text{diag}(p_1(1-p_1), p_2(1-p_2), \dots, p_n(1-p_n))$$

thì Hessian là:

$$\nabla^2 J(\beta) = \mathbf{X}^T \mathbf{R} \mathbf{X}$$

và bước Newton có dạng:

$$\beta_{new} = \beta - (\mathbf{X}^T \mathbf{R} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{p} - \mathbf{y})$$

Để kiểm tra tính lồi, lấy bất kỳ vector $\mathbf{v}$:

$$\mathbf{v}^T \nabla^2 J \mathbf{v} = \mathbf{v}^T \mathbf{X}^T \mathbf{R} \mathbf{X} \mathbf{v} = (\mathbf{X} \mathbf{v})^T \mathbf{R} (\mathbf{X} \mathbf{v}) \geq 0$$

vì mọi phần tử đường chéo $p_i(1-p_i)$ đều không âm. Đây là lý do Logistic Regression với cross-entropy có nghiệm tối ưu toàn cục, còn Newton's Method có thể tận dụng độ cong để đi rất nhanh gần nghiệm.

So sánh đặc tính vận hành:

Thuật toán Tối ưu	Cơ chế Đạo hàm	Ưu điểm Vận hành	Nhược điểm Khuyết góc
Gradient Descent	Chỉ sử dụng bậc một (∇J)	Chi phí tính toán trên mỗi bước lặp rất thấp ($\mathcal{O}(p)$). Phù hợp với không gian dữ liệu lớn chứa hàng triệu thuộc tính p .	Tốc độ hội tụ chậm (Linear Convergence). Tốn nhiều thời gian thử nghiệm để tìm ra hệ số học α phù hợp.
Newton's Method	Kết hợp bậc một và ma trận bậc hai ($H^{-1} \nabla J$)	Tốc độ hội tụ cực kỳ nhanh nhờ đặc tính hội tụ bậc hai (Quadratic Convergence). Số vòng lặp yêu cầu rất ít và không cần tùy chỉnh hyperparameter hệ số học α .	Chi phí tính toán ma trận nghịch đảo Hessian rất lớn ($\mathcal{O}(p^3)$) tại mỗi bước lặp. Hoàn toàn bất khả thi nếu số lượng thuộc tính p lớn.

6. Kiểm tra Thực thi: Sigmoid và Ranh giới Quyết định

Các công thức phía trên sẽ dễ nhớ hơn nếu gắn với hai trục giác hình học: sigmoid biến một điểm số thực thành xác suất, và ngưỡng $P(y = 1 \mid \mathbf{x}) = 0.5$ tạo ra ranh giới quyết định tuyến tính.

```
import numpy as np
import matplotlib.pyplot as plt

def sigmoid(z):
    return 1 / (1 + np.exp(-z))

np.random.seed(7)
n = 120
X0 = np.random.normal(loc=[-1.2, -0.8], scale=[0.55, 0.55], size=(n // 2, 2))
X1 = np.random.normal(loc=[1.2, 1.0], scale=[0.65, 0.65], size=(n // 2, 2))
X = np.vstack([X0, X1])
y = np.hstack([np.zeros(n // 2), np.ones(n // 2)])
X_design = np.c_[np.ones(n), X]

beta = np.zeros(3)
lr = 0.4
for _ in range(800):
    probs = sigmoid(X_design @ beta)
    grad = X_design.T @ (y - probs) / n
    beta += lr * grad

pred = (sigmoid(X_design @ beta) >= 0.5).astype(int)
accuracy = (pred == y).mean()
print("Beta học được:", np.round(beta, 3))
print("Độ chính xác huấn luyện:", round(float(accuracy), 3))

z = np.linspace(-8, 8, 300)
xx, yy = np.meshgrid(np.linspace(-3, 3, 160), np.linspace(-3, 3, 160))
grid_design = np.c_[np.ones(xx.size), xx.ravel(), yy.ravel()]
surface = sigmoid(grid_design @ beta).reshape(xx.shape)

fig, ax = plt.subplots(1, 2, figsize=(9, 3.8))
ax[0].plot(z, sigmoid(z), color="#4C78A8")
ax[0].axhline(0.5, color="black", linestyle="--", linewidth=1)
```

```

ax[0].axvline(0.0, color="black", linestyle="--", linewidth=1)
ax[0].set_title("Sigmoid biến điểm số thành xác suất")
ax[0].set_xlabel("điểm tuyến tính z")
ax[0].set_ylabel(" $\sigma(z)$ ")
ax[0].grid(alpha=0.25)

contour = ax[1].contourf(xx, yy, surface, levels=20, cmap="RdBu_r",
    ↪ alpha=0.75)
ax[1].scatter(X0[:, 0], X0[:, 1], label="class 0", edgecolor="black",
    ↪ alpha=0.85)
ax[1].scatter(X1[:, 0], X1[:, 1], label="class 1", edgecolor="black",
    ↪ alpha=0.85)
ax[1].contour(xx, yy, surface, levels=[0.5], colors="black", linewidths=2)
ax[1].set_title("Ranh giới xác suất học được")
ax[1].set_xlabel(" $x_1$ ")
ax[1].set_ylabel(" $x_2$ ")
ax[1].legend()
fig.colorbar(contour, ax=ax[1], label=" $P(y=1 \mid x)$ ")
plt.tight_layout()
plt.show()

```

Beta học được: [-0.101 4.325 3.452]

Độ chính xác huấn luyện: 1.0




Figure 3: Logistic Regression ánh xạ điểm tuyến tính qua sigmoid và học ranh giới xác suất tuyến tính.

7. Bảng Công thức Thi: Quy trình Thay số cho Logistic Regression

Dùng phần này khi đề bài nhắc đến “phân loại nhị phân”, “xác suất thuộc lớp 1”, “log odds”, hoặc “cross-entropy”.

Nhiệm vụ	Công thức	Cách dùng
Điểm tuyến tính	$z^{(i)} = \beta^T \mathbf{x}^{(i)}$	Nén toàn bộ đặc trưng thành một số thực.
Xác suất	$\hat{y}^{(i)} = \sigma(z^{(i)}) = \frac{1}{1+e^{-z^{(i)}}}$	Biến điểm số bất kỳ thành xác suất trong $(0, 1)$.
Luật quyết định	$\hat{y}^{(i)} \geq 0.5 \Rightarrow \text{lớp 1}$	Tương đương $z^{(i)} \geq 0$ nếu ngưỡng là 0.5.
Loss một mẫu	$J^{(i)} = -y^{(i)} \log \hat{y}^{(i)} - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$	Phạt rất nặng khi mô hình tự tin nhưng sai.
Gradient	$\nabla J = \sum_i (\hat{y}^{(i)} - y^{(i)}) \mathbf{x}^{(i)}$	Sai số dự đoán nhân với vector đặc trưng.
Hessian	$H = \sum_i \hat{y}^{(i)} (1 - \hat{y}^{(i)}) \mathbf{x}^{(i)} (\mathbf{x}^{(i)})^T$	Bán xác định dương, nên hàm mục tiêu lồi.
Cập nhật Gradient Descent	$\beta \leftarrow \beta - \alpha \nabla J$	Đi ngược chiều gradient của cross-entropy.

Bẫy thường gặp khi thi.

- Logistic Regression là mô hình tuyến tính theo không gian đặc trưng, nhưng xác suất đầu ra phi tuyến vì có sigmoid.
- Không mặc định dùng MSE để suy luận Logistic Regression; cross-entropy xuất phát từ Bernoulli MLE.
- Dấu của $z = \beta^T \mathbf{x}$ quyết định lớp khi ngưỡng là 0.5.
- Độ lớn $|z|$ thể hiện mức tự tin: dương lớn nghĩa là gần lớp 1, âm lớn nghĩa là gần lớp 0.

```
import numpy as np

beta = np.array([-0.4, 1.2, -0.8])
X_demo = np.array([
    [1.0, 0.0, 0.0],
    [1.0, 2.0, 1.0],
    [1.0, -1.0, 2.0],
])
```

```

y_demo = np.array([0, 1, 0])
scores = X_demo @ beta
probs = 1 / (1 + np.exp(-scores))
losses = -y_demo * np.log(probs) - (1 - y_demo) * np.log(1 - probs)

print("Điểm z:", np.round(scores, 3))
print("Xác suất:", np.round(probs, 3))
print("Lớp dự đoán:", (probs >= 0.5).astype(int))
print("Cross-entropy từng mẫu:", np.round(losses, 3))
print("Loss trung bình:", round(float(losses.mean()), 3))

```

```

Điểm z: [-0.4  1.2 -3.2]
Xác suất: [0.401 0.769 0.039]
Lớp dự đoán: [0 1 0]
Cross-entropy từng mẫu: [0.513 0.263 0.04 ]
Loss trung bình: 0.272

```

Bộ bài tập mẫu có lời giải

Đề bài. Cho mô hình Logistic Regression có $\beta = (-0.4, 1.2, -0.8)$, trong đó phần tử đầu tiên là bias. Với mẫu $\mathbf{x} = (1, 2, 1)$ và nhãn thật $y = 1$, hãy tính xác suất dự đoán, lớp dự đoán, và loss cross-entropy.

Lời giải từng bước.

1. Tính điểm tuyến tính:

$$z = -0.4 + 1.2(2) - 0.8(1) = 1.2$$

2. Đưa qua sigmoid:

$$\hat{y} = \sigma(1.2) = \frac{1}{1 + e^{-1.2}} \approx 0.768$$

3. Vì $0.768 \geq 0.5$, mô hình dự đoán **lớp 1**.

4. Vì $y = 1$, loss là:

$$J = -\log(0.768) \approx 0.264$$

Kết luận. Mô hình dự đoán đúng lớp 1 với xác suất khoảng 76.8%, và loss thấp vì dự đoán khá tự tin.

Bài 2: Bảng 12 dòng, tính xác suất, loss, accuracy

Đề bài. Cho mô hình $\beta = (-1.0, 0.9, 0.7)$, trong đó phần tử đầu là bias. Với 12 mẫu sau, hãy tính z , xác suất, lớp dự đoán, cross-entropy trung bình, và accuracy.

dòng	x_1	x_2	y
1	0.0	0.0	0
2	0.5	0.2	0
3	1.0	0.4	0
4	1.0	1.0	1
5	1.5	0.8	1
6	2.0	0.5	1
7	-0.5	1.0	0
8	0.2	1.8	1
9	2.5	1.0	1
10	-1.0	0.5	0
11	1.2	-0.2	0
12	0.8	1.5	1

Lời giải. Mỗi dòng làm cùng một quy trình:

$$z = -1.0 + 0.9x_1 + 0.7x_2, \quad \hat{p} = \frac{1}{1 + e^{-z}}$$

Ví dụ dòng 4:

$$z = -1.0 + 0.9(1.0) + 0.7(1.0) = 0.60$$

$$\hat{p} = \sigma(0.60) = \frac{1}{1 + e^{-0.60}} \approx 0.646$$

Vì $\hat{p} \geq 0.5$, dự đoán lớp 1. Vì $y = 1$, loss dòng 4 là:

$$-\log(0.646) \approx 0.437$$

Làm tương tự cho 12 dòng:

dòng	z	$\hat{p}$	lớp dự đoán	loss
1	-1.000	0.269	0	0.313

dòng	z	$\hat{p}$	lớp dự đoán	loss
2	-0.410	0.399	0	0.509
3	0.180	0.545	1	0.787
4	0.600	0.646	1	0.437
5	0.910	0.713	1	0.338
6	1.150	0.760	1	0.275
7	-0.750	0.321	0	0.387
8	0.440	0.608	1	0.497
9	1.950	0.875	1	0.133
10	-1.550	0.175	0	0.192
11	-0.060	0.485	0	0.664
12	0.770	0.684	1	0.380

Tổng loss xấp xỉ:

$$0.313 + 0.509 + \dots + 0.380 = 4.914$$

Cross-entropy trung bình:

$$\bar{J} = \frac{4.914}{12} \approx 0.409$$

Mô hình sai duy nhất ở dòng 3, nên accuracy:

$$\text{Accuracy} = \frac{11}{12} \approx 0.917$$

Kết luận. Bài kiểu này không cần học lại mô hình. Chỉ cần thay số vào z , qua sigmoid, đặt ngưỡng 0.5, rồi tính loss từng dòng.

Bài 3: Một bước cập nhật gradient

Đề bài. Với cùng 12 dòng ở Bài 2, từ $\beta = (-1.0, 0.9, 0.7)$, hãy tính một bước gradient descent với learning rate $\alpha = 0.1$.

Lời giải. Gradient của cross-entropy là:

$$\nabla J = \frac{1}{n} \mathbf{X}^T (\hat{\mathbf{p}} - \mathbf{y})$$

Từ bảng ở Bài 2, lấy từng sai số xác suất $\hat{p}_i - y_i$, rồi nhân với từng cột của $\mathbf{X}$. Sau khi cộng và chia cho $n = 12$, ta được:

$$\nabla J \approx \begin{pmatrix} 0.0399 \\ -0.0765 \\ -0.1166 \end{pmatrix}$$

Cập nhật:

$$\beta_{new} = \beta - 0.1 \nabla J$$

$$\beta_{new} \approx \begin{pmatrix} -1.0 \\ 0.9 \\ 0.7 \end{pmatrix} - 0.1 \begin{pmatrix} 0.0399 \\ -0.0765 \\ -0.1166 \end{pmatrix} = \begin{pmatrix} -1.0040 \\ 0.9076 \\ 0.7117 \end{pmatrix}$$

Kết luận. Nếu $\hat{p} - y$ dương, mô hình đang dự đoán xác suất lớp 1 quá cao cho dòng đó; gradient sẽ đẩy hệ số theo hướng giảm xác suất đó.

Phần 4: Học máy: Họ Hàm Mũ và Mô hình Tuyến tính Tổng quát (GLM)

Nguồn: `quarto/Exponential_Family_GLMs.qmd`

1. Họ Phân Phối Số Mũ (Exponential Family Distribution - EFD)

Một phân phối xác suất đơn biến thuộc **Họ phân phối số mũ** nếu hàm mật độ xác suất (hoặc hàm khối xác suất) của nó có thể biến đổi về dạng chuẩn tắc sau:

$$P(y | \eta) = b(y) \exp(\eta^T T(y) - a(\eta))$$

Trong đó: * y : Biến ngẫu nhiên của dữ liệu quan sát. * η : Tham số tự nhiên (Natural parameter / Canonical parameter). * $T(y)$: Thống kê đủ (Sufficient statistic) — thông thường trong các bài toán cơ bản $T(y) = y$. * $b(y)$: Thuộc đo cơ sở (Base measure). * $a(\eta)$: Hàm chuẩn hóa log (Log-partition function), đóng vai trò như một hằng số chuẩn hóa để đảm bảo tổng tích phân xác suất bằng 1.

Các tính chất toán học cốt lõi (Properties)

Hàm log-partition $a(\eta)$ mang thông tin cực kỳ quan trọng về các mô-men của phân phối: 1. **Kỳ vọng (Mean)**: Đạo hàm bậc nhất của $a(\eta)$ chính là kỳ vọng của thống kê đủ:

$$\mathbb{E}[y | \eta] = \frac{\partial a(\eta)}{\partial \eta}$$

2. **Phương sai (Variance)**: Đạo hàm bậc hai của $a(\eta)$ chính là phương sai của thống kê đủ:

$$\text{Var}(y | \eta) = \frac{\partial^2 a(\eta)}{\partial \eta^2}$$

2. Chuẩn hóa các phân phối kinh điển về dạng EFD

2.1 Phân phối Bernoulli (Nền tảng của Logistic Regression)

Phân phối Bernoulli mô hình hóa biến ngẫu nhiên nhị phân $y \in \{0, 1\}$ với xác suất thành công $P(y = 1) = \phi$:

$$P(y \mid \phi) = \phi^y (1 - \phi)^{1-y}$$

Sử dụng phép biến đổi mũ và logarit ($\exp(\log(\cdot))$) để đưa về dạng chuẩn tắc:

$$P(y \mid \phi) = \exp(\log(\phi^y (1 - \phi)^{1-y}))$$

$$P(y \mid \phi) = \exp(y \log \phi + (1 - y) \log(1 - \phi))$$

$$P(y \mid \phi) = \exp(y \log \phi + \log(1 - \phi) - y \log(1 - \phi))$$

$$P(y \mid \phi) = \exp\left(y \log\left(\frac{\phi}{1 - \phi}\right) + \log(1 - \phi)\right)$$

Đối chiếu với phương trình tổng quát của Họ phân phối số mũ, ta rút ra các thành phần chuẩn tắc: * **Base measure:** $b(y) = 1$ * **Sufficient statistic:** $T(y) = y$ * **Tham số tự nhiên η :**

$$\eta = \log\left(\frac{\phi}{1 - \phi}\right)$$

Nếu ta giải phương trình này để tìm ϕ theo η :

$$e^\eta = \frac{\phi}{1 - \phi} \implies e^{-\eta} = \frac{1 - \phi}{\phi} = \frac{1}{\phi} - 1$$

$$\phi = \frac{1}{1 + e^{-\eta}} = \sigma(\eta)$$

(Đây là minh chứng tối thượng vì sao hàm số Sigmoid lại xuất hiện một cách tự nhiên trong mô hình Logistic Regression). * **Log-partition function $a(\eta)$:**

$$a(\eta) = -\log(1 - \phi) = -\log\left(1 - \frac{1}{1 + e^{-\eta}}\right) = \log(1 + e^\eta)$$

2.2 Phân phối Gaussian (Nền tảng của Linear Regression)

Xét phân phối chuẩn Gaussian với phương sai cố định $\sigma^2 = 1$ để đơn giản hóa biểu thức đại số:

$$P(y | \mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(y - \mu)^2\right)$$

Khai triển hằng đẳng thức đáng nhớ bên trong hàm mũ:

$$P(y | \mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(y^2 - 2y\mu + \mu^2)\right)$$

$$P(y | \mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}y^2\right) \exp\left(y\mu - \frac{1}{2}\mu^2\right)$$

Đối chiếu với cấu trúc dạng chuẩn tắc EFD, ta phân rã được các thành phần: * **Base measure:** $b(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}y^2\right)$ * **Sufficient statistic:** $T(y) = y$ * **Tham số tự nhiên η :** $\eta = \mu$ * **Log-partition function $a(\eta)$:** $a(\eta) = \frac{1}{2}\mu^2 = \frac{1}{2}\eta^2$

3. Bản chất Tính Lỗi của bài toán MLE thuộc họ EFD

Xét tập dữ liệu gồm n mẫu độc lập i.i.d. Hàm Log-Likelihood theo tham số tự nhiên η là:

$$\ell(\eta) = \sum_{i=1}^n \log P(y^{(i)} | \eta) = \sum_{i=1}^n [\log b(y^{(i)}) + \eta^T T(y^{(i)}) - a(\eta)]$$

Để tìm điểm tối ưu, ta lấy đạo hàm bậc một (Gradient) theo η :

$$\nabla_{\eta} \ell(\eta) = \sum_{i=1}^n \left[T(y^{(i)}) - \frac{\partial a(\eta)}{\partial \eta} \right] = \sum_{i=1}^n [T(y^{(i)}) - \mathbb{E}[y | \eta]]$$

Tiếp tục lấy đạo hàm bậc hai để thu được ma trận Hessian:

$$H = \nabla_{\eta}^2 \ell(\eta) = - \sum_{i=1}^n \frac{\partial^2 a(\eta)}{\partial \eta \partial \eta^T} = - \sum_{i=1}^n \text{Var}(y | \eta)$$

Vì giá trị phương sai luôn là một số không âm (và ma trận hiệp phương sai luôn bán xác định dương), ta có:

$$\text{Var}(y \mid \eta) \succeq 0 \implies H \preceq 0$$

Do ma trận Hessian của hàm Log-Likelihood luôn bán xác định âm, hàm số này **chắc chắn là hàm lõm (Concave)**. Hệ quả là, hàm số đối ngẫu **Negative Log-Likelihood sẽ luôn là hàm lồi (Convex)**. Điều này đảm bảo mọi bài toán tối ưu hóa MLE thuộc Họ phân phối số mũ đều có một điểm cực trị tối ưu toàn cục duy nhất.

4. Khung Mô Hình Tuyến Tính Tổng Quát (Generalized Linear Models - GLMs)

Mô hình tuyến tính tổng quát (GLMs) là phương pháp chuẩn hóa toán học cho phép chúng ta mở rộng ranh giới dự đoán tuyến tính sang các dạng phân phối nhãn nhị biệt khác nhau. Một mô hình được cấu thành từ 3 giả định nền tảng (Assumptions) sau:

1. **Phân phối mục tiêu:** Biến mục tiêu y cho trước điều kiện biến đầu vào $\mathbf{x}$ phải tuân theo một phân phối xác suất thuộc Họ phân phối số mũ (EFD) với tham số tự nhiên η :

$$y \mid \mathbf{x}; \beta \sim \text{Exponential Family}(\eta)$$

2. **Thành phần Tuyến tính:** Tham số tự nhiên η được giả định biến thiên tuyến tính theo các đặc trưng đầu vào thông qua tổ hợp trọng số β :

$$\eta = \beta^T \mathbf{x}$$

3. **Hàm liên kết (Link Function):** Kỳ vọng của mô hình $\mu = \mathbb{E}[y \mid \mathbf{x}]$ liên kết với thành phần tuyến tính thông qua một hàm số g được gọi là hàm liên kết:

$$\eta = g(\mu) = \beta^T \mathbf{x} \implies \mu = g^{-1}(\beta^T \mathbf{x})$$

Nếu ta chọn $\eta = g(\mu)$ sao cho hàm liên kết khớp trực tiếp với định nghĩa tham số tự nhiên, hàm đó được gọi là **Canonical Link Function**.

5. Bản đồ ánh xạ hệ thống GLM

Bảng dưới đây tổng hợp cách khung lý thuyết GLM kiến tạo nên các thuật toán Machine Learning quen thuộc từ các giả định phân phối khác nhau:

Phân phối toán học	Tham số tự nhiên η	Canonical Link Function $g(\mu)$	Hàm dự đoán Inverse Link $g^{-1}(\beta^T \mathbf{x})$	Thuật toán ML cấu thành
Gaussian ($\sigma^2 = 1$)	$\eta = \mu$	Identity link: $\eta = \mu$	$\hat{y} = \beta^T \mathbf{x}$	Linear Regression
Bernoulli	$\eta = \log\left(\frac{\phi}{1-\phi}\right)$	Logit link: $\eta = \log\left(\frac{\mu}{1-\mu}\right)$	$\hat{y} = \frac{1}{1+e^{-\beta^T \mathbf{x}}} = \sigma(\beta^T \mathbf{x})$	Logistic Regression

6. Giai đoạn Dự đoán và Thuật toán Tối ưu hóa Tổng quát

Giai đoạn Dự đoán (Testing Phase)

Tại giai đoạn kiểm thử với một mẫu dữ liệu mới $\mathbf{x}$, mục tiêu của chúng ta là đưa ra kỳ vọng có điều kiện của nhãn y :

$$f_{\beta}(\mathbf{x}) = \mathbb{E}[y | \mathbf{x}; \beta] = \left. \frac{\partial a(\eta)}{\partial \eta} \right|_{\eta=\beta^T \mathbf{x}} = g^{-1}(\beta^T \mathbf{x})$$

Thuật toán Cập nhật Trọng số Tổng quát (Gradient Descent)

Một điều kỳ diệu mang tính hệ thống của GLM đó là: Nếu chúng ta sử dụng *Canonical Link Function*, thì đạo hàm của hàm mất mát Negative Log-Likelihood với mọi phân phối thuộc họ EFD đều cho ra cùng một dạng toán học duy nhất!

Công thức cập nhật vector trọng số tổng quát qua Gradient Descent là:

$$\beta^{(t+1)} = \beta^{(t)} + \alpha \sum_{i=1}^n (y^{(i)} - f_{\beta}(\mathbf{x}^{(i)})) \mathbf{x}^{(i)}$$

Viết chi tiết cho từng thành phần chỉ số thuộc tính β_j :

$$\beta_j^{(t+1)} = \beta_j^{(t)} + \alpha \sum_{i=1}^n (y^{(i)} - g^{-1}(\beta^T \mathbf{x}^{(i)})) x_j^{(i)}$$

Nhận xét tối thượng: Cho dù bạn đang làm Linear Regression với phân phối chuẩn, Logistic Regression với phân phối nhị phân, hay thậm chí Poisson Regression với dữ liệu đếm, quy tắc cập nhật trọng số luôn luôn không đổi. Toàn bộ sự khác biệt về mặt bản chất mô hình đã được gói gọn hoàn hảo bên trong hàm ngược liên kết g^{-1} .

7. Thực hành Minh họa bằng Code Python

Dưới đây là đoạn mã Python giúp bạn mô phỏng lại cách một mô hình GLM (như Logistic Regression) tự động kích hoạt hàm liên kết dựa trên phân phối Bernoulli để tối ưu hóa bộ trọng số:

```
import numpy as np
import matplotlib.pyplot as plt

class GLMBernoulliLogistic:
    def __init__(self, learning_rate=0.1, iters=1000):
        self.lr = learning_rate
        self.iters = iters
        self.weights = None

    def _inverse_link_function(self, z):
        # Hàm ngược liên kết ( $g^{-1}$ ) cho phân phối Bernoulli chính là hàm
        # ↪ Sigmoid
        return 1 / (1 + np.exp(-z))

    def fit(self, X, y):
        n_samples, n_features = X.shape
        self.weights = np.zeros(n_features)

        # Vòng lặp tối ưu hóa Gradient Descent tổng quát của hệ thống GLM
        for _ in range(self.iters):
            # 1. Thành phần tuyến tính:  $\eta = \beta^T \cdot x$ 
            eta = np.dot(X, self.weights)

            # 2. Kỳ vọng mô hình qua hàm ngược liên kết:  $\mu = g^{-1}(\eta)$ 
            y_pred = self._inverse_link_function(eta)

            # 3. Cập nhật trọng số theo quy tắc tổng quát của GLM
            gradient = np.dot(X.T, (y - y_pred)) / n_samples
```

```

        self.weights += self.lr * gradient

    def predict_prob(self, X):
        eta = np.dot(X, self.weights)
        return self._inverse_link_function(eta)

# Giả lập dữ liệu nhị phân để chạy thử nghiệm mô hình
np.random.seed(42)
X_dummy = np.random.randn(100, 2)
# Tạo nhãn tuyến tính giả lập bị ép qua sigmoid
true_eta = 1.5 * X_dummy[:, 0] - 2.0 * X_dummy[:, 1]
y_dummy = (1 / (1 + np.exp(-true_eta)) > 0.5).astype(int)

# Khởi tạo và huấn luyện mô hình GLM chuẩn tắc
model = GLMBernoulliLogistic(learning_rate=0.5, iters=500)
model.fit(X_dummy, y_dummy)
print("Bộ trọng số tối ưu tìm được qua GLM:", model.weights)

xx, yy = np.meshgrid(np.linspace(-3, 3, 160), np.linspace(-3, 3, 160))
grid = np.c_[xx.ravel(), yy.ravel()]
probs = model.predict_prob(grid).reshape(xx.shape)

plt.figure(figsize=(7, 5))
contour = plt.contourf(xx, yy, probs, levels=20, cmap="RdBu_r", alpha=0.75)
plt.colorbar(contour, label="$P(y=1 \mid x)$")
plt.scatter(X_dummy[y_dummy == 0, 0], X_dummy[y_dummy == 0, 1], label="class
↪ 0", edgecolor="black", alpha=0.85)
plt.scatter(X_dummy[y_dummy == 1, 0], X_dummy[y_dummy == 1, 1], label="class
↪ 1", edgecolor="black", alpha=0.85)
plt.contour(xx, yy, probs, levels=[0.5], colors="black", linewidths=2)
plt.title("Bernoulli GLM probability surface")
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.legend()
plt.grid(alpha=0.2)
plt.show()

```

Bộ trọng số tối ưu tìm được qua GLM: [4.74278036 -5.98881054]




Figure 4: A Bernoulli GLM learns a logistic probability surface through the inverse link function.

8. Bảng Công thức Thi: Chọn GLM và Thay số

Bắt đầu mọi bài GLM bằng cách xác định kiểu của biến mục tiêu.

Kiểu biến mục tiêu	Phân phối	Tham số tự nhiên / Link	Inverse Link / Dự đoán
Giá trị thực $y \in \mathbb{R}$	Gaussian	$\eta = \mu = \beta^T \mathbf{x}$	$\hat{y} = \beta^T \mathbf{x}$
Nhị phân $y \in \{0, 1\}$	Bernoulli	$\eta = \log \frac{\phi}{1-\phi}$	$\phi = \sigma(\beta^T \mathbf{x})$
Dữ liệu đếm $y \in \{0, 1, 2, \dots\}$	Poisson	$\eta = \log \lambda$	$\lambda = e^{\beta^T \mathbf{x}}$

Mẫu giải GLM tổng quát với canonical link.

1. Tính điểm tuyến tính: $\eta^{(i)} = \beta^T \mathbf{x}^{(i)}$.
2. Đổi điểm tuyến tính thành kỳ vọng: $\mu^{(i)} = g^{-1}(\eta^{(i)})$.
3. Tính sai số: $y^{(i)} - \mu^{(i)}$.
4. Cập nhật trọng số:

$$\beta \leftarrow \beta + \alpha \sum_i (y^{(i)} - \mu^{(i)}) \mathbf{x}^{(i)}$$

Mẹo nhớ: phân phối quyết định inverse link; inverse link quyết định cách dự đoán.

```
import numpy as np

eta = np.array([-2.0, 0.0, 2.0])
gaussian_mu = eta
bernoulli_mu = 1 / (1 + np.exp(-eta))
poisson_mu = np.exp(eta)

print("eta:", eta)
print("Inverse link Gaussian:", np.round(gaussian_mu, 3))
print("Inverse link Bernoulli:", np.round(bernoulli_mu, 3))
print("Inverse link Poisson:", np.round(poisson_mu, 3))
```

```
eta: [-2.  0.  2.]
Inverse link Gaussian: [-2.  0.  2.]
Inverse link Bernoulli: [0.119 0.5  0.881]
Inverse link Poisson: [0.135 1.  7.389]
```

Bộ bài tập mẫu có lời giải

Đề bài. Cho $\beta = (0.5, 1.0, -0.25)$ và $\mathbf{x} = (1, 2, 4)$, trong đó phần tử đầu là bias. Tính dự đoán nếu ta dùng Gaussian GLM, Bernoulli GLM và Poisson GLM.

Lời giải từng bước.

1. Tính điểm tuyến tính:

$$\eta = \beta^T \mathbf{x} = 0.5 + 1.0(2) - 0.25(4) = 1.5$$

2. Nếu là Gaussian:

$$\hat{y} = \eta = 1.5$$

3. Nếu là Bernoulli:

$$P(y = 1 \mid \mathbf{x}) = \sigma(1.5) = \frac{1}{1 + e^{-1.5}} \approx 0.818$$

4. Nếu là Poisson:

$$\lambda = e^{1.5} \approx 4.482$$

Kết luận. Cùng một điểm tuyến tính $\eta = 1.5$, nhưng mỗi GLM biến nó thành dự đoán khác nhau tùy theo phân phối mục tiêu.

Bài 2: Bảng 10 dòng, chọn inverse link phù hợp

Đề bài. Cho 10 giá trị η từ mô hình tuyến tính. Hãy tính dự đoán cho ba trường hợp: Gaussian, Bernoulli, và Poisson. Sau đó giải thích khi nào dùng từng loại.

dòng	η
1	-2.0
2	-1.2
3	-0.5
4	0.0
5	0.3
6	0.8
7	1.1
8	1.6
9	2.0
10	2.5

Lời giải. Ba inverse link cần dùng:

$$\mu_{\text{Gaussian}} = \eta, \quad \mu_{\text{Bernoulli}} = \sigma(\eta) = \frac{1}{1 + e^{-\eta}}, \quad \mu_{\text{Poisson}} = e^{\eta}$$

Ví dụ với $\eta = 0.8$:

$$\mu_{\text{Gaussian}} = 0.8$$

$$\mu_{\text{Bernoulli}} = \frac{1}{1 + e^{-0.8}} \approx 0.690$$

$$\mu_{\text{Poisson}} = e^{0.8} \approx 2.226$$

Làm tương tự cho toàn bộ bảng:

dòng	η	Gaussian μ	Bernoulli $P(y = 1)$	Poisson rate
1	-2.0	-2.0	0.119	0.135
2	-1.2	-1.2	0.231	0.301
3	-0.5	-0.5	0.378	0.607
4	0.0	0.0	0.500	1.000
5	0.3	0.3	0.574	1.350
6	0.8	0.8	0.690	2.226
7	1.1	1.1	0.750	3.004
8	1.6	1.6	0.832	4.953
9	2.0	2.0	0.881	7.389
10	2.5	2.5	0.924	12.182

Kết luận.

- Gaussian dùng khi y là số thực liên tục.
- Bernoulli dùng khi $y \in \{0, 1\}$.
- Poisson dùng khi y là số đếm không âm.

Bài 3: Tính log-likelihood Bernoulli từ 10 quan sát

Đề bài. Với xác suất dự đoán của Bernoulli GLM ở Bài 2 và nhãn thật dưới đây, hãy tính log-likelihood trung bình.

dòng	1	2	3	4	5	6	7	8	9	10
y	0	0	0	0	1	1	1	1	1	1

Lời giải. Bernoulli log-likelihood từng dòng:

$$\ell_i = y_i \log(p_i) + (1 - y_i) \log(1 - p_i)$$

Với $y = 0$, log-likelihood là $\log(1 - p)$. Với $y = 1$, log-likelihood là $\log(p)$.

dòng	p	y	log-likelihood
1	0.119	0	$\log(0.881) = -0.127$
2	0.231	0	$\log(0.769) = -0.263$
3	0.378	0	$\log(0.622) = -0.474$
4	0.500	0	$\log(0.500) = -0.693$

dòng	p	y	log-likelihood
5	0.574	1	$\log(0.574) = -0.554$
6	0.690	1	$\log(0.690) = -0.371$
7	0.750	1	$\log(0.750) = -0.287$
8	0.832	1	$\log(0.832) = -0.184$
9	0.881	1	$\log(0.881) = -0.127$
10	0.924	1	$\log(0.924) = -0.079$

Tổng log-likelihood:

$$-0.127 - 0.263 - 0.474 - 0.693 - 0.554 - 0.371 - 0.287 - 0.184 - 0.127 - 0.079 = -3.160$$

Log-likelihood trung bình:

$$\bar{\ell} = \frac{-3.160}{10} = -0.316$$

Negative log-likelihood trung bình:

$$-\bar{\ell} = 0.316$$

Kết luận. Logistic Regression chính là Bernoulli GLM với logit link. Khi tối ưu cross-entropy, ta đang tối thiểu hóa negative log-likelihood.

Phần 5: Học máy: Thuật toán Học Tạo sinh

Nguồn: *quarto/GLA.qmd*

1. Triết lý Mô hình Phân biệt (Discriminative) vs. Mô hình Sinh (Generative)

Khi giải quyết một bài toán phân loại, hai hướng tiếp cận cốt lõi bao gồm:

- **Mô hình Phân biệt (Discriminative Models):** Học trực tiếp xác suất điều kiện $P(y | \mathbf{x})$ từ dữ liệu (ví dụ: Logistic Regression). Mô hình này cố gắng tìm ra một đường ranh giới tối ưu để phân tách các lớp dữ liệu mà không cần quan tâm đến việc dữ liệu đó được sinh ra như thế nào.
- **Mô hình Sinh (Generative Models):** Thay vì học trực tiếp ranh giới, mô hình sinh đi tìm hiểu cách từng lớp dữ liệu được tạo ra một cách độc lập bằng cách mô hình hóa xác suất đồng thời (Joint Probability):

$$P(\mathbf{x}, y) = P(\mathbf{x} | y)P(y)$$

Sau khi đã học được phân phối $P(\mathbf{x} | y)$ cho từng lớp và xác suất tiên nghiệm (Prior) $P(y)$, mô hình áp dụng **Định lý Bayes** để tính xác suất hậu nghiệm (Posterior) tại giai đoạn dự đoán:

$$P(y = 1 | \mathbf{x}) = \frac{P(\mathbf{x} | y = 1)P(y = 1)}{P(\mathbf{x})}$$

Trong đó, mẫu số được khai triển bằng công thức xác suất đầy đủ:

$$P(\mathbf{x}) = P(\mathbf{x} | y = 1)P(y = 1) + P(\mathbf{x} | y = 0)P(y = 0)$$

Tùy thuộc vào bản chất của các thuộc tính đầu vào $\mathbf{x}$, ta có hai thuật toán sinh kinh điển: 1. **Thuộc tính liên tục ($\mathbf{x} \in \mathbb{R}^p$):** Gaussian Discriminant Analysis (GDA). 2. **Thuộc tính rời rạc:** Naive Bayes.

2. Phân tích Phân biệt Gaussian (Gaussian Discriminant Analysis - GDA)

GDA giả định rằng dữ liệu đầu vào ứng với mỗi nhãn cụ thể tuân theo một **Phân phối Chuẩn Đa Biến (Multivariate Gaussian Distribution)**.

2.1 Nhắc lại kiến thức: Phân phối Chuẩn Đa Biến

Một vector ngẫu nhiên $\mathbf{x} \in \mathbb{R}^p$ tuân theo phân phối chuẩn đa biến với vector kỳ vọng $\mu \in \mathbb{R}^p$ và ma trận hiệp phương sai $\Sigma \in \mathbb{R}^{p \times p}$ (ký hiệu $\mathbf{x} \sim \mathcal{N}(\mu, \Sigma)$) có hàm mật độ xác suất là:

$$P(\mathbf{x}; \mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right)$$

Trong đó $|\Sigma|$ là định thức của ma trận Σ .

2.2 Các giả định nền tảng của GDA

Xét bài toán phân loại nhị phân ($y \in \{0, 1\}$). GDA áp đặt các giả định phân phối sau: * Nhân mục tiêu y tuân theo phân phối Bernoulli với tham số ϕ :

$$y \sim \text{Bernoulli}(\phi) \implies P(y) = \phi^y (1 - \phi)^{1-y}$$

* Dữ liệu đầu vào điều kiện theo lớp $y = 0$ tuân theo phân phối chuẩn:

$$\mathbf{x} \mid y = 0 \sim \mathcal{N}(\mu_0, \Sigma)$$

* Dữ liệu đầu vào điều kiện theo lớp $y = 1$ tuân theo phân phối chuẩn:

$$\mathbf{x} \mid y = 1 \sim \mathcal{N}(\mu_1, \Sigma)$$

Lưu ý quan trọng: GDA giả định các lớp có vector kỳ vọng riêng biệt ($\mu_0 \neq \mu_1$) nhưng **chia sẻ chung một ma trận hiệp phương sai** Σ . Điều này giúp ranh giới quyết định toán học sau này là một đường thẳng (tuyến tính).

3. Ước lượng Tham số GDA bằng Maximum Likelihood Estimation (MLE)

Để tìm các tham số $\{\phi, \mu_0, \mu_1, \Sigma\}$, ta thiết lập hàm Log-Likelihood đồng thời trên toàn bộ n mẫu dữ liệu huấn luyện:

$$\ell(\phi, \mu_0, \mu_1, \Sigma) = \sum_{i=1}^n \log P(\mathbf{x}^{(i)}, y^{(i)}) = \sum_{i=1}^n [\log P(\mathbf{x}^{(i)} \mid y^{(i)}) + \log P(y^{(i)})]$$

Khai triển chi tiết hàm mục tiêu tối ưu hóa:

$$\ell = \sum_{i=1}^n \left[\log \left(\frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \right) - \frac{1}{2} (\mathbf{x}^{(i)} - \mu_{y^{(i)}})^T \Sigma^{-1} (\mathbf{x}^{(i)} - \mu_{y^{(i)}}) + y^{(i)} \log \phi + (1 - y^{(i)}) \log(1 - \phi) \right]$$

3.1 Ước lượng Tham số Tiềm nghiệm ϕ

Lấy đạo hàm riêng của ℓ theo biến vô hướng ϕ và đặt bằng 0:

$$\frac{\partial \ell}{\partial \phi} = \sum_{i=1}^n \left[\frac{y^{(i)}}{\phi} - \frac{1 - y^{(i)}}{1 - \phi} \right] = 0$$

$$\sum_{i=1}^n \frac{y^{(i)} - \phi}{\phi(1 - \phi)} = 0 \implies \sum_{i=1}^n y^{(i)} - n\phi = 0 \implies \phi = \frac{1}{n} \sum_{i=1}^n y^{(i)}$$

3.2 Ước lượng các Vector Kỳ vọng μ_0 và μ_1

Để tìm μ_0 , ta chỉ quan tâm đến các số hạng chứa μ_0 (các mẫu có $y^{(i)} = 0$). Áp dụng quy tắc đạo hàm ma trận $\frac{\partial}{\partial \mathbf{z}}(\mathbf{a} - \mathbf{z})^T \mathbf{A}(\mathbf{a} - \mathbf{z}) = -2\mathbf{A}(\mathbf{a} - \mathbf{z})$:

$$\nabla_{\mu_0} \ell = \sum_{i: y^{(i)}=0} \Sigma^{-1}(\mathbf{x}^{(i)} - \mu_0) = \mathbf{0}$$

$$\Sigma^{-1} \sum_{i: y^{(i)}=0} (\mathbf{x}^{(i)} - \mu_0) = \mathbf{0} \implies \mu_0 = \frac{\sum_{i=1}^n (1 - y^{(i)}) \mathbf{x}^{(i)}}{\sum_{i=1}^n (1 - y^{(i)})}$$

Tương tự cho lớp 1, ta có công thức nghiệm đóng:

$$\mu_1 = \frac{\sum_{i=1}^n y^{(i)} \mathbf{x}^{(i)}}{\sum_{i=1}^n y^{(i)}}$$

3.3 Ước lượng Ma trận Hiệp phương sai Chung Σ

Bằng phép toán tối ưu hóa ma trận nâng cao, ta thu được ma trận hiệp phương sai thực nghiệm mẫu:

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}^{(i)} - \mu_{y^{(i)}})(\mathbf{x}^{(i)} - \mu_{y^{(i)}})^T$$

4. Chứng minh GDA tương đương toán học với Hàm Sigmoid

Một điểm bộc phá lý thuyết đỉnh cao là: Nếu dữ liệu thỏa mãn các giả định của GDA, thì xác suất hậu nghiệm $P(y = 1 \mid \mathbf{x})$ được suy diễn ra sẽ có dạng chính xác là một **Hàm số Sigmoid**.

Biến đổi Đại số chi tiết

Áp dụng Định lý Bayes:

$$P(y = 1 \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid y = 1)P(y = 1)}{P(\mathbf{x} \mid y = 1)P(y = 1) + P(\mathbf{x} \mid y = 0)P(y = 0)} = \frac{1}{1 + \frac{P(\mathbf{x} \mid y = 0)P(y = 0)}{P(\mathbf{x} \mid y = 1)P(y = 1)}}$$

Ta viết lại biểu thức dưới dạng hàm mũ:

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + \exp\left(-\log\left(\frac{P(\mathbf{x} \mid y = 1)P(y = 1)}{P(\mathbf{x} \mid y = 0)P(y = 0)}\right)\right)}$$

Đặt giá trị bên trong hàm mũ là số hạng z :

$$z = \log\left(\frac{P(\mathbf{x} \mid y = 1)}{P(\mathbf{x} \mid y = 0)}\right) + \log\left(\frac{P(y = 1)}{P(y = 0)}\right)$$

Thay hàm mật độ xác suất chuẩn đa biến vào thành phần thứ nhất của z :

$$\log\left(\frac{P(\mathbf{x} \mid y = 1)}{P(\mathbf{x} \mid y = 0)}\right) = \log\left(\frac{\frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu_1)^T \Sigma^{-1}(\mathbf{x} - \mu_1)\right)}{\frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu_0)^T \Sigma^{-1}(\mathbf{x} - \mu_0)\right)}\right)$$

Triệt tiêu hằng số chuẩn hóa mặt trước và lấy logarit tự nhiên để triệt tiêu hàm số exp:

$$= -\frac{1}{2}(\mathbf{x} - \mu_1)^T \Sigma^{-1}(\mathbf{x} - \mu_1) + \frac{1}{2}(\mathbf{x} - \mu_0)^T \Sigma^{-1}(\mathbf{x} - \mu_0)$$

Khai triển các đa thức ma trận (lưu ý rằng $\mathbf{x}^T \Sigma^{-1} \mu_1 = \mu_1^T \Sigma^{-1} \mathbf{x}$ vì đây là đại lượng vô hướng):

$$= -\frac{1}{2} [\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\mu_1^T \Sigma^{-1} \mathbf{x} + \mu_1^T \Sigma^{-1} \mu_1] + \frac{1}{2} [\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\mu_0^T \Sigma^{-1} \mathbf{x} + \mu_0^T \Sigma^{-1} \mu_0]$$

Ta thấy số hạng bậc hai $\mathbf{x}^T \Sigma^{-1} \mathbf{x}$ bị triệt tiêu hoàn toàn (nhờ giả định chung ma trận Σ). Gom các số hạng còn lại theo biến $\mathbf{x}$:

$$= (\mu_1^T \Sigma^{-1} - \mu_0^T \Sigma^{-1}) \mathbf{x} - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_0^T \Sigma^{-1} \mu_0$$

Kết hợp với thành phần tiên nghiệm $\log\left(\frac{\phi}{1-\phi}\right)$, toàn bộ biểu thức z có cấu trúc tuyến tính hoàn hảo:

$$z = \theta^T \mathbf{x} + \theta_0$$

Trong đó: $\theta = \Sigma^{-1}(\mu_1 - \mu_0)$ $\theta_0 = -\frac{1}{2}\mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2}\mu_0^T \Sigma^{-1} \mu_0 + \log \frac{\phi}{1-\phi}$

Hệ quả là:

$$P(y = 1 | \mathbf{x}) = \frac{1}{1 + e^{-(\theta^T \mathbf{x} + \theta_0)}} = \sigma(\theta^T \mathbf{x} + \theta_0)$$

5. Thuật toán Phân loại Naive Bayes (Dữ liệu rời rạc)

Khi các đặc trưng đầu vào $\mathbf{x}$ là các biến rời rạc định danh (ví dụ: bài toán lọc thư rác từ các từ vựng xuất hiện), giả định phân phối liên tục Gauss không còn phù hợp. Ta chuyển sang sử dụng **Naive Bayes**.

5.1 Giả định Độc lập Điều kiện Naive Bayes

Nếu không có giả định đơn giản hóa, để mô hình hóa một vector thuộc tính nhị phân $\mathbf{x} \in \{0, 1\}^p$, ta cần một bảng xác suất khổng lồ chứa $2^p - 1$ tham số, điều này gây bùng nổ dữ liệu toán học.

Giả định “Ngây thơ” (Naive) đặt ra là: **Các đặc trưng đầu vào x_j độc lập với nhau khi biết trước nhãn lớp y .**

$$P(x_1, x_2, \dots, x_p | y) = \prod_{j=1}^p P(x_j | y)$$

5.2 Thiết lập các Tham số và MLE

Xét bài toán phân loại văn bản (Text Classification) với từ điển kích thước p . Đặt: $\phi_{j|y=1} = P(x_j = 1 | y = 1)$ $\phi_{j|y=0} = P(x_j = 1 | y = 0)$ $\phi_y = P(y = 1)$

Hàm Log-Likelihood đồng thời trên toàn bộ tập dữ liệu huấn luyện:

$$\ell(\phi_y, \phi_{j|y=1}, \phi_{j|y=0}) = \sum_{i=1}^n \log \left(\prod_{j=1}^p P(x_j^{(i)} | y^{(i)}) \cdot P(y^{(i)}) \right)$$

Tối ưu hóa hàm mục tiêu bằng phương pháp MLE, ta thu được các tỷ lệ đếm thực nghiệm trực quan:

$$\phi_{j|y=1} = \frac{\sum_{i=1}^n \mathbb{I}(x_j^{(i)} = 1 \wedge y^{(i)} = 1)}{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 1)}$$

$$\phi_{j|y=0} = \frac{\sum_{i=1}^n \mathbb{I}(x_j^{(i)} = 1 \wedge y^{(i)} = 0)}{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 0)}$$

$$\phi_y = \frac{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 1)}{n}$$

5.3 Kỹ thuật mịn hóa Laplace (Laplace Smoothing)

Nếu một từ vựng mới chưa từng xuất hiện trong lớp 1 ở tập huấn luyện, giá trị đếm bằng 0 dẫn đến $\phi_{j|y=1} = 0$. Khi gặp văn bản mới chứa từ này, phép nhân tích chuỗi sẽ triệt tiêu toàn bộ xác suất hậu nghiệm xuống bằng 0 một cách sai lầm ($P(y = 1 | \mathbf{x}) = 0$).

Để khắc phục, kỹ thuật **Laplace Smoothing** cộng thêm 1 vào tử số và cộng thêm kích thước miền giá trị vào mẫu số:

$$\phi_{j|y=1} = \frac{\sum_{i=1}^n \mathbb{I}(x_j^{(i)} = 1 \wedge y^{(i)} = 1) + 1}{\sum_{i=1}^n \mathbb{I}(y^{(i)} = 1) + 2}$$

6. Thực hành Triển khai GDA bằng Python từ đầu (Scratch)

Đoạn mã Python dưới đây hiện thực hóa toàn bộ các bước tính toán MLE của thuật toán GDA và dự đoán xác suất hậu nghiệm:

```
import numpy as np
import matplotlib.pyplot as plt

class GaussianDiscriminantAnalysis:
    def __init__(self):
        self.phi = None
        self.mu0 = None
        self.mu1 = None
        self.sigma = None

    def fit(self, X, y):
```

```

n_samples, n_features = X.shape

# 1. Ước lượng tham số Bernoulli phi
self.phi = np.mean(y)

# 2. Phân tách các mẫu dữ liệu theo từng lớp
X0 = X[y == 0]
X1 = X[y == 1]

# 3. Tính toán các vector kỳ vọng mu0 và mu1
self.mu0 = np.mean(X0, axis=0)
self.mu1 = np.mean(X1, axis=0)

# 4. Tính toán ma trận hiệp phương sai chung mẫu shared sigma
dev0 = X0 - self.mu0
dev1 = X1 - self.mu1

# Cộng gộp tổng bình phương độ lệch trên toàn bộ dữ liệu
shared_covariance = (np.dot(dev0.T, dev0) + np.dot(dev1.T, dev1)) /
↪ n_samples
    self.sigma = shared_covariance

def _multivariate_gaussian(self, X, mu, sigma):
    # Tính toán hàm mật độ xác suất chuẩn đa biến Gauss
    p = len(mu)
    det_sigma = np.linalg.det(sigma)
    inv_sigma = np.linalg.inv(sigma)

    # Tính hằng số chuẩn hóa mặt trước
    norm_const = 1.0 / ((2 * np.pi) ** (p / 2) * np.sqrt(det_sigma))

    # Tính khoảng cách Mahalanobis trong hàm mũ
    dev = X - mu
    exponent = -0.5 * np.sum(np.dot(dev, inv_sigma) * dev, axis=1)
    return norm_const * np.exp(exponent)

def predict_proba(self, X):
    # Giai đoạn dự đoán áp dụng Định lý Bayes
    px_y0 = self._multivariate_gaussian(X, self.mu0, self.sigma)
    px_y1 = self._multivariate_gaussian(X, self.mu1, self.sigma)

    # Tính xác suất đồng thời joint probability
    joint_y0 = px_y0 * (1 - self.phi)

```

```

        joint_y1 = px_y1 * self.phi

        # Chuẩn hóa posterior
        posterior_y1 = joint_y1 / (joint_y0 + joint_y1)
        return posterior_y1

# Kiểm thử thuật toán với dữ liệu giả lập mẫu
np.random.seed(42)
X_data = np.vstack([np.random.multivariate_normal([1.0, 1.0], [[1, 0], [0,
↪ 1]]), 50),
                    np.random.multivariate_normal([3.0, 4.0], [[1, 0], [0,
↪ 1]]), 50)])
y_data = np.hstack([np.zeros(50), np.ones(50)])

gda = GaussianDiscriminantAnalysis()
gda.fit(X_data, y_data)
print("Vector mu0 thực nghiệm tối ưu của GDA:", gda.mu0)
print("Vector mu1 thực nghiệm tối ưu của GDA:", gda.mu1)
print("Estimated shared covariance:")
print(np.round(gda.sigma, 3))

xx, yy = np.meshgrid(np.linspace(-2, 6, 160), np.linspace(-2, 7, 160))
grid = np.c_[xx.ravel(), yy.ravel()]
posterior = gda.predict_proba(grid).reshape(xx.shape)

plt.figure(figsize=(7, 5))
contour = plt.contourf(xx, yy, posterior, levels=20, cmap="RdBu_r",
↪ alpha=0.75)
plt.colorbar(contour, label="$P(y=1 \mid x)$")
plt.scatter(X_data[y_data == 0, 0], X_data[y_data == 0, 1], label="class 0",
↪ edgecolor="black", alpha=0.85)
plt.scatter(X_data[y_data == 1, 0], X_data[y_data == 1, 1], label="class 1",
↪ edgecolor="black", alpha=0.85)
plt.contour(xx, yy, posterior, levels=[0.5], colors="black", linewidths=2)
plt.title("GDA posterior surface and decision boundary")
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.legend()
plt.grid(alpha=0.2)
plt.show()

```

Vector mu0 thực nghiệm tối ưu của GDA: [0.86432437 0.9279826]

Vector mu1 thực nghiệm tối ưu của GDA: [2.90454712 4.14006205]
 Estimated shared covariance:
 [[0.726 0.025]
 [0.025 0.976]]




Figure 5: GDA posterior probabilities learned from two Gaussian-like classes.

7. Bảng Công thức Thi: Cách Thay số cho Bộ phân loại Sinh

Mô hình sinh luôn đi theo mẫu Bayes sau:

$$P(y | \mathbf{x}) = \frac{P(\mathbf{x} | y)P(y)}{\sum_c P(\mathbf{x} | y = c)P(y = c)}$$

Mô hình	Khi nào dùng	Tham số cần ước lượng	Luật dự đoán
GDA	Đặc trưng liên tục, mỗi lớp gần giống Gaussian	$\phi, \mu_0, \mu_1, \Sigma$ chung	Chọn lớp có $P(\mathbf{x} y)P(y)$ lớn hơn.
Naive Bayes	Đặc trưng nhị phân/đếm/văn bản	$P(y)$ và từng $P(x_j y)$	Nhân likelihood của các đặc trưng với prior.
Logistic Regression	Muốn học trực tiếp ranh giới quyết định	θ	Tính $\sigma(\theta^T \mathbf{x})$.

Công thức tham số GDA.

$$\phi = \frac{1}{n} \sum_i y^{(i)}$$

$$\mu_0 = \frac{\sum_i (1 - y^{(i)}) \mathbf{x}^{(i)}}{\sum_i (1 - y^{(i)})}, \quad \mu_1 = \frac{\sum_i y^{(i)} \mathbf{x}^{(i)}}{\sum_i y^{(i)}}$$

$$\Sigma = \frac{1}{n} \sum_i (\mathbf{x}^{(i)} - \mu_{y^{(i)}})(\mathbf{x}^{(i)} - \mu_{y^{(i)}})^T$$

Mẹo nhớ Naive Bayes: prior cho biết lớp đó phổ biến đến đâu; likelihood cho biết đặc trưng quan sát được phù hợp với lớp đó đến đâu.

```
px_y0 = 0.08
px_y1 = 0.24
prior_y0 = 0.60
prior_y1 = 0.40

joint0 = px_y0 * prior_y0
joint1 = px_y1 * prior_y1
posterior_y1 = joint1 / (joint0 + joint1)

print("Điểm joint cho y=0:", round(joint0, 3))
print("Điểm joint cho y=1:", round(joint1, 3))
print("P(y=1 | x):", round(posterior_y1, 3))
print("Lớp dự đoán:", int(posterior_y1 >= 0.5))
```

Điểm joint cho $y=0$: 0.048
Điểm joint cho $y=1$: 0.096
 $P(y=1 \mid \mathbf{x})$: 0.667
Lớp dự đoán: 1

Bộ bài tập mẫu có lời giải

Đề bài. Một bộ phân loại sinh cho biết:

- $P(\mathbf{x} \mid y = 0) = 0.08$, $P(y = 0) = 0.60$
- $P(\mathbf{x} \mid y = 1) = 0.24$, $P(y = 1) = 0.40$

Hãy tính $P(y = 1 \mid \mathbf{x})$ và lớp dự đoán.

Lời giải từng bước.

1. Tính joint score cho lớp 0:

$$P(\mathbf{x} \mid y = 0)P(y = 0) = 0.08(0.60) = 0.048$$

2. Tính joint score cho lớp 1:

$$P(\mathbf{x} \mid y = 1)P(y = 1) = 0.24(0.40) = 0.096$$

3. Chuẩn hóa bằng tổng hai joint score:

$$P(y = 1 \mid \mathbf{x}) = \frac{0.096}{0.048 + 0.096} = 0.667$$

4. Vì $0.667 > 0.5$, dự đoán **lớp 1**.

Kết luận. Dù prior của lớp 1 thấp hơn, likelihood của $\mathbf{x}$ dưới lớp 1 cao hơn đủ mạnh để posterior nghiêng về lớp 1.

Bài 2: Naive Bayes với bảng đếm từ

Đề bài. Một bộ phân loại spam dùng 10 email huấn luyện. Bảng dưới là số email trong từng lớp có chứa mỗi từ. Dùng Laplace smoothing $\alpha = 1$ để phân loại email mới chứa các từ **sale**, **free**, **meeting**.

lớp	số email	sale	free	meeting	project
spam	4	3	4	0	1
normal	6	1	0	5	4

Giả sử các từ là Bernoulli feature: từ xuất hiện hoặc không xuất hiện.

Lời giải. Prior:

$$P(spam) = \frac{4}{10} = 0.4, \quad P(normal) = \frac{6}{10} = 0.6$$

Với Laplace smoothing:

$$P(w = 1 \mid c) = \frac{\#(w = 1, c) + \alpha}{N_c + 2\alpha}$$

Với lớp spam:

$$P(sale = 1 \mid spam) = \frac{3 + 1}{4 + 2} = \frac{4}{6} = 0.667$$

$$P(free = 1 \mid spam) = \frac{4 + 1}{4 + 2} = \frac{5}{6} = 0.833$$

$$P(meeting = 1 \mid spam) = \frac{0 + 1}{4 + 2} = \frac{1}{6} = 0.167$$

Joint score spam:

$$0.4(0.667)(0.833)(0.167) \approx 0.03704$$

Với lớp normal:

$$P(sale = 1 \mid normal) = \frac{1 + 1}{6 + 2} = \frac{2}{8} = 0.250$$

$$P(free = 1 \mid normal) = \frac{0 + 1}{6 + 2} = \frac{1}{8} = 0.125$$

$$P(meeting = 1 \mid normal) = \frac{5 + 1}{6 + 2} = \frac{6}{8} = 0.750$$

Joint score normal:

$$0.6(0.250)(0.125)(0.750) = 0.01406$$

Chuẩn hóa posterior:

$$P(spam \mid words) = \frac{0.03704}{0.03704 + 0.01406} \approx 0.725$$

Vì $0.725 > 0.5$, dự đoán **spam**.

Kết luận. Naive Bayes nhận nhiều xác suất điều kiện lại. Khi làm bài tay, nên tính joint score từng lớp trước, rồi chuẩn hóa ở bước cuối.

Bài 3: Gaussian Discriminant Analysis từ 12 điểm một chiều

Đề bài. Cho dữ liệu một chiều. Ước lượng mean, variance chung, prior của mỗi lớp theo GDA, rồi phân loại điểm mới $x = 2.2$.

dòng	x	y
1	0.8	0
2	1.0	0
3	1.1	0
4	1.3	0
5	1.5	0
6	1.7	0
7	2.4	1
8	2.6	1
9	2.8	1
10	3.0	1
11	3.1	1
12	3.3	1

Lời giải.

Prior hai lớp bằng nhau:

$$P(y = 0) = P(y = 1) = \frac{6}{12} = 0.5$$

Mean lớp 0:

$$\mu_0 = \frac{0.8 + 1.0 + 1.1 + 1.3 + 1.5 + 1.7}{6} = \frac{7.4}{6} \approx 1.233$$

Mean lớp 1:

$$\mu_1 = \frac{2.4 + 2.6 + 2.8 + 3.0 + 3.1 + 3.3}{6} = \frac{17.2}{6} \approx 2.867$$

Variance chung của GDA:

$$\sigma^2 = \frac{1}{12} \sum_{i=1}^{12} (x_i - \mu_{y_i})^2 \approx 0.0922$$

Với $x = 2.2$, mật độ Gaussian theo từng lớp:

$$p(x = 2.2 \mid y = 0) = \frac{1}{\sqrt{2\pi(0.0922)}} \exp\left(-\frac{(2.2 - 1.233)^2}{2(0.0922)}\right) \approx 0.00828$$

$$p(x = 2.2 \mid y = 1) = \frac{1}{\sqrt{2\pi(0.0922)}} \exp\left(-\frac{(2.2 - 2.867)^2}{2(0.0922)}\right) \approx 0.1180$$

Nhân prior:

$$score_0 = 0.00828(0.5) = 0.00414, \quad score_1 = 0.1180(0.5) = 0.05902$$

Posterior lớp 1:

$$P(y = 1 \mid x = 2.2) = \frac{0.05902}{0.00414 + 0.05902} \approx 0.934$$

Vì $0.934 > 0.5$, dự đoán **lớp 1**.

Kết luận. GDA học phân phối của từng lớp trước, rồi dùng Bayes để đổi likelihood thành posterior. Với dữ liệu một chiều, điểm nằm gần mean lớp nào hơn thường nghiêng về lớp đó, nhưng prior và variance vẫn ảnh hưởng.

Phần 6: Học máy: Cây Quyết định Nâng cao và Phương pháp Kết hợp

Nguồn: *quarto/Decision_Tree.qmd*

1. Cơ chế Hoạt động của Cây Quyết định (Decision Tree)

Cây quyết định là thuật toán học máy phi tuyến tính hoạt động theo cơ chế chia để trị (Top-down, Greedy, Recursively partitioning). Thuật toán liên tục phân tách không gian thuộc tính thành các vùng hình chữ nhật loại trừ lẫn nhau (Mutually exclusive regions) sao cho dữ liệu ở mỗi vùng con đạt độ đồng nhất (Purity) cao nhất.

Tại một nút (node) bất kỳ, không gian dữ liệu được phân hoạch dựa trên một thuộc tính j và một ngưỡng giá trị t :

$$S(j, t) = \{\{x \in \mathcal{D} \mid x_j \leq t\}, \{x \in \mathcal{D} \mid x_j > t\}\} = \{R_1, R_2\}$$




Figure 6: A shallow decision tree and the axis-aligned regions it creates.

The important visual property is axis alignment: each split cuts one feature at one threshold, so deeper trees build more refined rectangular regions.

2. Hàm Mục Tiêu và Các Độ Đo Ô Nhiễm (Impurity Metrics)

Để đánh giá chất lượng của một phép phân tách tại nút R , ta định nghĩa hàm chi phí thông qua độ ô nhiễm $L(R)$.

2.1 Đối với Bài toán Phân loại (Classification)

Gọi p_c là tỷ lệ số mẫu thuộc lớp $c \in \{1, 2, \dots, C\}$ bên trong vùng R :

$$p_c = \frac{1}{|R|} \sum_{i \in R} \mathbb{I}(y^{(i)} = c)$$

- **Độ bất định Entropy (Entropy):** Đo lường mức độ hỗn loạn của thông tin. Hàm số đạt cực đại bằng $\log_2 C$ khi dữ liệu phân phối đều và đạt cực tiểu bằng 0 khi toàn bộ mẫu thuộc về một lớp duy nhất:

$$H(R) = - \sum_{c=1}^C p_c \log_2 p_c$$

- **Chỉ số Gini (Gini Index):** Đo lường xác suất phân loại sai một mẫu dữ liệu nếu ta chọn nhãn ngẫu nhiên dựa trên phân phối của vùng đó:

$$G(R) = 1 - \sum_{c=1}^C p_c^2$$

Khi phân hoạch một nút cha R thành hai nút con R_1 và R_2 , thuật toán tham lam sẽ quét qua toàn bộ các thuộc tính j và các ngưỡng t để chọn ra phép phân tách tối đa hóa **Information Gain**:

$$\max_{j,t} \text{Gain}(R, j, t) = H(R) - \left(\frac{|R_1|}{|R|} H(R_1) + \frac{|R_2|}{|R|} H(R_2) \right)$$

2.2 Đối với Bài toán Hồi quy (Regression Trees - CART)

Đối với bài toán dự đoán giá trị liên tục, ta không sử dụng Entropy hay Gini mà tối ưu hóa bằng **Sai số bình phương trung bình (MSE)**.

- **Hàm mục tiêu ô nhiễm tại nút R :**

$$L(R) = \frac{1}{|R|} \sum_{i \in R} (y^{(i)} - \bar{y}_R)^2$$

Trong đó $\bar{y}_R$ là giá trị trung bình cộng của các nhãn mục tiêu nằm trong vùng R :

$$\bar{y}_R = \frac{1}{|R|} \sum_{i \in R} y^{(i)}$$

- **Giá trị dự đoán:** Khi một mẫu dữ liệu mới rơi vào nút lá R , giá trị dự đoán đầu ra của mô hình chính là hằng số $\bar{y}_R$.
- **Tiêu chí phân hoạch:** Thuật toán tìm kiếm thuộc tính j và ngưỡng t sao cho tổng sai số bình phương sau phân tách là nhỏ nhất:

$$\min_{j,t} \left[\sum_{i \in R_1} (y^{(i)} - \bar{y}_{R_1})^2 + \sum_{i \in R_2} (y^{(i)} - \bar{y}_{R_2})^2 \right]$$

3. Kiểm Soát Overfitting & Kỹ Thuật Cắt Tỉa Cây (Pruning)

Nếu cây quyết định được phát triển tự do, nó sẽ mọc cho đến khi tất cả các nút lá đều đồng nhất tuyệt đối ($L(R) = 0$). Hiện tượng này gây ra hiện tượng Overfitting nghiêm trọng (High Variance). Để kiểm soát, ta sử dụng thuật toán **Cost-Complexity Pruning** (Cắt tỉa chi phí - phức tạp).

Ta thiết lập hàm mục tiêu tối ưu hóa có chứa thành phần phạt dựa trên kích thước cấu trúc cây:

$$C_\alpha(T) = \sum_{m=1}^{|T|} |R_m| L(R_m) + \alpha |T|$$

Trong đó: * $|T|$ là số lượng nút lá của cây T . * $L(R_m)$ là độ ô nhiễm tại nút lá thứ m . * $\alpha \geq 0$ là siêu tham số điều khiển sự đánh đổi (trade-off) giữa độ chính xác và độ phức tạp cấu trúc. α càng lớn, thuật toán càng ép cây phải bị cắt tỉa gọn hơn.

4. Các Phương Phương Học Tập Hợp (Ensemble Methods)

4.1 Phương pháp Bagging (Bootstrap Aggregating)

- **Nguyên lý:** Xây dựng song song nhiều cây quyết định hoàn toàn độc lập. Mỗi cây được huấn luyện trên một tập dữ liệu con được tạo ra bằng phương pháp lấy mẫu lặp lại ngẫu nhiên (Bootstrap sampling) từ tập dữ liệu huấn luyện gốc.

- **Đại diện tiêu biểu - Random Forest:** Để giảm thiểu độ tương quan giữa các cây, Random Forest bổ sung một cơ chế ngẫu nhiên hóa: Tại mỗi nút phân tách, thuật toán chỉ cho phép chọn thuộc tính tối ưu từ một tập con gồm k thuộc tính được chọn ngẫu nhiên ($k < p$, thông thường $k = \sqrt{p}$).

4.2 Phương pháp Boosting & Bản chất Toán học của XGBoost

Trái ngược với Bagging, Boosting xây dựng chuỗi các cây một cách tuần tự (Sequential), cây sau tập trung sửa sai cho các cây phía trước.

XGBoost (Extreme Gradient Boosting) nâng cấp thuật toán bằng cách áp dụng **Khai triển Taylor bậc hai** để xấp xỉ hàm mất mát tổng thể tại bước lặp thứ t , giúp tìm ra cấu trúc cây tối ưu một cách cực kỳ chính xác.

Hàm mất mát tại bước lặp thứ t khi thêm cây $f_t(\mathbf{x})$ vào mô hình:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y^{(i)}, \hat{y}^{(t-1)(i)} + f_t(\mathbf{x}^{(i)})) + \Omega(f_t)$$

Áp dụng khai triển Taylor bậc hai xấp xỉ hàm $l(y, \hat{y} + \Delta\hat{y}) \approx l(y, \hat{y}) + g\Delta\hat{y} + \frac{1}{2}h(\Delta\hat{y})^2$:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[l(y^{(i)}, \hat{y}^{(t-1)(i)}) + g_i f_t(\mathbf{x}^{(i)}) + \frac{1}{2} h_i f_t^2(\mathbf{x}^{(i)}) \right] + \Omega(f_t)$$

Trong đó g_i và h_i lần lượt là đạo hàm bậc một (Gradient) và đạo hàm bậc hai (Hessian) của hàm mất mát cũ tính tại giá trị dự đoán trước đó:

$$g_i = \frac{\partial l(y^{(i)}, \hat{y}^{(t-1)(i)})}{\partial \hat{y}^{(t-1)(i)}} \quad \text{và} \quad h_i = \frac{\partial^2 l(y^{(i)}, \hat{y}^{(t-1)(i)})}{\partial (\hat{y}^{(t-1)(i)})^2}$$

Bỏ qua các hằng số không ảnh hưởng đến quá trình tối ưu hóa, hàm mục tiêu rút gọn của XGBoost tại bước t là:

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i f_t(\mathbf{x}^{(i)}) + \frac{1}{2} h_i f_t^2(\mathbf{x}^{(i)}) \right] + \gamma |T| + \frac{1}{2} \lambda \sum_{j=1}^{|T|} w_j^2$$

Thông tin đạo hàm bậc hai h_i đóng vai trò như một hệ số điều hướng độ cong của không gian lỗi, giúp XGBoost hội tụ nhanh vượt trội so với Gradient Boosting truyền thống chỉ dùng đạo hàm bậc một.

5. Bảng Công thức Thi: Máy tính Phân tách Cây Quyết định

Khi đề bài hỏi một phép tách có tốt hay không, hãy tính độ ô nhiễm trước và sau khi tách.

Đại lượng	Công thức	Giá trị tốt nhất
Xác suất lớp	$p_c = \frac{\# \text{mẫu thuộc lớp } c}{ R }$	Dùng bên trong
Entropy	$H(R) = -\sum_c p_c \log_2 p_c$	Entropy/Gini.
Gini	$G(R) = 1 - \sum_c p_c^2$	0 nghĩa là nút hoàn toàn thuần nhất.
Độ ô nhiễm con có trọng số	$\frac{ R_1 }{ R } I(R_1) + \frac{ R_2 }{ R } I(R_2)$	0 nghĩa là nút hoàn toàn thuần nhất.
Information Gain	$I(R) - \left[\frac{ R_1 }{ R } I(R_1) + \frac{ R_2 }{ R } I(R_2) \right]$	Càng thấp càng tốt.
Giá trị lá hồi quy	$\bar{y}_R = \frac{1}{ R } \sum_{i \in R} y_i$	Càng cao càng tốt.
Cost-complexity pruning	$C_\alpha(T) = \sum_m R_m L(R_m) + \alpha T $	Dự đoán trung bình mục tiêu trong nút lá. α càng lớn, cây càng bị cắt gọn.

```
import numpy as np
import matplotlib.pyplot as plt

def entropy(counts):
    counts = np.array(counts, dtype=float)
    probs = counts[counts > 0] / counts.sum()
    return -np.sum(probs * np.log2(probs))

def gini(counts):
    counts = np.array(counts, dtype=float)
    probs = counts / counts.sum()
    return 1 - np.sum(probs ** 2)

parent = [5, 5]
left = [4, 1]
right = [1, 4]
n_parent = sum(parent)
weighted_entropy = (sum(left) / n_parent) * entropy(left) + (sum(right) /
    ↪ n_parent) * entropy(right)
weighted_gini = (sum(left) / n_parent) * gini(left) + (sum(right) / n_parent)
    ↪ * gini(right)
```



```

print("Entropy nút cha:", round(entropy(parent), 3))
print("Entropy con có trọng số:", round(weighted_entropy, 3))
print("Information Gain:", round(entropy(parent) - weighted_entropy, 3))
print("Gini nút cha:", round(gini(parent), 3))
print("Gini con có trọng số:", round(weighted_gini, 3))

labels = ["nút cha", "nút con"]
entropy_vals = [entropy(parent), weighted_entropy]
gini_vals = [gini(parent), weighted_gini]
x = np.arange(len(labels))
width = 0.35
plt.figure(figsize=(6, 3.5))
plt.bar(x - width / 2, entropy_vals, width, label="entropy")
plt.bar(x + width / 2, gini_vals, width, label="gini")
plt.xticks(x, labels)
plt.ylabel("độ ô nhiễm")
plt.title("Phép tách tốt làm giảm độ ô nhiễm")
plt.legend()
plt.grid(axis="y", alpha=0.25)
plt.show()

```

```

Entropy nút cha: 1.0
Entropy con có trọng số: 0.722
Information Gain: 0.278
Gini nút cha: 0.5
Gini con có trọng số: 0.32

```




Figure 7: Information gain compares parent impurity with weighted child impurity.

Bộ bài tập mẫu có lời giải

Đề bài. Một nút cha có 10 mẫu: 5 mẫu lớp 0 và 5 mẫu lớp 1. Một phép tách tạo ra:

- Nút trái: 4 mẫu lớp 0, 1 mẫu lớp 1.
- Nút phải: 1 mẫu lớp 0, 4 mẫu lớp 1.

Hãy tính Information Gain theo Entropy.

Lời giải từng bước.

1. Entropy nút cha:

$$H(R) = -0.5 \log_2(0.5) - 0.5 \log_2(0.5) = 1$$

2. Entropy nút trái:

$$H(R_1) = -0.8 \log_2(0.8) - 0.2 \log_2(0.2) \approx 0.722$$

3. Entropy nút phải có cùng phân phối đảo ngược, nên:

$$H(R_2) \approx 0.722$$

4. Entropy sau tách:

$$\frac{5}{10}(0.722) + \frac{5}{10}(0.722) = 0.722$$

5. Information Gain:

$$IG = 1 - 0.722 = 0.278$$

Kết luận. Phép tách này hữu ích vì làm Entropy giảm từ 1 xuống 0.722.

Bài 2: Chọn split tốt nhất từ bộ dữ liệu 12 dòng

Đề bài. Cho bộ dữ liệu nhị phân sau. Hãy so sánh hai split: $x_1 \leq 2.5$ và $x_2 \leq 1.5$ bằng Information Gain theo Gini. Split nào tốt hơn?

dòng	x_1	x_2	y
1	1.0	1.0	0
2	1.2	1.4	0
3	1.5	2.0	0
4	2.0	1.1	0
5	2.4	1.8	1
6	2.8	1.2	1
7	3.0	2.0	1
8	3.2	2.4	1
9	3.8	1.0	1
10	4.0	2.8	1
11	4.3	1.7	1
12	4.8	2.2	1

Lời giải. Gini của một nút:

$$G(R) = 1 - p_0^2 - p_1^2$$

Information Gain theo Gini:

$$IG = G(R) - \frac{|R_L|}{|R|}G(R_L) - \frac{|R_R|}{|R|}G(R_R)$$

Nút cha có 4 mẫu lớp 0 và 8 mẫu lớp 1:

$$G(R) = 1 - \left(\frac{4}{12}\right)^2 - \left(\frac{8}{12}\right)^2 = 1 - \frac{16}{144} - \frac{64}{144} = 0.444$$

Với split $x_1 \leq 2.5$:

- Nút trái có 5 mẫu: 4 lớp 0, 1 lớp 1.

- Nút phải có 7 mẫu: 0 lớp 0, 7 lớp 1.

$$G(R_L) = 1 - \left(\frac{4}{5}\right)^2 - \left(\frac{1}{5}\right)^2 = 0.320$$

$$G(R_R) = 1 - 0^2 - 1^2 = 0$$

Gini sau split:

$$\frac{5}{12}(0.320) + \frac{7}{12}(0) = 0.133$$

Gain:

$$IG_{x_1} = 0.444 - 0.133 = 0.311$$

Với split $x_2 \leq 1.5$:

- Nút trái có 5 mẫu: 2 lớp 0, 3 lớp 1.
- Nút phải có 7 mẫu: 2 lớp 0, 5 lớp 1.

$$G(R_L) = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = 0.480$$

$$G(R_R) = 1 - \left(\frac{2}{7}\right)^2 - \left(\frac{5}{7}\right)^2 \approx 0.245$$

Gini sau split:

$$\frac{5}{12}(0.480) + \frac{7}{12}(0.245) \approx 0.343$$

Gain:

$$IG_{x_2} = 0.444 - 0.343 = 0.102$$

Kết luận. Chọn split có gain lớn hơn. Trong bài thi, nếu hai split cùng hợp lý trực giác, cứ để Gini/Entropy quyết định.

Bài 3: Lá hồi quy và MSE sau split

Đề bài. Với dữ liệu hồi quy 10 dòng, xét split $x \leq 5$. Mỗi lá dự đoán bằng trung bình y trong lá. Tính MSE sau split.

x	1	2	3	4	5	6	7	8	9	10
y	3	4	5	6	8	13	14	16	18	20

Lời giải.

Lá trái chứa $y = \{3, 4, 5, 6, 8\}$:

$$\hat{y}_L = \frac{3 + 4 + 5 + 6 + 8}{5} = \frac{26}{5} = 5.2$$

Sai số bình phương trong lá trái:

$$(3 - 5.2)^2 + (4 - 5.2)^2 + (5 - 5.2)^2 + (6 - 5.2)^2 + (8 - 5.2)^2 = 14.8$$

Lá phải chứa $y = \{13, 14, 16, 18, 20\}$:

$$\hat{y}_R = \frac{13 + 14 + 16 + 18 + 20}{5} = \frac{81}{5} = 16.2$$

Sai số bình phương trong lá phải:

$$(13 - 16.2)^2 + (14 - 16.2)^2 + (16 - 16.2)^2 + (18 - 16.2)^2 + (20 - 16.2)^2 = 32.8$$

Tổng SSE sau split:

$$SSE = 14.8 + 32.8 = 47.6$$

MSE sau split:

$$MSE = \frac{47.6}{10} = 4.76$$

Kết luận. Với cây hồi quy, lá không bỏ phiếu lớp mà lấy trung bình mục tiêu. Split tốt là split làm tổng sai số trong lá nhỏ đi.

Phần 7: Học máy: Mạng Nơ-ron và Lan truyền Ngược Vector hóa

Nguồn: `quarto/Neural_Network.qmd`

1. Bức tranh tinh thần: mạng nơ-ron đang lưu gì?

Một mạng nơ-ron không phải là một công thức bí ẩn. Nó là nhiều tầng biến đổi dữ liệu liên tiếp. Ở mỗi tầng, có hai pha:

1. **Pha tuyến tính:** gom thông tin từ tầng trước bằng trọng số và độ lệch.
2. **Pha phi tuyến:** đưa kết quả qua hàm kích hoạt để tạo giá trị kích hoạt cho tầng sau.

Với tầng l :

$$\mathbf{Z}^{[l]} = \mathbf{W}^{[l]} \mathbf{A}^{[l-1]} + \mathbf{b}^{[l]}$$

$$\mathbf{A}^{[l]} = g^{[l]}(\mathbf{Z}^{[l]})$$

Ý nghĩa của từng ký hiệu:

Ký hiệu	Nằm ở đâu trong mạng?	Nói bằng lời
$\mathbf{A}^{[0]}$	Tầng đầu vào	Dữ liệu gốc, thường chính là $\mathbf{X}^T$.
$\mathbf{W}^{[l]}$	Các cạnh nối từ tầng $l - 1$ sang tầng l	Trọng số cho biết giá trị kích hoạt tầng trước ảnh hưởng mạnh yếu thế nào đến tầng sau.
$\mathbf{b}^{[l]}$	Mỗi nơ-ron ở tầng l có một độ lệch	Dịch điểm tuyến tính lên hoặc xuống trước khi kích hoạt.
$\mathbf{Z}^{[l]}$	Bên trong tầng l , trước hàm kích hoạt	Điểm tuyến tính trước kích hoạt.
$\mathbf{A}^{[l]}$	Đầu ra của tầng l	Giá trị kích hoạt sau khi áp dụng hàm g . Đây là thứ được gửi sang tầng kế tiếp.
$d\mathbf{Z}^{[l]}$	Khi lan truyền ngược qua tầng l	Tín hiệu lỗi tại điểm trước kích hoạt.
$d\mathbf{W}^{[l]}, d\mathbf{b}^{[l]}$	Cùng chỗ với $\mathbf{W}^{[l]}, \mathbf{b}^{[l]}$	Hướng cần chỉnh trọng số và độ lệch để hàm mất mát giảm.

Nếu chỉ nhớ một câu: lan truyền xuôi tạo ra Z rồi A ; lan truyền ngược tạo ra dZ rồi dW, db ; bước cập nhật dùng dW, db để sửa W, b .




Figure 8: Vị trí của A , W , b , Z trong một tầng kết nối đầy đủ.

2. Một nơ-ron đơn: từ đầu vào đến dự đoán

Một nơ-ron nhận vector đầu vào $\mathbf{x}$, nhân với trọng số $\mathbf{w}$, cộng độ lệch b , rồi đưa qua hàm kích hoạt:

$$z = \mathbf{w}^T \mathbf{x} + b$$

$$a = g(z)$$

Nếu g là sigmoid, a có thể đọc như xác suất. Nếu g là ReLU, a là tín hiệu dương được truyền tiếp.

Ví dụ:

$$\mathbf{x} = (2, 3), \quad \mathbf{w} = (0.5, -0.2), \quad b = 0.1$$

$$z = 0.5(2) - 0.2(3) + 0.1 = 0.5$$

Nếu dùng sigmoid:

$$a = \sigma(0.5) = \frac{1}{1 + e^{-0.5}} \approx 0.622$$

Điều quan trọng: z là điểm thô trước kích hoạt, còn a là tín hiệu đã xử lý để đưa sang bước sau.

3. Lan truyền xuôi: dữ liệu chảy từ trái sang phải

Với mini-batch có m mẫu, ta không xử lý từng mẫu riêng lẻ mà xếp chúng thành ma trận.

Nếu tầng $l - 1$ có n_{l-1} nơ-ron và tầng l có n_l nơ-ron:

Đại lượng	Kích thước	Vai trò
$\mathbf{A}^{[l-1]}$	$n_{l-1} \times m$	Giá trị kích hoạt của tầng trước cho toàn bộ mini-batch.
$\mathbf{W}^{[l]}$	$n_l \times n_{l-1}$	Mỗi hàng là trọng số đi vào một nơ-ron của tầng l .
$\mathbf{b}^{[l]}$	$n_l \times 1$	Độ lệch của từng nơ-ron, được cộng cho mọi cột trong mini-batch.
$\mathbf{Z}^{[l]}$	$n_l \times m$	Điểm tuyến tính của tầng l .
$\mathbf{A}^{[l]}$	$n_l \times m$	Đầu ra của tầng l sau hàm kích hoạt.

Tưởng tượng mỗi cột là một mẫu. Mỗi hàng là một nơ-ron. Vì vậy $\mathbf{A}^{[l]}$ có hàng là nơ-ron tầng l và cột là mẫu trong mini-batch.

Lan truyền xuôi: tính dự đoán và mất mát




Figure 9: Lan truyền xuôi tạo Z rồi A ở từng tầng.

4. Lan truyền ngược: lỗi chảy từ phải sang trái

Lan truyền xuôi trả lời câu hỏi: **mô hình dự đoán gì?**

Lan truyền ngược trả lời câu hỏi: **mỗi tham số phải bị sửa bao nhiêu để hàm mất mát giảm?**

Ký hiệu quan trọng nhất là $\mathbf{dZ}^{[l]}$:

$$\mathbf{dZ}^{[l]} = \frac{\partial \mathcal{L}}{\partial \mathbf{Z}^{[l]}}$$

Đọc bằng lời: nếu điểm trước kích hoạt $\mathbf{Z}^{[l]}$ thay đổi một chút, hàm mất mát thay đổi bao nhiêu?

Sau khi có $\mathbf{dZ}^{[l]}$, ta tính được:

$$\mathbf{dW}^{[l]} = \frac{1}{m} \mathbf{dZ}^{[l]} (\mathbf{A}^{[l-1]})^T$$

$$\mathbf{db}^{[l]} = \frac{1}{m} \sum_{i=1}^m \mathbf{dZ}^{(i)[l]}$$

Ý nghĩa trực giác:

- $\mathbf{dZ}^{[l]}$ là mức lỗi của từng nơ-ron trong từng mẫu.
- $\mathbf{A}^{[l-1]}$ là tín hiệu đã đi vào tầng đó.

- dW bằng **lỗi nhân tín hiệu đầu vào**. Nếu đầu vào lớn và lỗi lớn, cạnh đó cần được sửa nhiều.
- db là lỗi trung bình của từng nơ-ron.

Với tầng ẩn:

$$dZ^{[l]} = ((W^{[l+1]})^T dZ^{[l+1]}) \odot g'(Z^{[l]})$$

Phần $(W^{[l+1]})^T dZ^{[l+1]}$ kéo lỗi từ tầng sau về tầng trước. Phần $\odot g'(Z^{[l]})$ kiểm tra hàm kích hoạt ở tầng này có cho gradient đi qua hay không.

Lan truyền ngược: hàm mất mát gửi tín hiệu sửa tham số




Figure 10: Lan truyền ngược đưa lỗi về từng tầng rồi tạo dW , db để cập nhật tham số.

Sau khi có gradient, cập nhật tham số:

$$W^{[l]} \leftarrow W^{[l]} - \alpha dW^{[l]}$$

$$b^{[l]} \leftarrow b^{[l]} - \alpha db^{[l]}$$

Trong đó α là learning rate.

5. Vì sao sigmoid dễ làm mất gradient?

Sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Đạo hàm:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

Khi z rất lớn, $\sigma(z) \approx 1$, nên $\sigma'(z) \approx 0$. Khi z rất âm, $\sigma(z) \approx 0$, nên $\sigma'(z) \approx 0$. Nếu nhiều tầng đều nhân với đạo hàm gần 0, tín hiệu đạo hàm về các tầng đầu gần như biến mất. Đây là hiện tượng **gradient biến mất**.

Cận trên exam-style cho vanishing gradient.

Vì $\sigma(z) \in (0, 1)$, đặt $s = \sigma(z)$ thì:

$$\sigma'(z) = s(1 - s)$$

Hàm $s(1 - s)$ đạt cực đại tại $s = \frac{1}{2}$, nên:

$$0 < \sigma'(z) \leq \frac{1}{4}$$

Với một mạng sâu dạng vô hướng:

$$a^{[0]} = x, \quad z^{[\ell]} = w_{\ell} a^{[\ell-1]}, \quad a^{[\ell]} = \sigma(z^{[\ell]})$$

gradient về trọng số tầng đầu có dạng tích theo quy tắc chuỗi:

$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial a^{[L]}} \left[\prod_{\ell=2}^L \sigma'(z^{[\ell]}) w_{\ell} \right] \sigma'(z^{[1]}) a^{[0]}$$

Nếu $|w_{\ell}| \leq 1$, phần tín hiệu đi từ tầng cuối về tầng đầu bị chặn bởi:

$$\prod_{\ell=2}^L |\sigma'(z^{[\ell]}) w_{\ell}| \leq \left(\frac{1}{4} \right)^{L-1}$$

Ví dụ với $L = 8$:

$$\left(\frac{1}{4}\right)^7 = \frac{1}{16384} \approx 0.000061$$

Nghĩa là chỉ riêng việc nhân chuỗi các đạo hàm sigmoid đã có thể làm tín hiệu nhỏ đi hơn 16 nghìn lần. Nếu nhiều neuron rơi vào vùng bão hòa, đạo hàm còn nhỏ hơn $\frac{1}{4}$, nên gradient biến mất nhanh hơn nữa.

ReLU:

$$g(z) = \max(0, z)$$

Đạo hàm của ReLU bằng 1 khi $z > 0$, nên ở miền dương tín hiệu đạo hàm đi qua dễ hơn.

Ba cách giảm vanishing gradient thường gặp:

- **ReLU:** tránh nhân gradient với một số luôn nhỏ hơn hoặc bằng 0.25 như sigmoid.
- **Batch Normalization:** giữ z ít rơi vào vùng bão hòa, nên đạo hàm của sigmoid/tanh ít bị kéo về 0 hơn.
- **Residual connection:** thêm đường tắt dạng $\mathbf{A}^{[l+1]} = F(\mathbf{A}^{[l]}) + \mathbf{A}^{[l]}$, giúp gradient có một nhánh identity để chảy ngược về tầng trước.




Figure 11: Sigmoid dễ bão hòa ở hai đầu, còn ReLU giữ gradient tốt ở miền dương.

6. Dropout và Chuẩn hóa Mini-batch

Dropout

Dropout tắt ngẫu nhiên một phần giá trị kích hoạt trong lúc huấn luyện:

$$\mathbf{A}_{\text{drop}}^{[l]} = \mathbf{A}^{[l]} \odot \mathbf{M}^{[l]}$$

Trong đó $\mathbf{M}^{[l]}$ là ma trận 0 hoặc 1. Nếu một nơ-ron bị tắt, mạng không được dựa quá nhiều vào nó. Nhờ vậy mô hình bớt overfit.

Khi kiểm thử, ta không tắt nơ-ron nữa. Với inverted dropout, lúc huấn luyện thường chia giá trị kích hoạt còn sống cho $1 - p$ để giữ kỳ vọng ổn định.

Chuẩn hóa mini-batch

Chuẩn hóa mini-batch chuẩn hóa $\mathbf{Z}^{[l]}$ trong một mini-batch:

$$\hat{z}^{(i)} = \frac{z^{(i)} - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}}$$

Sau đó học thêm scale và shift:

$$\tilde{z}^{(i)} = \gamma \hat{z}^{(i)} + \beta$$

Tác dụng chính:

- Giúp phân phối đầu vào của mỗi tầng ổn định hơn.
- Cho phép dùng learning rate lớn hơn.
- Thường làm quá trình train nhanh và mượt hơn.

Backward pass của Batch Normalization.

Trong bài tính tay, nếu một neuron có mini-batch $z_1, \dots, z_m$ và:

$$\tilde{z}_i = \gamma \hat{z}_i + \beta, \quad \hat{z}_i = \frac{z_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}}$$

thì gradient từ tầng sau thường được ký hiệu:

$$g_i = \frac{\partial L}{\partial \tilde{z}_i}$$

Hai gradient dễ nhất là:

$$\frac{\partial L}{\partial \gamma} = \sum_{i=1}^m g_i \hat{z}_i, \quad \frac{\partial L}{\partial \beta} = \sum_{i=1}^m g_i$$

Gradient quay về từng z_i có dạng gọn:

$$\frac{\partial L}{\partial z_i} = \frac{\gamma}{m\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}} \left[mg_i - \sum_{j=1}^m g_j - \hat{z}_i \sum_{j=1}^m g_j \hat{z}_j \right]$$

Cách nhớ: có ba phần điều chỉnh. Phần mg_i là gradient trực tiếp của phần tử i ; phần $-\sum_j g_j$ xuất hiện vì mean phụ thuộc vào cả batch; phần $-\hat{z}_i \sum_j g_j \hat{z}_j$ xuất hiện vì variance cũng phụ thuộc vào cả batch.

Ví dụ mini-batch nhanh. Với $z = (1, 3, 5, 7)$, ta có $\mu_{\mathcal{B}} = 4$, $\sigma_{\mathcal{B}}^2 = 5$, và:

$$\hat{z} = \left(-\frac{3}{\sqrt{5}}, -\frac{1}{\sqrt{5}}, \frac{1}{\sqrt{5}}, \frac{3}{\sqrt{5}} \right)$$

Nếu $\gamma = 2$, $\beta = -1$, thì:

$$\tilde{z} = 2\hat{z} - 1$$

Nếu $g = (1, -1, 2, -2)$:

$$\frac{\partial L}{\partial \beta} = 0, \quad \frac{\partial L}{\partial \gamma} = \frac{-6}{\sqrt{5}} \approx -2.683$$

Đây là đúng kiểu thay số cần cho câu BatchNorm trong đề thi.

7. Bảng Công thức Thi: Lan truyền Xuôi, Lan truyền Ngược, Cập nhật

Giai đoạn	Công thức	Kích thước
Đầu vào	$\mathbf{A}^{[0]} = \mathbf{X}^T$	$n_0 \times m$
Tuyến tính xuôi	$\mathbf{Z}^{[l]} = \mathbf{W}^{[l]} \mathbf{A}^{[l-1]} + \mathbf{b}^{[l]}$	$n_l \times m$
Kích hoạt xuôi	$\mathbf{A}^{[l]} = g^{[l]}(\mathbf{Z}^{[l]})$	$n_l \times m$
Lỗi đầu ra, sigmoid + BCE	$\mathbf{dZ}^{[L]} = \mathbf{A}^{[L]} - \mathbf{Y}$	$n_L \times m$
Lỗi tầng ẩn	$\mathbf{dZ}^{[l]} = ((\mathbf{W}^{[l+1]})^T \mathbf{dZ}^{[l+1]}) \odot g'(\mathbf{Z}^{[l]})$	$n_l \times m$
Đạo hàm theo trọng số	$\mathbf{dW}^{[l]} = \frac{1}{m} \mathbf{dZ}^{[l]} (\mathbf{A}^{[l-1]})^T$	$n_l \times n_{l-1}$
Đạo hàm theo độ lệch	$\mathbf{db}^{[l]} = \frac{1}{m} \sum_i \mathbf{dZ}^{(i)[l]}$	$n_l \times 1$
Cập nhật trọng số	$\mathbf{W}^{[l]} \leftarrow \mathbf{W}^{[l]} - \alpha \mathbf{dW}^{[l]}$	giống $\mathbf{W}^{[l]}$
Cập nhật độ lệch	$\mathbf{b}^{[l]} \leftarrow \mathbf{b}^{[l]} - \alpha \mathbf{db}^{[l]}$	giống $\mathbf{b}^{[l]}$

Quy tắc kiểm tra nhanh:

- dW phải cùng kích thước với W .
- db phải cùng kích thước với b .
- dZ phải cùng kích thước với Z .
- Nếu phép nhân ma trận không khớp kích thước, hãy kiểm tra lại chiều mini-batch: thường mỗi cột là một mẫu.

dW từ backprop: $\begin{bmatrix} -0.045927 & 0.072171 \end{bmatrix}$
 dW từ sai phân số: $\begin{bmatrix} -0.045927 & 0.072171 \end{bmatrix}$
Sai lệch tuyệt đối: $\begin{bmatrix} 0. & 0. \end{bmatrix}$

8. Bộ bài tập mẫu có lời giải

Bài 1: Xác định kích thước ma trận

Đề bài. Một mini-batch có $m = 5$ mẫu, tầng trước có $n_{l-1} = 3$ nơ-ron, tầng hiện tại có $n_l = 4$ nơ-ron. Hãy xác định kích thước của $\mathbf{A}^{[l-1]}$, $\mathbf{W}^{[l]}$, $\mathbf{b}^{[l]}$, $\mathbf{Z}^{[l]}$, $\mathbf{dW}^{[l]}$.

Lời giải.

Vì mỗi cột là một mẫu:

$$\mathbf{A}^{[l-1]} \in \mathbb{R}^{3 \times 5}$$

Vì tầng hiện tại có 4 nơ-ron, mỗi nơ-ron nhận 3 giá trị kích hoạt từ tầng trước:

$$\mathbf{W}^{[l]} \in \mathbb{R}^{4 \times 3}$$

Độ lệch có một số cho mỗi nơ-ron:

$$\mathbf{b}^{[l]} \in \mathbb{R}^{4 \times 1}$$

Tuyến tính xuôi:

$$\mathbf{Z}^{[l]} = \mathbf{W}^{[l]} \mathbf{A}^{[l-1]} + \mathbf{b}^{[l]}$$

Kích thước:

$$(4 \times 3)(3 \times 5) + (4 \times 1) = 4 \times 5$$

Nên:

$$\mathbf{Z}^{[l]} \in \mathbb{R}^{4 \times 5}$$

Đạo hàm theo trọng số luôn cùng kích thước với trọng số:

$$d\mathbf{W}^{[l]} \in \mathbb{R}^{4 \times 3}$$

Kết luận. Nếu dW không cùng kích thước với W , phép nhân trong backprop đã sai.

Bài 2: Lan truyền xuôi qua mạng 2-2-1

Đề bài. Cho mạng có 2 đầu vào, 2 nơ-ron ẩn dùng ReLU, và 1 đầu ra dùng sigmoid:

$$\mathbf{x} = \begin{pmatrix} 1.0 \\ 2.0 \end{pmatrix}, \quad \mathbf{W}^{[1]} = \begin{pmatrix} 0.5 & -0.4 \\ 0.3 & 0.8 \end{pmatrix}, \quad \mathbf{b}^{[1]} = \begin{pmatrix} 0.1 \\ -0.2 \end{pmatrix}$$

$$\mathbf{W}^{[2]} = \begin{pmatrix} 1.2 & -0.7 \end{pmatrix}, \quad b^{[2]} = 0.05$$

Tính $\mathbf{Z}^{[1]}$, $\mathbf{A}^{[1]}$, $Z^{[2]}$, và $A^{[2]}$.

Lời giải.

Tầng ẩn:

$$\mathbf{z}^{[1]} = \begin{pmatrix} 0.5 & -0.4 \\ 0.3 & 0.8 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 0.1 \\ -0.2 \end{pmatrix}$$

Neuron ẩn thứ nhất:

$$z_1^{[1]} = 0.5(1) - 0.4(2) + 0.1 = -0.2$$

Neuron ẩn thứ hai:

$$z_2^{[1]} = 0.3(1) + 0.8(2) - 0.2 = 1.7$$

Do đó:

$$\mathbf{z}^{[1]} = \begin{pmatrix} -0.2 \\ 1.7 \end{pmatrix}$$

Qua ReLU:

$$\mathbf{A}^{[1]} = \begin{pmatrix} \max(0, -0.2) \\ \max(0, 1.7) \end{pmatrix} = \begin{pmatrix} 0 \\ 1.7 \end{pmatrix}$$

Tầng đầu ra:

$$Z^{[2]} = \begin{pmatrix} 1.2 & -0.7 \end{pmatrix} \begin{pmatrix} 0 \\ 1.7 \end{pmatrix} + 0.05$$

$$Z^{[2]} = 1.2(0) - 0.7(1.7) + 0.05 = -1.14$$

Qua sigmoid:

$$A^{[2]} = \sigma(-1.14) = \frac{1}{1 + e^{1.14}} \approx 0.242$$

Kết luận. Mạng dự đoán xác suất khoảng 0.242 cho lớp 1.

Bài 3: Một bước lan truyền ngược ở tầng đầu ra

Đề bài. Với đầu ra của Bài 2 và nhãn thật $y = 1$, dùng sigmoid + binary cross-entropy. Tính $dZ^{[2]}$, $dW^{[2]}$, $db^{[2]}$.

Lời giải.

Với sigmoid + binary cross-entropy:

$$dZ^{[2]} = A^{[2]} - y$$

Thay số:

$$dZ^{[2]} = 0.242 - 1 = -0.758$$

Vì chỉ có một mẫu:

$$dW^{[2]} = dZ^{[2]}(A^{[1]})^T$$

$$dW^{[2]} = -0.758 \begin{pmatrix} 0 & 1.7 \end{pmatrix} = \begin{pmatrix} 0 & -1.289 \end{pmatrix}$$

Đạo hàm theo độ lệch:

$$db^{[2]} = dZ^{[2]} = -0.758$$

Nếu tốc độ học $\alpha = 0.1$, cập nhật tầng đầu ra:

$$W_1^{[2]} \leftarrow 1.2 - 0.1(0) = 1.2$$

$$W_2^{[2]} \leftarrow -0.7 - 0.1(-1.289) = -0.571$$

$$b^{[2]} \leftarrow 0.05 - 0.1(-0.758) = 0.126$$

Kết luận. Vì mô hình dự đoán quá thấp so với nhãn 1, đạo hàm làm độ lệch tầng đầu ra tăng và làm trọng số nối từ giá trị kích hoạt 1.7 bớt âm để lần sau xác suất lớp 1 cao hơn.

Phần 8: Học máy: Tối ưu hóa, Thiên lệch-Phương sai, và Điều chuẩn

Nguồn: `quarto/Optimization_Bias_Variance-Regularization.qmd`

1. Tối ưu hóa bằng Gradient Descent

Giả sử ta tối thiểu hóa loss hồi quy tuyến tính:

$$L(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Gradient descent cập nhật tham số theo quy tắc:

$$\beta^{(t+1)} = \beta^{(t)} - \alpha \nabla L(\beta^{(t)})$$

Trong đó α là learning rate. Nếu α quá nhỏ, mô hình học chậm. Nếu α quá lớn, loss có thể dao động hoặc tăng.

Với từng hệ số β_j :

$$\frac{\partial L}{\partial \beta_j} = -\frac{1}{n} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i) x_{i,j}$$

Suy ra cập nhật:

$$\beta_j \leftarrow \beta_j + \frac{\alpha}{n} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i) x_{i,j}$$

Thực giác: nếu residual $y_i - \hat{y}_i$ dương, mô hình đang dự đoán thấp hơn thực tế. Ta tăng các hệ số tương ứng với đặc trưng dương để kéo dự đoán lên.

2. Batch, Stochastic, và Mini-batch

Biến thể	Dữ liệu dùng trong một lần cập nhật	Công thức	Khi nào nhớ tới
Batch Gradient Descent	Toàn bộ n mẫu	$\beta_j \leftarrow \beta_j + \frac{\alpha}{n} \sum_i (y_i - \hat{y}_i) x_{i,j}$	Mượt, ổn định, nhưng chậm với dữ liệu lớn.
Stochastic Gradient Descent	Một mẫu ngẫu nhiên	$\beta_j \leftarrow \beta_j + \alpha (y_i - \hat{y}_i) x_{i,j}$	Nhanh, nhiễu cao, loss dao động.
Mini-batch Gradient Descent	Một nhóm m mẫu	$\beta_j \leftarrow \beta_j + \frac{\alpha}{m} \sum_{i \in \mathcal{B}} (y_i - \hat{y}_i) x_{i,j}$	Cân bằng giữa tốc độ, vector hóa, và ổn định.

```
import numpy as np
import matplotlib.pyplot as plt

beta_grid = np.linspace(-1, 5, 300)
loss_grid = (beta_grid - 2.3) ** 2 + 0.4

beta = -0.5
alpha = 0.22
path = [beta]
for _ in range(12):
    grad = 2 * (beta - 2.3)
    beta = beta - alpha * grad
    path.append(beta)

path = np.array(path)
path_loss = (path - 2.3) ** 2 + 0.4

plt.figure(figsize=(7, 4))
plt.plot(beta_grid, loss_grid, color="#4C78A8", label="loss")
plt.scatter(path, path_loss, color="#F58518", zorder=3, label="các bước cập
↪ nhật")
for a, b, la, lb in zip(path[:-1], path[1:], path_loss[:-1], path_loss[1:]):
    plt.annotate("", xy=(b, lb), xytext=(a, la), arrowprops={"arrowstyle":
↪ "->", "color": "#F58518"})
plt.xlabel("tham số beta")
plt.ylabel("loss")
plt.title("Learning rate điều khiển độ dài bước đi")
plt.legend()
plt.grid(alpha=0.25)
plt.show()
```




Figure 12: Gradient descent đi từng bước xuống đáy của hàm loss lồi.

3. Underfitting và Overfitting

Khi mô hình gặp dữ liệu mới, ta quan tâm test loss:

$$L_{\text{test}} = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} [(y - \hat{f}(\mathbf{x}))^2]$$

Hai kiểu lỗi chính:

- **Underfitting, high bias:** train loss cao, test loss cao. Mô hình quá đơn giản, không học được quy luật thật.
- **Overfitting, high variance:** train loss thấp, test loss cao. Mô hình quá linh hoạt, học cả nhiễu của tập train.

Một câu nhớ nhanh: bias là lỗi do giả định quá cứng; variance là lỗi do mô hình thay đổi quá mạnh khi tập train thay đổi.

4. Bias-Variance Decomposition

Giả sử:

$$y = f(\mathbf{x}) + \epsilon, \quad \mathbb{E}[\epsilon] = 0, \quad \text{Var}(\epsilon) = \sigma^2$$

Mô hình học từ một tập dữ liệu ngẫu nhiên $\mathcal{D}$, nên dự đoán $\hat{f}(\mathbf{x}; \mathcal{D})$ cũng là biến ngẫu nhiên. Tại một điểm $\mathbf{x}$ cố định:

$$\mathbb{E}[(y - \hat{f})^2] = \text{Bias}(\hat{f})^2 + \text{Var}(\hat{f}) + \sigma^2$$

Suy luận từng bước:

$$\mathbb{E}[(y - \hat{f})^2] = \mathbb{E}[(f + \epsilon - \hat{f})^2]$$

Khai triển bình phương:

$$\mathbb{E}[(f - \hat{f})^2 + 2\epsilon(f - \hat{f}) + \epsilon^2]$$

Vì $\mathbb{E}[\epsilon] = 0$, hạng chéo bằng 0. Vì $\mathbb{E}[\epsilon^2] = \sigma^2$, còn:

$$\mathbb{E}_{\mathcal{D}}[(f - \hat{f})^2] + \sigma^2$$

Thêm và bớt dự đoán trung bình $\mathbb{E}_{\mathcal{D}}[\hat{f}]$:

$$f - \hat{f} = (f - \mathbb{E}_{\mathcal{D}}[\hat{f}]) + (\mathbb{E}_{\mathcal{D}}[\hat{f}] - \hat{f})$$

Hạng thứ nhất tạo **bias bình phương**. Hạng thứ hai tạo **variance**. Hạng chéo bằng 0 vì độ lệch quanh trung bình có kỳ vọng bằng 0.

5. Regularization

Regularization thêm hình phạt vào loss để mô hình bớt đuối theo nhiễu:

$$L_{\text{reg}}(\beta) = L(\beta) + \lambda R(\beta)$$

Trong đó $\lambda \geq 0$ điều khiển độ mạnh của phạt.

Phương pháp	Penalty	Tác dụng
Ridge, L_2	$\lambda \sum_j \beta_j^2$	Co nhỏ hệ số một cách mượt, giảm variance.
Lasso, L_1	$\lambda \sum_j \beta_j $	Có thể đẩy một số hệ số về đúng 0, chọn đặc trưng.
Elastic Net	$\lambda_1 \ \beta\ _1 + \lambda_2 \ \beta\ _2^2$	Kết hợp sparse và ổn định.

Nếu λ quá nhỏ, mô hình có thể overfit. Nếu λ quá lớn, mô hình có thể underfit.

6. Chọn siêu tham số bằng Cross-validation

Quy trình K -fold cross-validation:

1. Chia tập train thành K fold.
2. Với mỗi ứng viên λ , train trên $K - 1$ fold và validate trên fold còn lại.
3. Lặp để mỗi fold được làm validation một lần.
4. Lấy trung bình validation loss.
5. Chọn λ có validation loss trung bình nhỏ nhất.
6. Train lại trên toàn bộ tập train bằng λ đã chọn.

Không dùng test set để chọn λ , vì test set phải là phần đánh giá cuối cùng.

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(3)
x = np.linspace(-3, 3, 35)
true_y = np.sin(x)
y = true_y + np.random.normal(0, 0.22, size=x.shape)
x_grid = np.linspace(-3, 3, 300)
```

```

true_grid = np.sin(x_grid)

degrees = [1, 5, 18]
titles = ["High bias\nunderfit", "Cân bằng", "High variance\noverfit"]
fig, axes = plt.subplots(1, 3, figsize=(10, 3.4), sharey=True)

for ax, degree, title in zip(axes, degrees, titles):
    coef = np.polyfit(x, y, degree)
    pred = np.polyval(coef, x_grid)
    train_mse = np.mean((np.polyval(coef, x) - y) ** 2)
    test_mse = np.mean((pred - true_grid) ** 2)
    ax.scatter(x, y, color="#4C78A8", s=35, label="mẫu train")
    ax.plot(x_grid, true_grid, color="black", linestyle="--", label="hàm
    ⇨ thật")
    ax.plot(x_grid, pred, color="#F58518", linewidth=2, label="mô hình")
    ax.set_title(f"{title}\nbậc={degree}")
    ax.text(-2.9, 1.15, f"train MSE={train_mse:.2f}\ntest
    ⇨ MSE={test_mse:.2f}", fontsize=8)
    ax.set_ylim(-1.5, 1.5)
    ax.grid(alpha=0.25)
axes[0].legend(fontsize=8, loc="lower left")
plt.tight_layout()
plt.show()

```




Figure 13: Underfitting, fit hợp lý, và overfitting trên cùng một bộ dữ liệu nhiễu.

7. Bảng Công thức Thi: Bias, Variance, Regularization

Dấu hiệu	Chẩn đoán	Cách xử lý
Train loss cao, test loss cao	High bias	Thêm đặc trưng, tăng bậc mô hình, giảm regularization.
Train loss thấp, test loss cao	High variance	Tăng regularization, đơn giản hóa mô hình, thêm dữ liệu.
Train loss thấp, test loss thấp	Fit tốt	Giữ mô hình, kiểm tra thêm bằng dữ liệu mới.
Validation loss nhỏ nhất tại λ trung bình	Trade-off tốt	Chọn λ đó rồi train lại trên full train.
Loss dao động mạnh khi train	Learning rate lớn hoặc SGD nhiều	Giảm α , dùng mini-batch, chuẩn hóa dữ liệu.

Gradient cần nhớ:

$$\nabla L = -\frac{1}{n} \mathbf{X}^T (\mathbf{y} - \mathbf{X}\beta)$$

Ridge gradient add-on:

$$\nabla L_{\text{ridge}} = \nabla L + 2\lambda\beta$$

Bias-variance:

$$\text{MSE} = \text{Bias}^2 + \text{Variance} + \text{Noise}$$

8. Bộ bài tập mẫu có lời giải

Bài 1: Tính objective Ridge

Đề bài. Một mô hình có train loss 0.20 và trọng số $\beta = (2, -1, 0.5)$. Tính ridge objective với $\lambda = 0.1$.

Lời giải.

Tính penalty:

$$\|\beta\|_2^2 = 2^2 + (-1)^2 + 0.5^2 = 4 + 1 + 0.25 = 5.25$$

Nhân với λ :

$$\lambda \|\beta\|_2^2 = 0.1(5.25) = 0.525$$

Cộng với loss gốc:

$$L_{\text{reg}} = 0.20 + 0.525 = 0.725$$

Kết luận. Ridge objective bằng 0.725.

Bài 2: Chọn λ từ bảng cross-validation

Đề bài. Sau 5-fold cross-validation, ta có validation MSE:

λ	fold 1	fold 2	fold 3	fold 4	fold 5
0.00	0.92	1.10	0.98	1.05	1.20
0.01	0.70	0.78	0.74	0.76	0.81
0.10	0.54	0.57	0.55	0.58	0.56
1.00	0.61	0.65	0.64	0.62	0.67
10.00	1.20	1.15	1.25	1.18	1.22

Chọn λ tốt nhất.

Lời giải. Tính trung bình từng dòng:

$$\lambda = 0 : \frac{0.92 + 1.10 + 0.98 + 1.05 + 1.20}{5} = 1.050$$

$$\lambda = 0.01 : \frac{0.70 + 0.78 + 0.74 + 0.76 + 0.81}{5} = 0.758$$

$$\lambda = 0.10 : \frac{0.54 + 0.57 + 0.55 + 0.58 + 0.56}{5} = 0.560$$

$$\lambda = 1.00 : \frac{0.61 + 0.65 + 0.64 + 0.62 + 0.67}{5} = 0.638$$

$$\lambda = 10.00 : \frac{1.20 + 1.15 + 1.25 + 1.18 + 1.22}{5} = 1.200$$

Bảng tóm tắt:

λ	validation MSE trung bình
0.00	1.050
0.01	0.758
0.10	0.560
1.00	0.638
10.00	1.200

Kết luận. Chọn $\lambda = 0.10$ vì validation MSE trung bình nhỏ nhất. $\lambda = 0$ có dấu hiệu overfit, còn $\lambda = 10$ quá mạnh nên dễ underfit.

Bài 3: Một bước Gradient Descent trên dữ liệu 12 dòng

Đề bài. Dữ liệu có một đặc trưng x và intercept. Bắt đầu với $\beta_0 = 0, \beta_1 = 0$, learning rate $\alpha = 0.01$. Tính một bước batch gradient descent cho loss MSE.

dòng	x	y
1	1	4
2	2	5
3	3	7
4	4	8
5	5	11
6	6	13
7	7	15
8	8	16
9	9	19
10	10	21
11	11	22
12	12	25

Lời giải. Với $\beta_0 = \beta_1 = 0$, mọi dự đoán ban đầu bằng 0, nên residual $r_i = y_i$.

Gradient theo dạng cập nhật cộng:

$$\beta_j \leftarrow \beta_j + \frac{\alpha}{n} \sum_{i=1}^n r_i x_{i,j}$$

Với intercept, $x_{i,0} = 1$.

Tính tổng residual:

$$\sum r_i = 4 + 5 + 7 + 8 + 11 + 13 + 15 + 16 + 19 + 21 + 22 + 25 = 166$$

Tính tổng residual nhân đặc trưng:

$$\sum r_i x_i = 4(1) + 5(2) + 7(3) + 8(4) + 11(5) + 13(6) + 15(7) + 16(8) + 19(9) + 21(10) + 22(11) + 25(12) = 1356$$

Cập nhật intercept:

$$\beta_0^{new} = 0 + \frac{0.01}{12}(166) \approx 0.1383$$

Cập nhật slope:

$$\beta_1^{new} = 0 + \frac{0.01}{12}(1356) = 1.1300$$

Kết luận. Một bước cập nhật đã kéo đường dự đoán từ đường phẳng $\hat{y} = 0$ về phía dữ liệu. Trong bài thi, chỉ cần nhớ: residual nhân đặc trưng rồi lấy trung bình.

Phần 9: Học máy: Học Không Giám sát và Phân cụm K-means

Nguồn: `quarto/Unsupervised_Learning_K_Means.qmd`

1. Tổng quan về Học Không Giám Sát (Unsupervised Learning)

Trong khi Học có giám sát (Supervised Learning) làm việc với cặp dữ liệu huấn luyện đầy đủ nhãn $\{(\mathbf{x}^{(i)}, y^{(i)})\}$, **Học không giám sát** chỉ nhận đầu vào là một tập hợp các vector đặc trưng không có nhãn mục tiêu kèm theo:

$$\mathcal{D} = \{\mathbf{x}^{(i)}\}_{i=1}^n \quad \text{với } \mathbf{x}^{(i)} \in \mathbb{R}^p$$

Mục tiêu của hệ thống là tự tìm ra các mô thức cấu trúc ẩn (Hidden structures) hoặc quy luật phân bố của dữ liệu. Các nhánh bài toán chính bao gồm: * **Phân cụm (Clustering)**: Gom nhóm các điểm dữ liệu tương đồng vào cùng một cụm. * **Giảm chiều dữ liệu (Dimensionality Reduction)**: Nén không gian thuộc tính từ bậc cao về bậc thấp mà vẫn giữ tối đa lượng thông tin (ví dụ: PCA). * **Phát hiện dị biệt (Anomaly Detection)**: Tìm kiếm các điểm dữ liệu bất thường lệch sâu khỏi phân phối chuẩn.

2. Giải thuật Phân Cụm K-means (K-means Clustering)

K-means là thuật toán phân cụm dựa trên phân hoạch không gian (Partitioning method). Thuật toán cố gắng chia n mẫu dữ liệu thành K cụm khác nhau ($C_1, C_2, \dots, C_K$) cố định sao cho tổng bình phương khoảng cách từ các điểm đến tâm cụm (Centroid) tương ứng là nhỏ nhất.

2.1 Hàm Mục Tiêu Định Lượng (Distortion Function / Cost Function)

Về mặt toán học, K-means tối thiểu hóa hàm chi phí J , còn được gọi là độ méo dạng (Distortion Function):

$$J(c^{(1)}, \dots, c^{(n)}, \mu_1, \dots, \mu_K) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}^{(i)} - \mu_{c^{(i)}}\|^2$$

Trong đó: * $c^{(i)} \in \{1, 2, \dots, K\}$ là chỉ số cụm được gán cho mẫu dữ liệu $\mathbf{x}^{(i)}$. * $\mu_k \in \mathbb{R}^p$ là vector tọa độ tâm của cụm thứ k . * $\|\cdot\|$ đại diện cho khoảng cách hình học L2 (Euclidean distance).

Diễn giải cho người mới học. Với mỗi điểm dữ liệu, K-means chỉ hỏi một câu: “Tâm cụm nào gần điểm này nhất?” Khoảng cách bình phương là mức phạt cho phép gán đó. Hàm mục tiêu là mức phạt trung bình trên toàn bộ dữ liệu, nên phân cụm tốt nghĩa là các điểm nằm gần tâm cụm được gán của chúng.

Với một cụm cố định C_k , bước cập nhật tâm cụm giải bài toán nhỏ hơn:

$$\min_{\mu_k} \sum_{i \in C_k} \|\mathbf{x}^{(i)} - \mu_k\|^2$$

Lấy đạo hàm theo μ_k :

$$\sum_{i \in C_k} 2(\mu_k - \mathbf{x}^{(i)}) = 0$$


Cô lập tâm cụm:

$$|C_k| \mu_k = \sum_{i \in C_k} \mathbf{x}^{(i)} \implies \mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}^{(i)}$$

Vì vậy, tâm cụm tốt nhất cho một nhóm điểm cố định chính là trung bình cộng của các điểm trong nhóm đó.

2.2 Quy Trình Vòng Lặp Hội Tụ (Coordinate Descent)

Hàm mục tiêu J phụ thuộc vào hai nhóm biến độc lập: chỉ số gán cụm $c^{(i)}$ và tọa độ tâm μ_k . Để tối ưu, K-means thực hiện kỹ thuật tối ưu hóa luân phiên theo từng nhóm biến (Coordinate Descent):



1. **Bước gán cụm (Cluster Assignment Step):** Giữ cố định toàn bộ các tâm cụm μ_k , tối ưu hóa hàm chi phí bằng cách tìm chỉ số cụm $c^{(i)}$ gần nhất cho từng mẫu dữ liệu:

$$c^{(i)} \leftarrow \arg \min_k \|\mathbf{x}^{(i)} - \mu_k\|^2$$

2. **Bước cập nhật tâm cụm (Centroid Update Step):** Giữ cố định toàn bộ các chỉ số gán cụm $c^{(i)}$, tối ưu hóa tọa độ các tâm cụm μ_k bằng cách lấy đạo hàm riêng của J theo từng μ_k và đặt bằng 0. Kết quả nghiệm đóng chính là tọa độ trung bình cộng:

$$\mu_k \leftarrow \frac{\sum_{i=1}^n \mathbb{I}(c^{(i)} = k) \mathbf{x}^{(i)}}{\sum_{i=1}^n \mathbb{I}(c^{(i)} = k)} = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}^{(i)}$$

Chứng minh tính hội tụ: Vì tại mỗi phân đoạn của Bước 1 và Bước 2, giá trị của hàm chi phí J luôn luôn giảm hoặc giữ nguyên ($J^{(t+1)} \leq J^{(t)}$), đồng thời hàm J luôn bị chặn dưới bởi số 0, nên giải thuật K -means **chắc chắn luôn luôn hội tụ** về một điểm cực trị sau một số hữu hạn vòng lặp. Tuy nhiên, vì đây là hàm không lồi hoàn toàn, thuật toán có thể bị kẹt ở điểm cực tiểu cục bộ (Local Minimum) phụ thuộc vào cách khởi tạo tâm cụm ban đầu.

Bản chứng minh đầy đủ hơn để dùng khi thi.

K-means tối ưu hàm:

$$J(\mathbf{c}, \mu) = \sum_{i=1}^m \left\| \mathbf{x}^{(i)} - \mu_{c_i} \right\|_2^2$$

trong đó c_i là nhãn cụm của điểm thứ i .

Bước 1: Gán cụm khi tâm cố định. Với các tâm cụm không đổi, mỗi điểm được gán về tâm gần nhất:

$$c_i^{new} = \arg \min_k \left\| \mathbf{x}^{(i)} - \mu_k \right\|_2^2$$

nên:

$$\left\| \mathbf{x}^{(i)} - \mu_{c_i^{new}} \right\|_2^2 \leq \left\| \mathbf{x}^{(i)} - \mu_{c_i^{old}} \right\|_2^2$$

cho từng điểm. Cộng trên toàn bộ dữ liệu suy ra J không tăng.

Bước 2: Cập nhật tâm khi nhãn cố định. Với một cụm C_k đã cố định, ta cần giải:

$$\min_{\mu_k} \sum_{\mathbf{x}^{(i)} \in C_k} \|\mathbf{x}^{(i)} - \mu_k\|_2^2$$

Lấy gradient:

$$-2 \sum_{\mathbf{x}^{(i)} \in C_k} \mathbf{x}^{(i)} + 2|C_k|\mu_k = 0$$

suy ra:

$$\mu_k = \frac{1}{|C_k|} \sum_{\mathbf{x}^{(i)} \in C_k} \mathbf{x}^{(i)}$$

Tức là tâm mới chính là trung bình cộng, nghiệm tối ưu của cụm đó. Vì vậy bước cập nhật tâm cũng không làm tăng J .

Bước 3: Vì sao hữu hạn? Có tối đa K^m cách gán m điểm vào K cụm. Mỗi vòng lặp làm J giảm hoặc giữ nguyên, và khi phép gán không đổi thì các tâm cũng không đổi. Vì số trạng thái gán cụm là hữu hạn, thuật toán phải dừng sau hữu hạn bước.

Điều không được hiểu sai: Hội tụ không có nghĩa là đạt cực tiểu toàn cục. K-means là coordinate descent trên một bài toán có biến rời rạc c_i và tâm liên tục μ_k , nên hàm mục tiêu không lồi toàn cục. Một nghiệm có thể ổn định với hai bước Lloyd nhưng vẫn kém hơn một cách chia khác. Trong thực tế nên dùng K-means++, chạy nhiều lần với nhiều khởi tạo, rồi chọn nghiệm có distortion nhỏ nhất.

3. Cải Tiến Chọn Tâm Ban Đầu: K-means++

Để giảm thiểu rủi ro bị kẹt ở cực tiểu cục bộ do khởi tạo các tâm ban đầu quá gần nhau, thuật toán **K-means++** bổ sung quy tắc chọn tâm thông minh dựa trên xác suất khoảng cách:

1. Chọn ngẫu nhiên tâm cụm đầu tiên μ_1 từ tập dữ liệu.
2. Với mỗi mẫu dữ liệu $\mathbf{x}^{(i)}$, tính toán khoảng cách ngắn nhất từ nó đến các tâm cụm đã được chọn trước đó, ký hiệu là $D(\mathbf{x}^{(i)})$.
3. Chọn tâm cụm tiếp theo μ_k từ các điểm dữ liệu dựa trên phân phối xác suất tỷ lệ thuận với bình phương khoảng cách:

$$P(\mathbf{x}^{(i)}) = \frac{D(\mathbf{x}^{(i)})^2}{\sum_{j=1}^n D(\mathbf{x}^{(j)})^2}$$

(Điểm nào nằm càng xa các tâm cụm đã có thì càng có xác suất cao được chọn làm tâm cụm mới). 4. Lặp lại bước 2 và 3 cho đến khi đủ K tâm cụm, sau đó tiến hành chạy vòng lặp K -means chuẩn.

4. Thực Hành Trace Thuật Toán Bằng Tay (Bản Số Hóa)

Dưới đây là phần số hóa chi tiết bài toán chạy mô phỏng từng bước (Trace) từ ghi chép thực tế của bạn với 5 mẫu dữ liệu trong không gian 2D ($p = 2$), phân thành $K = 2$ cụm.

4.1 Khởi tạo dữ liệu gốc (Input Data)

- $\mathbf{x}^{(1)} = (1, 1)$
- $\mathbf{x}^{(2)} = (2, 1)$
- $\mathbf{x}^{(3)} = (4, 1)$
- $\mathbf{x}^{(4)} = (7, 1)$
- $\mathbf{x}^{(5)} = (9, 1)$

Chọn 2 tâm cụm khởi tạo ban đầu ngẫu nhiên:

- $\mu_1^{(0)} = (2, 1)$
- $\mu_2^{(0)} = (4, 1)$

4.2 Vòng Lặp 1 (Iteration 1)

Bước 1: Gán cụm dựa trên khoảng cách Euclidean gần nhất

Tính toán khoảng cách từ các điểm dữ liệu đến hai tâm $\mu_1^{(0)}$ và $\mu_2^{(0)}$:

- Mẫu $\mathbf{x}^{(1)} = (1, 1)$: Gần $\mu_1^{(0)}$ hơn $\Rightarrow c^{(1)} = 1$.
- Mẫu $\mathbf{x}^{(2)} = (2, 1)$: Trùng với $\mu_1^{(0)}$ $\Rightarrow c^{(2)} = 1$.
- Mẫu $\mathbf{x}^{(3)} = (4, 1)$: Trùng với $\mu_2^{(0)}$ $\Rightarrow c^{(3)} = 2$.
- Mẫu $\mathbf{x}^{(4)} = (7, 1)$: Gần $\mu_2^{(0)}$ hơn $\Rightarrow c^{(4)} = 2$.

- Mẫu $\mathbf{x}^{(5)} = (9, 1)$: Gần $\mu_2^{(0)}$ hơn $\implies c^{(5)} = 2$.

Kết thúc bước gán cụm, ta có thành phần thành viên:

- Cụm 1: $C_1 = \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}\}$
- Cụm 2: $C_2 = \{\mathbf{x}^{(3)}, \mathbf{x}^{(4)}, \mathbf{x}^{(5)}\}$

Bước 2: Cập nhật lại tọa độ các tâm cụm

Tính toán trung bình cộng tọa độ các điểm thành viên trong mỗi cụm:

- Tâm cụm 1 mới:

$$\mu_1^{(1)} = \frac{(1, 1) + (2, 1)}{2} = (1.5, 1)$$

- Tâm cụm 2 mới:

$$\mu_2^{(1)} = \frac{(4, 1) + (7, 1) + (9, 1)}{3} = \left(\frac{20}{3}, 1\right) \approx (6.67, 1)$$

4.3 Vòng Lặp 2 (Iteration 2)

Bước 1: Gán lại cụm dựa trên các tâm mới $\mu_1^{(1)}$ và $\mu_2^{(1)}$

- Mẫu $\mathbf{x}^{(1)} = (1, 1)$: Khoảng cách đến $\mu_1^{(1)}$ là 0.5, đến $\mu_2^{(1)}$ là 5.17 $\implies c^{(1)} = 1$.
- Mẫu $\mathbf{x}^{(2)} = (2, 1)$: Khoảng cách đến $\mu_1^{(1)}$ là 0.5, đến $\mu_2^{(1)}$ là 4.67 $\implies c^{(2)} = 1$.
- Mẫu $\mathbf{x}^{(3)} = (4, 1)$: Khoảng cách đến $\mu_1^{(1)}$ là 2.5, đến $\mu_2^{(1)}$ là 2.67 $\implies$ Vẫn gần $\mu_1^{(1)}$ hơn!
Điểm $\mathbf{x}^{(3)}$ bị nhảy cụm từ cụm 2 sang cụm 1 $\implies c^{(3)} = 1$.
- Mẫu $\mathbf{x}^{(4)} = (7, 1)$: Gần $\mu_2^{(1)}$ hơn $\implies c^{(4)} = 2$.
- Mẫu $\mathbf{x}^{(5)} = (9, 1)$: Gần $\mu_2^{(1)}$ hơn $\implies c^{(5)} = 2$.

Thành phần thành viên mới sau khi phân định lại:

- Cụm 1: $C_1 = \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \mathbf{x}^{(3)}\}$
- Cụm 2: $C_2 = \{\mathbf{x}^{(4)}, \mathbf{x}^{(5)}\}$

Bước 2: Cập nhật lại tọa độ các tâm cụm một lần nữa

- Tâm cụm 1 mới:

$$\mu_1^{(2)} = \frac{(1, 1) + (2, 1) + (4, 1)}{3} = \left(\frac{7}{3}, 1\right) \approx (2.33, 1)$$

- Tâm cụm 2 mới:

$$\mu_2^{(2)} = \frac{(7, 1) + (9, 1)}{2} = (8, 1)$$

4.4 Kết luận hội tụ (Convergence)

Nếu ta tiếp tục chạy sang Vòng lặp 3, việc gán cụm cho các mẫu dựa trên các tâm cụm mới $(2.33, 1)$ và $(8, 1)$ sẽ giữ nguyên kết quả thành viên không đổi so với Vòng lặp 2. Thuật toán chính thức **đạt trạng thái ổn định**: phép gán cụm không đổi và các tâm cụm không còn di chuyển. Với K -means, đây là nghiệm hội tụ cục bộ phụ thuộc vào khởi tạo, không phải bảo đảm nghiệm tối ưu toàn cục cho mọi bộ dữ liệu.

5. Thực Hành Hiện Thực Hóa Thuật Toán Bằng Python

Đoạn mã Python dưới đây lập trình lại toàn bộ quy trình Coordinate Descent của thuật toán K -means chuẩn để bạn chạy kiểm thử:

```
import numpy as np

class KMeansClustering:
    def __init__(self, k=2, max_iters=100):
        self.k = k
        self.max_iters = max_iters
        self.centroids = None

    def fit(self, X):
        # Khởi tạo ngẫu nhiên K tâm cụm từ các điểm dữ liệu thực tế
        n_samples, n_features = X.shape
        random_indices = np.random.choice(n_samples, self.k, replace=False)
```

```

self.centroids = X[random_indices]

for _ in range(self.max_iters):
    # Bước 1: Gán cụm (Cluster Assignment)
    # Tính khoảng cách từ tất cả các điểm đến toàn bộ K tâm cụm
    distances = np.linalg.norm(X[:, np.newaxis] - self.centroids,
↪ axis=2)
    labels = np.argmin(distances, axis=1)

    # Lưu lại tâm cụm cũ để kiểm tra điều kiện dừng hội tụ
    old_centroids = self.centroids.copy()

    # Bước 2: Cập nhật tâm cụm (Centroid Update)
    for cluster_idx in range(self.k):
        cluster_points = X[labels == cluster_idx]
        if len(cluster_points) > 0:
            self.centroids[cluster_idx] = np.mean(cluster_points,
↪ axis=0)

    # Nếu tọa độ tâm cụm không đổi, giải thuật đã hội tụ về một
    ↪ nghiệm ổn định
    if np.allclose(old_centroids, self.centroids):
        break

return labels

# Nạp đúng dữ liệu mẫu từ bài tập trace bằng tay trong ghi chép
X_trace = np.array([
    [1.0, 1.0],
    [2.0, 1.0],
    [4.0, 1.0],
    [7.0, 1.0],
    [9.0, 1.0]
])

# Chạy giải thuật thực nghiệm
np.random.seed(0)
kmeans = KMeansClustering(k=2, max_iters=10)
final_labels = kmeans.fit(X_trace)
print("Tọa độ các tâm cụm hội tụ cuối cùng:\n", kmeans.centroids)
print("Nhãn cụm hội tụ được gán tương ứng cho từng mẫu:", final_labels)

```

Tọa độ các tâm cụm hội tụ cuối cùng:

```
[[8.          1.          ]  
 [2.33333333 1.          ]]
```

Nhãn cụm hội tụ được gán tương ứng cho từng mẫu: [1 1 1 0 0]

```
import numpy as np  
import matplotlib.pyplot as plt  
  
X_trace = np.array([  
    [1.0, 1.0],  
    [2.0, 1.0],  
    [4.0, 1.0],  
    [7.0, 1.0],  
    [9.0, 1.0]  
)  
  
centroids = np.array([[2.0, 1.0], [4.0, 1.0]])  
history = []  
  
for iteration in range(4):  
    distances = np.linalg.norm(X_trace[:, None, :] - centroids[None, :, :],  
    ↪ axis=2)  
    labels = np.argmin(distances, axis=1)  
    distortion = np.mean(np.min(distances, axis=1) ** 2)  
    history.append((iteration, centroids.copy(), labels.copy(), distortion))  
  
    new_centroids = centroids.copy()  
    for k in range(2):  
        if np.any(labels == k):  
            new_centroids[k] = X_trace[labels == k].mean(axis=0)  
    if np.allclose(new_centroids, centroids):  
        break  
    centroids = new_centroids  
  
print("Distortion theo từng vòng lặp:", [round(item[3], 3) for item in  
    ↪ history])  
  
fig, axes = plt.subplots(1, len(history), figsize=(4 * len(history), 3.2),  
    ↪ sharey=True)  
if len(history) == 1:  
    axes = [axes]  
  
colors = np.array(["#4C78A8", "#F58518"])
```

```

for ax, (iteration, centroids_i, labels_i, distortion_i) in zip(axes,
    ↪ history):
    ax.scatter(X_trace[:, 0], X_trace[:, 1], c=colors[labels_i], s=80,
    ↪ edgecolor="black", label="data points")
    ax.scatter(centroids_i[:, 0], centroids_i[:, 1], c=colors, marker="X",
    ↪ s=220, edgecolor="black", label="centroids")
    for point, label in zip(X_trace, labels_i):
        center = centroids_i[label]
        ax.plot([point[0], center[0]], [point[1], center[1]],
    ↪ color=colors[label], alpha=0.55)
    ax.set_title(f"iter {iteration}\nJ={distortion_i:.3f}")
    ax.set_xlim(0, 10)
    ax.set_ylim(0.4, 1.8)
    ax.set_xlabel("$x_1$")
    ax.grid(alpha=0.25)
axes[0].set_ylabel("$x_2$")
plt.tight_layout()
plt.show()

```

Distortion theo từng vòng lặp: [np.float64(7.0), np.float64(2.461), np.float64(1.333)]




Figure 14: Trace trực quan của K-means: phép gán ổn định dần và distortion giảm đơn điệu.

6. Bảng Công thức Thi: Các Điểm Cốt lõi của K-means

Khái niệm	Điều cần nhớ
Đầu vào	Chỉ có đặc trưng $\mathbf{x}^{(i)}$; không có nhãn $y^{(i)}$.

Khái niệm	Điều cần nhớ
Mục tiêu	Tối thiểu hóa khoảng cách bình phương trung bình từ mỗi điểm đến tâm cụm được gán.
Bước gán cụm	Chọn tâm gần nhất: $c^{(i)} \leftarrow \arg \min_k \ \mathbf{x}^{(i)} - \mu_k\ ^2$.
Bước cập nhật tâm	Thay mỗi tâm cụm bằng trung bình các điểm được gán vào cụm đó.
Hội tụ	Chi phí không tăng, nhưng nghiệm cuối có thể là cục bộ, không chắc tối ưu toàn cục.
Điểm yếu chính	Nhạy với khởi tạo và giá trị K .
Cách cải thiện	Dùng K-means++ và chạy nhiều lần với các khởi tạo khác nhau.

Mẹo nhớ một dòng: bước gán chọn tâm gần nhất; bước cập nhật kéo tâm về trung bình các điểm được gán.

Bộ bài tập mẫu có lời giải

Đề bài. Cho các điểm một chiều $x = \{1, 2, 4, 7, 9\}$ và $K = 2$. Khởi tạo $\mu_1 = 2, \mu_2 = 4$. Hãy thực hiện một vòng K-means đầu tiên.

Lời giải từng bước.

1. Gán cụm theo tâm gần nhất:

- $x = 1$: gần $\mu_1 = 2$ hơn, nên vào cụm 1.
- $x = 2$: trùng $\mu_1 = 2$, nên vào cụm 1.
- $x = 4$: trùng $\mu_2 = 4$, nên vào cụm 2.
- $x = 7$: gần $\mu_2 = 4$ hơn, nên vào cụm 2.
- $x = 9$: gần $\mu_2 = 4$ hơn, nên vào cụm 2.

2. Ta có:

$$C_1 = \{1, 2\}, \quad C_2 = \{4, 7, 9\}$$

3. Cập nhật tâm cụm:

$$\mu_1 = \frac{1 + 2}{2} = 1.5$$

$$\mu_2 = \frac{4 + 7 + 9}{3} = \frac{20}{3} \approx 6.67$$

Kết luận. Sau vòng đầu tiên, hai tâm mới là $\mu_1 = 1.5$ và $\mu_2 \approx 6.67$.

Bài 2: K-means trên bộ dữ liệu 10 điểm hai chiều

Đề bài. Cho 10 điểm:

dòng	x_1	x_2
1	1.0	1.0
2	1.2	0.8
3	0.8	1.3
4	1.5	1.1
5	2.0	1.0
6	7.0	7.0
7	7.5	6.8
8	6.8	7.4
9	8.0	7.2
10	7.2	7.8

Chạy K-means với $K = 2$, khởi tạo $\mu_1 = (1, 1)$ và $\mu_2 = (7, 7)$. Hãy theo dõi nhãn cụm, tâm cụm, và distortion đến khi hội tụ.

Lời giải.

Vòng 0 dùng tâm ban đầu:

$$\mu_1^{(0)} = (1, 1), \quad \mu_2^{(0)} = (7, 7)$$

Ví dụ điểm $(2.0, 1.0)$:

$$d^2((2, 1), \mu_1) = (2 - 1)^2 + (1 - 1)^2 = 1$$

$$d^2((2, 1), \mu_2) = (2 - 7)^2 + (1 - 7)^2 = 61$$

Nên điểm này thuộc cụm 1. Các điểm 1 đến 5 gần μ_1 , các điểm 6 đến 10 gần μ_2 :

$$C_1 = \{(1.0, 1.0), (1.2, 0.8), (0.8, 1.3), (1.5, 1.1), (2.0, 1.0)\}$$

$$C_2 = \{(7.0, 7.0), (7.5, 6.8), (6.8, 7.4), (8.0, 7.2), (7.2, 7.8)\}$$

Distortion vòng 0 là trung bình khoảng cách bình phương đến tâm được gán:

$$J^{(0)} \approx 0.368$$

Cập nhật tâm cụm:

$$\mu_1^{(1)} = \left(\frac{1.0 + 1.2 + 0.8 + 1.5 + 2.0}{5}, \frac{1.0 + 0.8 + 1.3 + 1.1 + 1.0}{5} \right) = (1.30, 1.04)$$

$$\mu_2^{(1)} = \left(\frac{7.0 + 7.5 + 6.8 + 8.0 + 7.2}{5}, \frac{7.0 + 6.8 + 7.4 + 7.2 + 7.8}{5} \right) = (7.30, 7.24)$$

Vòng 1, khi dùng hai tâm mới, nhãn cụm không đổi:

$$C_1 = \text{điểm 1 đến 5}, \quad C_2 = \text{điểm 6 đến 10}$$

Distortion giảm:

$$J^{(1)} \approx 0.248$$

Vì cập nhật lại trung bình vẫn cho (1.30, 1.04) và (7.30, 7.24), thuật toán hội tụ.

Kết luận. Vì dữ liệu tách thành hai nhóm rất rõ, K-means hội tụ nhanh. Với dữ liệu thật, nên chạy nhiều khởi tạo vì kết quả phụ thuộc tâm ban đầu.

Bài 3: Chọn K bằng elbow từ bảng distortion

Đề bài. Giả sử chạy K-means với nhiều K thu được distortion:

K	1	2	3	4	5	6
distortion	38.5	8.2	5.7	4.9	4.5	4.2

Chọn K hợp lý.

Lời giải. Khi tăng K , distortion luôn giảm hoặc giữ nguyên. Ta tìm điểm mà mức giảm bắt đầu chậm lại:

- Từ $K = 1$ sang $K = 2$: giảm 30.3, rất lớn.
- Từ $K = 2$ sang $K = 3$: giảm 2.5.
- Các bước sau giảm rất ít.

Kết luận. Elbow nằm tại $K = 2$. Đây là lựa chọn hợp lý vì thêm cụm sau 2 không cải thiện distortion nhiều.