

Học máy: Hồi quy Tuyến tính từ Xác suất, MLE, và Ma trận

Quoc Kien

1. Vì sao OLS có thể xuất hiện từ xác suất?

Bản đồ ký hiệu ma trận

Ký hiệu	Nghĩa	Kích thước thường gặp
$\mathbf{X}$	Ma trận thiết kế, thường có cột 1 cho bias	$n \times p$
$\mathbf{y}$	Vector mục tiêu thật	$n \times 1$
β	Vector hệ số cần học	$p \times 1$
$\hat{\mathbf{y}}$	Vector dự đoán	$\mathbf{X}\beta$
$\mathbf{r}$	Vector residual	$\mathbf{y} - \mathbf{X}\beta$
σ^2	Phương sai nhiễu Gaussian	Một số dương

Khi gặp bài MLE dẫn tới OLS, hãy đọc theo chuỗi: giả định Gaussian cho y_i , viết likelihood, lấy log, bỏ các hằng số không phụ thuộc β , rồi nhận ra cực đại log-likelihood tương đương cực tiểu $\|\mathbf{y} - \mathbf{X}\beta\|_2^2$.

Trong mô hình hồi quy tuyến tính, ta không giả sử dữ liệu nằm hoàn hảo trên một đường hoặc một mặt phẳng. Ta giả sử mỗi nhãn thật được tạo bởi phân tín hiệu tuyến tính cộng với nhiễu:

$$y_i = \beta^T \mathbf{x}_i + \epsilon_i$$

Trong đó:

- $\mathbf{x}_i$ là vector đặc trưng của mẫu thứ i . Nếu mô hình có intercept, phần tử đầu tiên của $\mathbf{x}_i$ thường là 1.
- β là vector hệ số cần học.

- ϵ_i là phần nhiễu mà mô hình không giải thích được.

Giả định quan trọng nhất:

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Nghĩa là sai số có trung bình bằng 0, độc lập giữa các mẫu, và có cùng phương sai σ^2 . Khi đó:

$$y_i \mid \mathbf{x}_i; \beta \sim \mathcal{N}(\beta^T \mathbf{x}_i, \sigma^2)$$

Mật độ xác suất của một nhãn y_i là:

$$p(y_i \mid \mathbf{x}_i; \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

Trực giác: nếu mô hình dự đoán gần y_i , sai số nhỏ, mũ âm nhỏ, xác suất cao. Nếu mô hình dự đoán rất xa, sai số bình phương lớn, xác suất thấp.

2. Maximum Likelihood Estimation dẫn tới OLS

Vì các mẫu độc lập, xác suất quan sát toàn bộ dữ liệu là tích của xác suất từng mẫu:

$$L(\beta) = \prod_{i=1}^n p(y_i \mid \mathbf{x}_i; \beta)$$

Thay công thức Gaussian vào:

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

Tích nhiều số nhỏ dễ khó nhìn, nên ta lấy log. Vì log là hàm tăng đơn điệu, cực đại của L cũng là cực đại của $\ell = \log L$:

$$\ell(\beta) = \sum_{i=1}^n \left[\log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2} \right]$$

Gộp hằng số:

$$\ell(\beta) = n \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Khi tối ưu theo β :

- Hằng $n \log \left(\frac{1}{\sqrt{2\pi}\sigma} \right)$ là hằng số.
- $\frac{1}{2\sigma^2}$ là hệ số dương.
- Tối đa hóa số âm của tổng bình phương sai số tương đương tối thiểu hóa tổng bình phương sai số.

Vì vậy:

$$\max_{\beta} \ell(\beta) \iff \min_{\beta} \frac{1}{2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Kết luận lớn: OLS không chỉ là một mẹo hình học. Nó là nghiệm MLE nếu nhiễu của hồi quy tuyến tính là Gaussian i.i.d.

3. Biểu diễn ma trận

Với n mẫu và p đặc trưng, gom dữ liệu thành:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} \in \mathbb{R}^{n \times p}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} \in \mathbb{R}^p$$

Vector dự đoán toàn bộ dữ liệu là:

$$\hat{\mathbf{y}} = \mathbf{X}\beta$$

Vector sai số:

$$\mathbf{r} = \mathbf{y} - \mathbf{X}\beta$$

Loss OLS dạng ma trận:

$$L(\beta) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 = \frac{1}{2} (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

Nếu bạn thấy biểu thức này trong đề thi, hãy đọc nó như sau: lấy từng residual, bình phương, cộng lại, rồi nhân $\frac{1}{2}$.

4. Suy luận Normal Equations

Khai triển loss:

$$\begin{aligned} L(\beta) &= \frac{1}{2} (\mathbf{y}^T - \beta^T \mathbf{X}^T) (\mathbf{y} - \mathbf{X}\beta) \\ &= \frac{1}{2} (\mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta) \end{aligned}$$

Hai hạng giữa là scalar và là chuyển vị của nhau, nên bằng nhau:

$$\mathbf{y}^T \mathbf{X}\beta = \beta^T \mathbf{X}^T \mathbf{y}$$

Do đó:

$$L(\beta) = \frac{1}{2} (\mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta)$$

Lấy gradient theo β :

$$\nabla_{\beta} L = -\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X}\beta$$

Tại điểm cực tiểu, gradient bằng vector 0:

$$-\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X}\beta = \mathbf{0}$$

Suy ra hệ phương trình chuẩn:

$$\boxed{\mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y}}$$

Nếu $\mathbf{X}^T \mathbf{X}$ khả nghịch:

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Trong code, nên dùng `np.linalg.solve(X.T @ X, X.T @ y)` thay vì tự tính nghịch đảo, vì solve thường ổn định số học hơn.

5. Ý nghĩa hình học

Normal equations có thể viết lại:

$$\mathbf{X}^T (\mathbf{y} - \mathbf{X}\beta) = \mathbf{0}$$

Tức là:

- $\hat{\mathbf{y}} = \mathbf{X}\beta$ nằm trong không gian cột của $\mathbf{X}$.
- Residual $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$ vuông góc với từng cột của $\mathbf{X}$.
- OLS chọn hình chiếu vuông góc của $\mathbf{y}$ lên không gian mà mô hình có thể biểu diễn.

```
import numpy as np
import matplotlib.pyplot as plt

X = np.array([
    [1.0, 0.0],
    [1.0, 1.0],
    [1.0, 2.0],
    [1.0, 3.0],
])
y = np.array([1.0, 2.2, 1.9, 3.2])
beta = np.linalg.solve(X.T @ X, X.T @ y)
y_hat = X @ beta
residual = y - y_hat

print("beta:", np.round(beta, 3))
print("X.T @ residual:", np.round(X.T @ residual, 10))

plt.figure(figsize=(7, 4))
plt.scatter(X[:, 1], y, label="y quan sát", color="#4C78A8", s=70)
plt.plot(X[:, 1], y_hat, label="đường fit OLS", color="#F58518", linewidth=2)
for x_i, y_i, y_fit in zip(X[:, 1], y, y_hat):
```

```
plt.plot([x_i, x_i], [y_fit, y_i], color="#A0AEC0", linestyle="--")
plt.title("Normal equations như phép chiếu vuông góc")
plt.xlabel("đặc trưng x")
plt.ylabel("mục tiêu y")
plt.legend()
plt.grid(alpha=0.25)
plt.show()
```

beta: [1.13 0.63]
X.T @ residual: [-0. -0.]




Figure 1: OLS chiếu y lên không gian dự đoán; residual vuông góc với các cột của X.

6. Quy trình giải bài Matrix OLS

Khi đề cho nhiều biến hoặc yêu cầu dùng ma trận, hãy làm theo checklist:

1. Tạo $\mathbf{X}$, nhớ thêm cột 1 nếu mô hình có intercept.
2. Kiểm tra kích thước:

$$\mathbf{X} : n \times p, \quad \beta : p \times 1, \quad \mathbf{y} : n \times 1$$

3. Tính ba khối:

$$\mathbf{X}^T \mathbf{X}, \quad \mathbf{X}^T \mathbf{y}, \quad (\mathbf{X}^T \mathbf{X})^{-1}$$

4. Tính nghiệm:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

5. Kiểm tra residual bằng trực giao:

$$\mathbf{X}^T (\mathbf{y} - \mathbf{X} \hat{\beta}) = \mathbf{0}$$

Bẫy thường gặp: nếu $\mathbf{X}^T \mathbf{X}$ không khả nghịch, không dùng được công thức inverse trực tiếp. Khi đó cần pseudo-inverse, regularization, hoặc loại bỏ đặc trưng phụ thuộc tuyến tính.

7. Bảng Công thức Thi: Matrix OLS

Nhiệm vụ	Công thức	Cách dùng khi làm bài
Mô hình xác suất	$y_i \mid \mathbf{x}_i \sim \mathcal{N}(\beta^T \mathbf{x}_i, \sigma^2)$	Nhận ra OLS từ giả định nhiều Gaussian.
Likelihood	$L = \prod_i p(y_i \mid \mathbf{x}_i; \beta)$	Mẫu độc lập nên xác suất nhân lại.
Log-likelihood	$\ell = \log L$	Biến tích thành tổng, dễ đạo hàm.
Loss ma trận	$L = \frac{1}{2} \ \mathbf{y} - \mathbf{X}\beta\ _2^2$	Dạng ngắn của RSS.
Gradient	$\nabla L = -\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X} \beta$	Đặt bằng 0 để tìm nghiệm đóng.
Normal equations	$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$	Hệ tuyến tính cần giải.
Nghiệm đóng	$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$	Dùng khi ma trận khả nghịch.
Pseudoinverse	$\beta = \mathbf{X}^+ \mathbf{y}$	Dùng khi $\mathbf{X}^T \mathbf{X}$ suy biến hoặc gần suy biến.

Quy trình thay số:

1. Thêm cột 1 nếu cần intercept.
 2. Tính $\mathbf{G} = \mathbf{X}^T \mathbf{X}$.
 3. Tính $\mathbf{h} = \mathbf{X}^T \mathbf{y}$.
 4. Giải $\mathbf{G}\beta = \mathbf{h}$.
 5. Dự đoán bằng $\hat{\mathbf{y}} = \mathbf{X}\beta$.
 6. Kiểm tra $\mathbf{X}^T(\mathbf{y} - \hat{\mathbf{y}}) \approx \mathbf{0}$.
-

Dạng bài chứng minh: Gaussian MLE dẫn tới Normal Equations

Khi đề yêu cầu chứng minh OLS từ giả định Gaussian, hãy viết theo chuỗi sau:

Giả định:

$$y_i = \beta^T \mathbf{x}_i + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Suy ra:

$$p(y_i | \mathbf{x}_i; \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta^T \mathbf{x}_i)^2}{2\sigma^2}\right)$$

Log-likelihood toàn bộ dữ liệu:

$$\ell(\beta) = C - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Trong đó C không phụ thuộc β . Vì vậy:

$$\arg \max_{\beta} \ell(\beta) = \arg \min_{\beta} \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2$$

Dạng ma trận:

$$L(\beta) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

Gradient:

$$\nabla L = -\mathbf{X}^T(\mathbf{y} - \mathbf{X}\beta)$$

Đặt bằng 0:

$$\mathbf{X}^T\mathbf{X}\beta = \mathbf{X}^T\mathbf{y}$$

Đây là Normal Equations.

8. Bộ bài tập mẫu có lời giải

Bài 1: Giải OLS bằng ma trận với hai điểm

Đề bài. Fit đường thẳng có intercept qua hai điểm $(x, y) = (0, 1)$ và $(1, 3)$ bằng công thức ma trận.

Lời giải.

Thiết kế ma trận:

$$\mathbf{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$$

Tính:

$$\mathbf{X}^T\mathbf{X} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{X}^T\mathbf{y} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

Normal equations:

$$\begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

Từ phương trình thứ hai: $\beta_0 + \beta_1 = 3$. Từ phương trình thứ nhất: $2\beta_0 + \beta_1 = 4$. Trừ hai phương trình:

$$\beta_0 = 1, \quad \beta_1 = 2$$

Vậy:

$$\boxed{\hat{y} = 1 + 2x}$$

Bài 2: Bộ dữ liệu 10 dòng, giải đầy đủ bằng matrix OLS

Đề bài. Cho dữ liệu học tập sau. Mô hình có dạng $\hat{y} = \beta_0 + \beta_1 h + \beta_2 q$, trong đó h là số giờ học, q là số quiz đã làm. Hãy tính hệ số OLS và dự đoán điểm cho sinh viên học $h = 6$ giờ, làm $q = 5$ quiz.

dòng	h	q	y
1	1	1	52
2	2	1	57
3	2	2	60
4	3	2	65
5	4	3	71
6	5	3	76
7	5	4	79
8	6	4	84
9	7	5	90
10	8	5	95

Lời giải bằng công thức. Tạo:

$$\mathbf{X} = \begin{pmatrix} 1 & h_1 & q_1 \\ 1 & h_2 & q_2 \\ \vdots & \vdots & \vdots \\ 1 & h_{10} & q_{10} \end{pmatrix}, \quad \beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Từ bảng dữ liệu, ta có:

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 10 & 43 & 30 \\ 43 & 233 & 159 \\ 30 & 159 & 110 \end{pmatrix}$$

và

$$\mathbf{X}^T \mathbf{y} = \begin{pmatrix} 729 \\ 3434 \\ 2377 \end{pmatrix}$$

Do đó normal equations là:

$$\begin{pmatrix} 10 & 43 & 30 \\ 43 & 233 & 159 \\ 30 & 159 & 110 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} 729 \\ 3434 \\ 2377 \end{pmatrix}$$

Giải hệ tuyến tính này cho:

$$\beta \approx \begin{pmatrix} 45.323 \\ 4.613 \\ 2.581 \end{pmatrix}$$

Vậy mô hình là:

$$\hat{y} = 45.323 + 4.613h + 2.581q$$

Dự đoán cho $h = 6, q = 5$:

$$\hat{y} = 45.323 + 4.613(6) + 2.581(5)$$

$$\hat{y} = 45.323 + 27.678 + 12.905 = 85.906$$

Cách đọc kết quả. Hệ số $\beta_1 \approx 4.613$ cho biết khi giữ số quiz không đổi, học thêm một giờ làm điểm dự đoán tăng trung bình khoảng 4.613. Hệ số $\beta_2 \approx 2.581$ cho biết khi giữ số giờ học không đổi, làm thêm một quiz làm điểm dự đoán tăng trung bình khoảng 2.581.

Kết luận. Dự đoán điểm cho sinh viên học 6 giờ và làm 5 quiz là khoảng 85.91.