

Học máy: Suy luận Bình phương Tối thiểu OLS

Quoc Kien

1. Mô hình Hồi quy Tuyến tính Đơn

Bản đồ ký hiệu và quy trình thay số

Ký hiệu	Nghĩa	Khi làm bài dùng thế nào?
x_i	Giá trị đầu vào của mẫu thứ i	Cột dữ liệu độc lập.
y_i	Giá trị mục tiêu thật của mẫu thứ i	Cột cần dự đoán.
$\hat{y}_i$	Giá trị mô hình dự đoán	$\hat{y}_i = \beta_0 + \beta_1 x_i$.
$\bar{x}, \bar{y}$	Trung bình của x và y	Dùng để tính hệ số góc và hệ số chặn.
β_1	Hệ số góc	Đo y đổi bao nhiêu khi x tăng 1 đơn vị.
β_0	Hệ số chặn	Giá trị dự đoán khi $x = 0$.
e_i	Residual/sai số	$e_i = y_i - \hat{y}_i$.

Quy trình tính tay: tính $\bar{x}, \bar{y}$ trước, sau đó tính $\sum(x_i - \bar{x})(y_i - \bar{y})$ và $\sum(x_i - \bar{x})^2$, cuối cùng suy ra β_1, β_0 , rồi kiểm tra bằng residual.

Trong hồi quy tuyến tính đơn, ta mô hình hóa quan hệ giữa biến phụ thuộc y và biến độc lập x bằng một đường thẳng:

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

Trong đó:

- β_0 là **hệ số chặn**: giá trị dự đoán của y khi $x = 0$.
- β_1 là **hệ số góc**: khi x tăng 1 đơn vị, $\hat{y}$ thay đổi trung bình β_1 đơn vị.
- $\hat{y}_i$ là giá trị mô hình dự đoán cho quan sát thứ i .

Mục tiêu của OLS là chọn β_0, β_1 sao cho sai lệch giữa dữ liệu thật y_i và dự đoán $\hat{y}_i$ là nhỏ nhất.

2. Hàm mất mát: Residual Sum of Squares

Sai số của điểm thứ i là:

$$e_i = y_i - \hat{y}_i = y_i - \beta_0 - \beta_1 x_i$$

OLS dùng tổng bình phương sai số:

$$RSS = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Ta thường đặt thêm hệ số $\frac{1}{2}$ để khi đạo hàm, số 2 triệt tiêu:

$$f(\beta_0, \beta_1) = \frac{1}{2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Trực giác: bình phương làm sai số âm/dương đều thành dương, đồng thời phạt mạnh các điểm lệch xa.

3. Suy luận hệ số chặn β_0

Lấy đạo hàm riêng theo β_0 :

$$\frac{\partial f}{\partial \beta_0} = \sum_{i=1}^n -(y_i - \beta_0 - \beta_1 x_i) = 0$$

Nhân hai vế với -1 :

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

Tách tổng:

$$\sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0$$

Chuyển vế:

$$n\beta_0 = \sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i$$

Chia cho n :

$$\beta_0 = \frac{1}{n} \sum_{i=1}^n y_i - \beta_1 \frac{1}{n} \sum_{i=1}^n x_i$$

Vì $\bar{x} = \frac{1}{n} \sum x_i$ và $\bar{y} = \frac{1}{n} \sum y_i$, ta có:

$$\boxed{\beta_0 = \bar{y} - \beta_1 \bar{x}}$$

Điều này cũng cho thấy đường OLS luôn đi qua điểm trung bình $(\bar{x}, \bar{y})$.

4. Suy luận hệ số góc β_1

Lấy đạo hàm riêng theo β_1 :

$$\frac{\partial f}{\partial \beta_1} = \sum_{i=1}^n -(y_i - \beta_0 - \beta_1 x_i)x_i = 0$$

Nhân với -1 :

$$\sum_{i=1}^n (x_i y_i - \beta_0 x_i - \beta_1 x_i^2) = 0$$

Thay $\beta_0 = \bar{y} - \beta_1 \bar{x}$ và dùng $\sum x_i = n\bar{x}$:

$$\sum x_i y_i - (\bar{y} - \beta_1 \bar{x})n\bar{x} - \beta_1 \sum x_i^2 = 0$$

Khai triển:

$$\sum x_i y_i - n\bar{x}\bar{y} + n\beta_1 \bar{x}^2 - \beta_1 \sum x_i^2 = 0$$

Gom các hạng tử chứa β_1 :

$$\sum x_i y_i - n\bar{x}\bar{y} = \beta_1 \left(\sum x_i^2 - n\bar{x}^2 \right)$$

Suy ra:

$$\beta_1 = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$$

Dạng dễ nhớ hơn:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Tử số đo mức x và y cùng biến thiên; mẫu số đo độ phân tán của x .

5. Quy trình giải bài OLS trong 60 giây

Khi gặp một bài OLS tuyến tính đơn, hãy đi theo thứ tự này:

1. Lập bảng $x_i, y_i, x_i - \bar{x}, y_i - \bar{y}$.
2. Tính hai tổng quan trọng:

$$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), \quad S_{xx} = \sum_i (x_i - \bar{x})^2$$

3. Tính:

$$\beta_1 = \frac{S_{xy}}{S_{xx}}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

4. Viết mô hình cuối:

$$\hat{y} = \beta_0 + \beta_1 x$$

5. Nếu đề hỏi kiểm tra chất lượng, tính residual:

$$e_i = y_i - \hat{y}_i$$

Bẫy thường gặp: không được dùng công thức $\beta_1 = \frac{\sum x_i y_i}{\sum x_i^2}$ trừ khi dữ liệu đã được centered hoặc mô hình không có intercept. Với OLS thường có intercept, phải dùng độ lệch quanh trung bình.

6. Bảng Công thức Thi: Quy trình Thay số OLS

Bước	Công thức	Ý nghĩa
1. Tính trung bình	$\bar{x} = \frac{1}{n} \sum x_i, \bar{y} = \frac{1}{n} \sum y_i$	Xác định tâm dữ liệu.
2. Tính S_{xy}	$S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	Đo x, y biến thiên cùng nhau.
3. Tính S_{xx}	$S_{xx} = \sum (x_i - \bar{x})^2$	Đo độ phân tán của x .
4. Tính slope	$\beta_1 = \frac{S_{xy}}{S_{xx}}$	Độ dốc đường hồi quy.
5. Tính intercept	$\beta_0 = \bar{y} - \beta_1 \bar{x}$	Dịch đường thẳng cho đi qua điểm trung bình.
6. Dự đoán	$\hat{y} = \beta_0 + \beta_1 x$	Thay x mới vào mô hình.
7. Tính residual	$e_i = y_i - \hat{y}_i$	Sai số dọc của từng điểm.

Mẹo nhớ nhanh.

- $\beta_1 > 0$: x tăng thì y có xu hướng tăng.
- $\beta_1 < 0$: x tăng thì y có xu hướng giảm.
- Nếu $S_{xx} = 0$, mọi x_i giống nhau nên không xác định được slope.
- Đường OLS luôn đi qua $(\bar{x}, \bar{y})$.

7. Minh họa bằng Python

```

import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)
X = 2 * np.random.rand(50, 1)
y = 4 + 3 * X + np.random.randn(50, 1)

x_mean = np.mean(X)
y_mean = np.mean(y)
beta_1 = np.sum((X - x_mean) * (y - y_mean)) / np.sum((X - x_mean) ** 2)
beta_0 = y_mean - beta_1 * x_mean

X_new = np.array([[0], [2]])
y_predict = beta_0 + beta_1 * X_new

print("beta_0:", round(float(beta_0), 3))
print("beta_1:", round(float(beta_1), 3))

plt.figure(figsize=(8, 5))
plt.scatter(X, y, color="#4C78A8", label="Dữ liệu")
plt.plot(X_new, y_predict, color="#F58518", linewidth=2, label=f"OLS: y =  
↪ {beta_0:.2f} + {beta_1:.2f}x")
plt.xlabel("x")
plt.ylabel("y")
plt.title("Minh họa hồi quy tuyến tính OLS")
plt.legend()
plt.grid(alpha=0.25)
plt.show()

```

```

beta_0: 4.097
beta_1: 2.888

```




Figure 1: Đường OLS khớp dữ liệu và các residual theo phương dọc.

8. Bộ bài tập mẫu có lời giải

Bài 1: Tính đường OLS từ 3 điểm

Đề bài. Cho ba điểm $(1, 2)$, $(2, 3)$, $(3, 5)$. Tìm đường OLS $\hat{y} = \beta_0 + \beta_1 x$.

Lời giải.

$$\bar{x} = \frac{1 + 2 + 3}{3} = 2, \quad \bar{y} = \frac{2 + 3 + 5}{3} = \frac{10}{3}$$

$$S_{xy} = (1 - 2)(2 - \frac{10}{3}) + (2 - 2)(3 - \frac{10}{3}) + (3 - 2)(5 - \frac{10}{3}) = 3$$

$$S_{xx} = (1 - 2)^2 + (2 - 2)^2 + (3 - 2)^2 = 2$$

$$\beta_1 = \frac{3}{2} = 1.5, \quad \beta_0 = \frac{10}{3} - 1.5(2) = \frac{1}{3}$$

Kết luận.

$$\hat{y} = \frac{1}{3} + 1.5x$$

Bài 2: Dữ liệu 10 dòng và dự đoán

Đề bài. Cho bảng dữ liệu:

x	1	2	3	4	5	6	7	8	9	10
y	3	5	6	8	11	12	14	17	18	20

Hãy fit đường OLS và dự đoán y khi $x = 12$.

Tính trung bình:

$$\bar{x} = \frac{1 + 2 + \dots + 10}{10} = 5.5$$

$$\bar{y} = \frac{3 + 5 + 6 + 8 + 11 + 12 + 14 + 17 + 18 + 20}{10} = 11.4$$

Tính hai tổng chính:

$$S_{xy} = \sum_{i=1}^{10} (x_i - \bar{x})(y_i - \bar{y}) = 159.0$$

$$S_{xx} = \sum_{i=1}^{10} (x_i - \bar{x})^2 = 82.5$$

Hệ số góc:

$$\beta_1 = \frac{S_{xy}}{S_{xx}} = \frac{159.0}{82.5} \approx 1.927$$

Hệ số chặn:

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = 11.4 - 1.927(5.5) \approx 0.800$$

Đường OLS:

$$\hat{y} = 0.800 + 1.927x$$

Dự đoán tại $x = 12$:

$$\hat{y} = 0.800 + 1.927(12) \approx 23.927$$

Kết luận. Khi $x = 12$, mô hình dự đoán $y \approx \boxed{23.93}$.

Bài 3: Dùng residual để kiểm tra đường OLS

Đề bài. Với bộ dữ liệu ở Bài 2, sau khi fit OLS, hãy kiểm tra hai điều kiện:

$$\sum_{i=1}^n e_i = 0, \quad \sum_{i=1}^n x_i e_i = 0$$

Trong đó $e_i = y_i - \hat{y}_i$. Giải thích vì sao hai điều kiện này quan trọng.

Lời giải. Điều kiện thứ nhất nói residual không còn lệch trung bình lên hoặc xuống. Điều kiện thứ hai nói residual không còn tương quan tuyến tính với x . Nếu một trong hai điều kiện còn lớn, ta vẫn có thể chỉnh intercept hoặc slope để giảm RSS.

Từ $\hat{y} = 0.800 + 1.927x$, residual xấp xỉ:

x	1	2	3	4	5	6	7	8	9	10
$e = y - \hat{y}$	0.273	0.345	-0.582	-0.509	0.564	-0.364	-0.291	0.782	-0.145	-0.073

Tổng residual:

$$\sum e_i \approx 0.273 + 0.345 - 0.582 - 0.509 + 0.564 - 0.364 - 0.291 + 0.782 - 0.145 - 0.073 \approx 0$$

Tổng $x_i e_i$:

$$\sum x_i e_i \approx 0$$

RSS:

$$\sum e_i^2 \approx 1.964$$

Kết luận. Hai tổng gần 0 xác nhận nghiệm OLS đã dừng đúng tại điểm cực tiểu. Đây là cách kiểm tra nhanh khi đề bài yêu cầu chứng minh đường fit đã tối ưu.